

UNIVERSIDADE ESTADUAL DO NORTE DO PARANÁ
***CAMPUS* LUIZ MENEGHEL**
CENTRO DE CIÊNCIAS TECNOLÓGICAS
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

Diego Souza Vieira

Viabilidade da detecção e contagem automática de instrumentos cirúrgicos por visão computacional

BANDEIRANTES
2026

Diego Souza Vieira

Viabilidade da detecção e contagem automática de instrumentos cirúrgicos por visão computacional

Trabalho de Conclusão de Curso apresentado ao curso de Ciência da Computação da Universidade Estadual do Norte do Paraná, como requisito parcial para a obtenção do título de Bacharel em Ciência da Computação.

Área de Concentração:Inteligência Artificial

Linha de Pesquisa: Visão Computacional

Orientador(a): Prof. Glauco Carlos Silva

BANDEIRANTES
2026

Ficha catalográfica

Diego Souza Vieira

Viabilidade da detecção e contagem automática de instrumentos cirúrgicos por visão computacional

Trabalho de Conclusão de Curso apresentado ao Curso de Bacharelado em Ciência da Computação da Universidade Estadual do Norte do Paraná, *Campus* Luiz Meneghel, Centro de Ciências Tecnológicas, como requisito parcial para obtenção do título de Bacharel em Ciência da Computação.

Área de Concentração: Inteligência Artificial

Linha de Pesquisa: Visão Computacional

Orientador(a): Prof. Glauco Carlos Silva

Banca Examinadora

Prof. Glauco Carlos Silva
Universidade Estadual do Norte do Paraná (UENP)
UENP | *Campus* Luiz Meneghel

Prof. Dr. Jader Maikol Caldonazzo Garbelini (membro interno)
Universidade Estadual do Norte do Paraná (UENP)
UENP | *Campus* Luiz Meneghel

Thiago Adriano Coleti (membro interno)
Universidade Estadual do Norte do Paraná (UENP)
UENP | *Campus* Luiz Meneghel

Bandeirantes, 00 do MÊS DE ano.

Dedico este trabalho a... *(opcional)*

Agradecimentos

Para o desenvolvimento desta pesquisa, eu agradeço a... *(opcional)*

Epígrafe *(opcional)*

Exemplo de epígrafe:

"A verdadeira viagem de descobrimento
não consiste em procurar novas
paisagens, mas em ter novos olhos"

– **Marcel Proust**

VIEIRA, Diego Souza Vieira. **Viabilidade da detecção e contagem automática de instrumentos cirúrgicos por visão computacional**. 2026. 66 f. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) – Centro de Ciências Tecnológicas, Universidade Estadual do Norte do Paraná, Bandeirantes, 2026.

Resumo

A conferência de instrumentos cirúrgicos envolve reconhecer os materiais e verificar suas quantidades em diferentes etapas da rotina hospitalar. Este trabalho avaliou a viabilidade técnica da detecção e da contagem automática de instrumentos selecionados da caixa de apendicectomia, visando ao apoio à conferência no expurgo e no preparo. Foram reunidas imagens de fontes públicas e fotografias do Hospital Universitário da Universidade Estadual de Londrina, submetidas à revisão, padronização das anotações e verificação de repetições. A base consolidada reuniu 10.327 imagens e 12.714 objetos anotados, organizados em sete categorias gerais. O modelo YOLO26n foi treinado durante 50 épocas, com dimensão de entrada configurada em 640 pixels. O limiar de confiança para a contagem foi definido no conjunto de validação e aplicado ao teste, composto por 1.008 imagens e 1.377 objetos. A avaliação alcançou mAP@0,50 de 98,06% e mAP@0,50:0,95 de 86,73%. A contagem total foi correta em 96,43% das imagens, enquanto as quantidades de todas as categorias coincidiram simultaneamente com a referência em 95,63%. O erro absoluto médio da contagem total foi de 0,0536 objeto por imagem. O acerto do total diminuiu de 99,29% nas imagens com um objeto para 78,43% nas cenas com quatro ou mais. O tempo médio de processamento por chamada completa foi de 29,24 ms no equipamento utilizado. Os resultados indicam viabilidade técnica inicial nas condições avaliadas, com limitações relacionadas à composição do teste, à cobertura das categorias e às dificuldades em cenas com vários instrumentos. A abordagem apresenta potencial como apoio à conferência, mas requer avaliação adicional antes de sua utilização na rotina hospitalar.

Norma de referência: ABNT NBR 6028 – Resumo, resenha e recensão (2021).

Palavras-chave: visão computacional; instrumentos cirúrgicos; detecção de objetos; contagem automática; YOLO.

VIEIRA, Diego Souza Vieira. **Feasibility of automatic surgical instrument detection and counting using computer vision**. 2026. 66p. Undergraduate Final Project (Bachelor's Degree in Computer Science) -- Center of Technological Sciences, Northern Paraná State University, Bandeirantes, 2026.

Abstract

Checking surgical instruments involves identifying items and verifying their quantities at different stages of hospital workflows. This study evaluated the technical feasibility of automatically detecting and counting selected instruments from an appendectomy set to support checking activities in the decontamination and preparation areas. Images from public sources and photographs from the University Hospital of the State University of Londrina were reviewed, their annotations were standardized, and repeated images were checked. The consolidated dataset comprised 10,327 images and 12,714 annotated objects organized into seven broad categories. A YOLO26n model was trained for 50 epochs with the input image size configured to 640 pixels. The confidence threshold for counting was selected using the validation set and then applied to the test set, which contained 1,008 images and 1,377 objects. The evaluation achieved a mAP@0.50 of 98.06% and a mAP@0.50:0.95 of 86.73%. The total count was correct in 96.43% of the images, while counts for all categories simultaneously matched the reference in 95.63%. The mean absolute error of the total count was 0.0536 objects per image. Exact total-count accuracy decreased from 99.29% for single-object images to 78.43% for scenes containing four or more objects. The mean processing time per complete call was 29.24 ms on the equipment used. These findings indicate initial technical feasibility under the evaluated conditions, with limitations related to test-set composition, category coverage, and difficulties in scenes containing multiple instruments. The approach shows potential to support instrument checking but requires further evaluation before use in hospital workflows.

Reference standard: ABNT NBR 6028 – Summary, review and review (2021).

Keywords: computer vision; surgical instruments; object detection; automatic counting; YOLO.

Lista de Figuras

1 Exemplo de instrumento identificado por uma caixa delimitadora . 16
2 Relações entre conceitos de aprendizado utilizados nesta pesquisa 21
3 Exemplo didático de suavização e realce de bordas 23
4 Cálculo ilustrativo da interseção sobre união entre duas caixas . . 30
5 Contagem total correta apesar de uma omissão e uma detecção indevida 33
6 Evolução das métricas de validação e da perda de localização durante o treinamento 48
7 Erro de contagem por categoria em função do limiar de confiança na validação 49
8 Acerto da contagem total conforme a quantidade de objetos de referência na cena 52
9 Exemplos de sobrecontagem em afastadores e de confusão entre cabo de bisturi e lâminas 54

Lista de Tabelas

1 Composição da base consolidada por origem 37
2 Quantidade de objetos anotados por categoria na base consolidada 39
3 Distribuição das imagens e dos objetos por divisão 40
4 Parâmetros definidos para o treinamento principal 42
5 Detecção por categoria no ponto de operação adotado para a contagem 50
6 Resultados de contagem por origem das imagens de teste 51

Lista de abreviaturas e siglas

AP	Average Precision — precisão média
CME	Centro de Material e Esterilização
CNN	Convolutional Neural Network — rede neural convolucional
CPU	Central Processing Unit — unidade central de processamento
CVAT	Computer Vision Annotation Tool
DL	Deep Learning — aprendizado profundo
FN	Falso negativo
FP	Falso positivo
GPU	Graphics Processing Unit — unidade de processamento gráfico
HEIC	High Efficiency Image Container
HSV	Hue, Saturation and Value — matiz, saturação e valor
HU-UEL	Hospital Universitário da Universidade Estadual de Londrina
IA	Inteligência artificial
IoU	Intersection over Union — interseção sobre união
JPEG	Joint Photographic Experts Group
JSONL	JSON Lines — formato de registros JSON separados por linha
MAE	Mean Absolute Error — erro absoluto médio
mAP	Mean Average Precision — média das precisões médias
ML	Machine Learning — aprendizado de máquina
MPS	Metal Performance Shaders
NMS	Non-Maximum Suppression — supressão de não máximos
OMS	Organização Mundial da Saúde
R-CNN	Region-based Convolutional Neural Network — rede neural convolucional baseada e
SHA-256	Secure Hash Algorithm de 256 bits
VP	Verdadeiro positivo
YOLO	You Only Look Once

Lista de símbolos

B_p	Caixa delimitadora prevista pelo modelo
B_r	Caixa delimitadora de referência
$\cap$	Interseção entre conjuntos ou regiões
$\cup$	União entre conjuntos ou regiões
$\lvert \cdot \rvert$	Área de uma região ou valor absoluto, conforme o contexto
P	Precisão das detecções
R	Revocação das detecções
N	Número de imagens avaliadas
C	Número de classes ou categorias
i	Índice de uma imagem
c	Índice de uma classe ou categoria
D_i	Conjunto de detecções aceitas na imagem i
d	Uma detecção pertencente ao conjunto D_i
$\sum$	Somatório
$\mathbf{1}[\cdot]$	Função indicadora: vale um quando a condição é verdadeira e zero caso contrário
n_i	Quantidade total de objetos de referência na imagem i
$\widehat{n}_i$	Quantidade total de objetos prevista na imagem i
n_{ic}	Quantidade de objetos de referência da categoria c na imagem i
$\widehat{n}_{ic}$	Quantidade prevista de objetos da categoria c na imagem i
$\mathrm{MAE}_{\mathrm{total}}$	Erro absoluto médio da contagem total por imagem
MAE_c	Erro absoluto médio da contagem da categoria c
E_{total}	Proporção de imagens com contagem total correta
E_{classes}	Proporção de imagens com contagem correta em todas as categorias simultaneament

Sumário

1 INTRODUÇÃO **14**
1.1 Problema de pesquisa e justificativa 17
1.2 Objetivos 18
1.3 Delimitação do estudo 18

2 FUNDAMENTAÇÃO TEÓRICA **20**
2.1 Inteligência artificial, aprendizado e visão computacional 20
2.2 Da imagem digital às características aprendidas 21
2.3 Classificação, detecção e modelos da família YOLO 23
2.4 Treinamento, preparação dos dados e generalização 25
2.5 Pesquisas relacionadas à conferência de instrumentos 28
2.6 Como avaliar a detecção dos objetos 29
2.7 Da detecção à avaliação da contagem 31
2.8 Interpretação da viabilidade técnica 34

3 METODOLOGIA **35**
3.1 Constituição e procedência da base de imagens 35
3.2 Seleção, anotação e padronização dos instrumentos 36
3.3 Consolidação, verificação e separação dos dados 39
3.4 Ambiente computacional e configuração do treinamento 41
3.5 Aumento de dados durante o treinamento 43
3.6 Protocolo de avaliação da detecção e da contagem 44

4 RESULTADOS E DISCUSSÃO **47**
4.1 Evolução do treinamento 47
4.2 Escolha do limiar de confiança para a contagem 48
4.3 Desempenho na detecção dos instrumentos 49
4.4 Contagem total e contagem por categoria 50
4.5 Origem das imagens e quantidade de objetos na cena 51
4.6 Análise visual dos acertos e das falhas 53
4.7 Tempo de processamento e alcance dos resultados 55

5 CONCLUSÃO **57**

REFERÊNCIAS **59**

1 INTRODUÇÃO

Antes que uma cirurgia seja realizada, os instrumentos necessários precisam estar disponíveis, organizados e conferidos. Após o uso, esses materiais retornam a um fluxo de recebimento, limpeza, preparo e esterilização que permite sua utilização em novos procedimentos. Nesse percurso, reconhecer cada peça e verificar as quantidades são tarefas que conectam o trabalho de diferentes profissionais. No Hospital Universitário da Universidade Estadual de Londrina (HU-UEL), o estudo de Moreto (2025) descreve conferências tanto na recepção do material utilizado quanto no preparo dos conjuntos que serão encaminhados à esterilização.

Esses conjuntos são frequentemente organizados em caixas cirúrgicas: recipientes que reúnem instrumentos selecionados para atender a determinado procedimento ou especialidade. Cada caixa possui uma composição de tipos e quantidades definida pelo serviço. Assim, uma caixa destinada a uma cirurgia cardíaca pode reunir instrumentos diferentes daqueles utilizados em neurocirurgia ou em uma apendicectomia, procedimento de retirada do apêndice. A caixa de apendicectomia adotada como referência nesta pesquisa delimita os objetos de interesse, entre eles pinças, tesouras e afastadores. Essa delimitação permite estudar um conjunto concreto de materiais, associado a uma necessidade hospitalar, em vez de tentar reconhecer indiscriminadamente todos os instrumentos existentes.

A conferência desses materiais tem importância tanto para a organização do serviço quanto para a segurança do cuidado. Durante a cirurgia, a contagem de instrumentos, compressas e agulhas integra as medidas recomendadas pela Organização Mundial da Saúde para prevenir que materiais permaneçam inadvertidamente no paciente (Organização Mundial da Saúde, 2009). No Brasil, a segurança cirúrgica também faz parte das ações do Programa Nacional de Segurança do Paciente (Brasil, 2014). A conferência realizada no processamento dos instrumentos e a contagem durante a operação, contudo, correspondem a momentos diferentes. O presente estudo se concentra no primeiro contexto: o apoio à identificação e à contagem de instrumentos fora do paciente, a partir de fotografias.

A importância dessa conferência também é evidenciada pelos casos de retenção não intencional de materiais. Em um estudo realizado em hospitais de Massachusetts, nos Estados Unidos, Gawande *et al.* (2003) identificaram uma ocorrência de retenção a cada 8.801 a 18.760 operações hospitalares no período de 1990 a 2000. Entre os casos de retenção em que a contagem havia sido realizada, 88% apresentavam registro de contagem correta. Esses dados históricos

abrangem compressas e instrumentos e não representam uma estimativa para o HU-UEL. Eles mostram, contudo, que a concordância numérica, isoladamente, não garante a ausência de materiais retidos. Por isso, a contagem automática é investigada como recurso de apoio à conferência, sem substituir os demais procedimentos de segurança.

Esse contexto envolve o Centro de Material e Esterilização (CME), setor responsável pelo processamento dos materiais utilizados na assistência. No fluxo descrito por Moreto (2025), o expurgo recebe os instrumentos utilizados, que passam pela conferência e pela limpeza; na área de preparo, outra conferência acompanha a organização e o fechamento das caixas. O registro individual das peças nesses pontos evidencia uma tarefa repetitiva que motiva a investigação de recursos de apoio. Nesta pesquisa, a aplicação é pretendida em ambos os ambientes, e as fotografias hospitalares foram obtidas tanto no expurgo quanto na área de preparo. A questão é saber se um computador pode extrair de uma imagem informações suficientemente confiáveis sobre quais instrumentos estão presentes e em que quantidade.

A área da computação que estuda a obtenção de informações a partir de imagens é chamada de visão computacional. Suas aplicações incluem o reconhecimento de objetos e a análise de imagens médicas, entre outras tarefas em que informações visuais precisam ser interpretadas. Uma das abordagens utilizadas é o aprendizado de máquina: em vez de escrever uma regra para cada possível aparência de um objeto, são apresentados exemplos a um modelo computacional, que ajusta seu funcionamento para reconhecer padrões. As redes neurais são modelos formados por operações interligadas, com valores ajustáveis durante esse aprendizado. Quando utilizam múltiplas camadas de processamento para aprender representações dos dados, integram o campo do aprendizado profundo (Goodfellow; Bengio; Courville, 2016).

Para a conferência de instrumentos, não basta reconhecer que uma fotografia contém uma pinça. É necessário localizar cada objeto individual, inclusive quando vários aparecem juntos. Essa tarefa é chamada de detecção de objetos. Uma forma usual de apresentar seu resultado é desenhar um retângulo ao redor de cada objeto e associá-lo a uma classe, isto é, à categoria que o identifica. O retângulo recebe o nome de caixa delimitadora. Quando cada instrumento é localizado uma única vez e recebe a identificação correta, essas detecções podem ser somadas para obter a quantidade total e a quantidade por categoria.

A Figura 1 exemplifica essa representação em uma fotografia do conjunto hospitalar. A marcação foi realizada para indicar o objeto de interesse e sua categoria.

Para aprender a realizar essa tarefa, o modelo recebe imagens acompa-

Figura 1: Exemplo de instrumento identificado por uma caixa delimitadora



Fonte: elaboração própria, a partir de fotografia do conjunto HU-UEL (2026).

nhadas de marcações que indicam a posição e a classe dos objetos. Essas marcações são as anotações de referência: exemplos revisados que orientam o aprendizado e permitem, posteriormente, comparar a resposta do modelo com os objetos efetivamente presentes na imagem. A qualidade desse material importa porque uma caixa mal posicionada, uma classe incorreta ou um instrumento não marcado pode comprometer o aprendizado e a avaliação. Por isso, preparar uma base de imagens envolve selecionar os exemplos, conferir as marcações e organizar nomes e categorias antes do treinamento.

Entre os modelos desenvolvidos para detectar objetos estão o Faster R-CNN e os modelos da família *You Only Look Once* (YOLO). No Faster R-CNN, o processamento inclui a proposta de regiões que podem conter objetos e a análise dessas regiões para classificá-los e ajustar sua localização (Ren *et al.*, 2015). A proposta original do YOLO reúne a estimativa das posições e das classes em um processamento da imagem completa, com ênfase na rapidez da detecção (Redmon *et al.*, 2016). Essas abordagens oferecem caminhos distintos para o mesmo problema; a escolha entre elas depende da aplicação, dos dados e dos recursos disponíveis.

Neste estudo, foi selecionada a família YOLO por combinar a localização e a identificação dos objetos em uma solução que permite construir a contagem a partir das detecções. A escolha também encontra apoio em pesquisas sobre instrumentos cirúrgicos, como as de Ran *et al.* (2023) e Jiang *et al.* (2023), que investigaram adaptações de versões anteriores dessa família. Seus resultados motivam a investigação, mas não antecipam o desempenho nas fotografias utilizadas aqui. O modelo adotado é o YOLO26n, variante compacta da família YOLO26.

Essa família disponibiliza variantes de diferentes tamanhos, identificadas por n, s, m, l e x, com diferentes necessidades de processamento (Ultralytics, 2026d). A escolha da variante n considerou os recursos computacionais disponíveis e a possibilidade de avaliar uma solução de menor porte, mantendo a qualidade das detecções e das contagens como questões a serem examinadas experimentalmente.

Essa avaliação exige separar o aprendizado da verificação de seus resultados. As imagens de treinamento são utilizadas para ajustar o modelo; as de validação permitem acompanhar o aprendizado e orientar escolhas de configuração; e as de teste são reservadas para avaliar o desempenho após essas escolhas. Também é necessário preparar as imagens para a entrada da rede. Fotografias de dimensões diferentes são redimensionadas e, quando necessário, recebem preenchimento nas bordas para se adequar ao tamanho de processamento adotado. Esse procedimento facilita a execução computacional, mas pode reduzir detalhes relevantes para distinguir instrumentos semelhantes. As decisões de preparação e avaliação, portanto, fazem parte do problema investigado, e não apenas da execução do programa.

1.1 Problema de pesquisa e justificativa

A possibilidade de contar instrumentos por imagens é atraente, mas seu uso depende de reconhecer os objetos apesar das variações presentes nas fotografias. Instrumentos metálicos podem produzir reflexos; peças diferentes podem ter formatos semelhantes; e um objeto pode esconder parte de outro. Essas condições dificultam a localização e a identificação, como discutido nos estudos de Ran *et al.* (2023) e Jiang *et al.* (2023). Por isso, a existência de um detector capaz de reconhecer objetos em outras aplicações não é suficiente para concluir que ele atenderá à conferência pretendida no hospital.

A pergunta que orienta esta pesquisa é: em que medida um modelo da família YOLO é tecnicamente viável para identificar e contar instrumentos selecionados da caixa de apendicectomia, nas condições representadas pelas fotografias de avaliação, visando ao apoio à conferência no expurgo e no preparo de caixas cirúrgicas?

Neste contexto, avaliar a viabilidade significa examinar a qualidade das detecções, os erros de contagem, os recursos computacionais empregados e as situações em que o modelo apresenta dificuldades. Acertar somente o total de objetos não é suficiente. Em uma imagem com dois instrumentos, por exemplo, o modelo pode deixar de reconhecer um deles e marcar indevidamente outra região, produzindo duas detecções apesar do erro. Também pode localizar ambos e

trocar suas classes. A análise precisa, portanto, considerar tanto o total quanto a identificação e a localização dos objetos que deram origem à contagem. Os indicadores e os procedimentos utilizados para essa análise são apresentados na metodologia.

A contribuição pretendida é oferecer evidências sobre as possibilidades e os limites dessa abordagem em um conjunto relacionado à rotina do HU-UEL. Para isso, foram reunidas imagens de bases disponíveis na internet e fotografias hospitalares, com revisão dos objetos e de suas anotações. A combinação dessas fontes fornece exemplos para o treinamento, enquanto a avaliação deve mostrar até que ponto o modelo consegue lidar com imagens que não foram utilizadas para ajustá-lo. O estudo trata a contagem automática como um possível recurso de apoio à conferência profissional, sem pressupor que o desempenho em fotografias demonstre, por si só, redução de acidentes ou prontidão para uso assistencial.

1.2 Objetivos

O objetivo geral é avaliar a viabilidade técnica da detecção e da contagem automática de instrumentos selecionados da caixa de apendicectomia, agrupados em sete categorias gerais, por meio do modelo YOLO26n, visando ao apoio à conferência no expurgo e no preparo de caixas cirúrgicas.

Para alcançar esse objetivo, foram definidos os seguintes objetivos específicos:

a) organizar e revisar as imagens da internet e do HU-UEL, padronizando as categorias e as anotações dos objetos;
b) preparar os conjuntos de treinamento, validação e teste, com controle de duplicatas e agrupamento das imagens relacionadas identificadas;
c) treinar um modelo YOLO para localizar e identificar os instrumentos nas categorias gerais adotadas;
d) avaliar a detecção e a contagem, considerando os resultados totais, os resultados por categoria e a frequência de imagens com contagem correta;
e) analisar os erros e os recursos computacionais empregados, identificando condições favoráveis e limitações para a aplicação pretendida.

1.3 Delimitação do estudo

O experimento utiliza fotografias estáticas e sete categorias gerais: pinças, tesouras, afastadores, porta-agulhas, cabos de bisturi, bicos de aspiração e cúpulas. As cúpulas são recipientes que também integram a contagem dos objetos

de interesse. O foco é localizar os objetos e estimar suas quantidades, sem distinguir todos os tipos de instrumentos pertencentes a uma mesma categoria. A correspondência entre os instrumentos selecionados e as categorias utilizadas no treinamento é apresentada na metodologia. Diferenças de tamanho não originam classes distintas.

O agrupamento reúne exemplos de diferentes instrumentos sob um número menor de rótulos e delimita uma tarefa compatível com o objetivo de avaliar a contagem. Essa organização foi considerada pertinente diante da distribuição desigual dos exemplos disponíveis. Entretanto, a pesquisa não compara categorias gerais e específicas e, portanto, não permite afirmar que o agrupamento produziu desempenho superior. Também permanece necessária a análise por categoria, pois reunir instrumentos diferentes não elimina a diversidade visual nem o desequilíbrio da base.

A seleção foi limitada aos objetos de interesse para os quais se obtiveram imagens adequadas. As pinças anatômicas e os cabos de bisturi estão representados somente por imagens da internet na base consolidada. Essas diferenças de cobertura devem ser consideradas ao interpretar os resultados, especialmente quando se discute a aplicação no ambiente hospitalar.

As fotografias incluem instrumentos isolados, alguns conjuntos com vários objetos e bandejas vazias. Embora tenham sido obtidas imagens nos dois ambientes de aplicação pretendidos, o estudo não equivale a uma implantação do sistema no fluxo de trabalho. A avaliação se refere aos objetos visíveis nas fotografias e às condições representadas no conjunto de teste. A conferência integral de uma caixa, o reconhecimento de materiais totalmente encobertos e a demonstração de benefícios durante o uso hospitalar exigem avaliações próprias. Dessa forma, a pesquisa busca estabelecer uma base experimental para decidir como a contagem por visão computacional pode avançar em direção à aplicação pretendida.

2 FUNDAMENTAÇÃO TEÓRICA

Reconhecer uma tesoura em uma fotografia parece uma tarefa simples para quem conhece o instrumento. Para um computador, entretanto, a imagem é inicialmente um conjunto de números. Transformar esses números em informações como a posição, o tipo e a quantidade de objetos exige um método de análise. Este capítulo apresenta esse percurso: começa pelas relações entre inteligência artificial e aprendizado, explica como imagens podem ser processadas por redes neurais e chega aos critérios utilizados para avaliar a detecção e a contagem.

2.1 Inteligência artificial, aprendizado e visão computacional

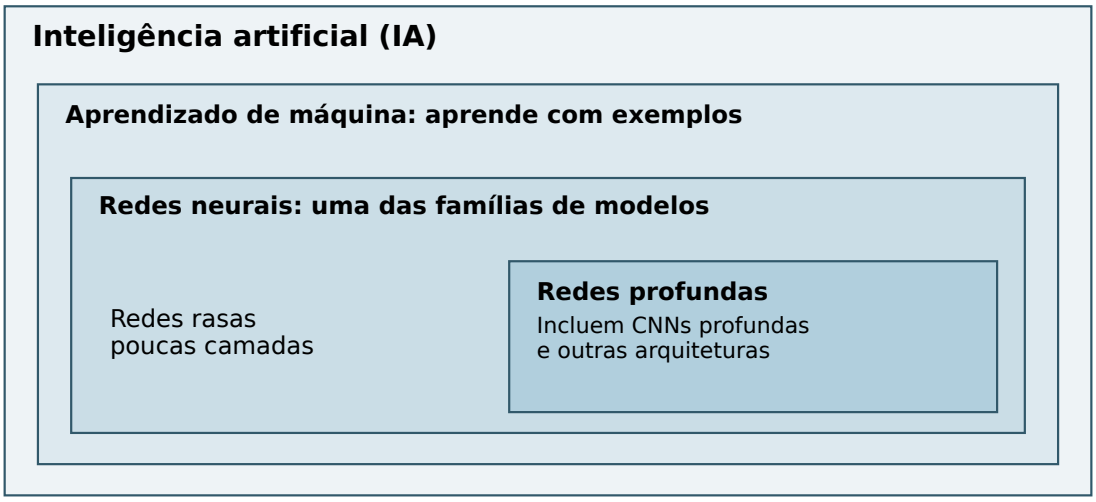
A inteligência artificial (IA) reúne métodos destinados a realizar tarefas que envolvem capacidades como reconhecer padrões e tomar decisões. Uma de suas abordagens é o aprendizado de máquina, também chamado de *machine learning* (ML): o sistema ajusta um modelo a partir de dados, em vez de depender somente de regras definidas manualmente. Uma rede neural artificial é uma família de modelos que combina operações numéricas interligadas. Seus parâmetros, entre eles os pesos das conexões, determinam como as informações são transformadas e podem ser ajustados durante o aprendizado (Goodfellow; Bengio; Courville, 2016).

Aprendizado profundo, ou *deep learning* (DL), refere-se ao aprendizado de representações por múltiplas camadas de processamento. A saída de uma camada fornece informações para as seguintes, permitindo combinar padrões mais simples em representações mais complexas (LeCun; Bengio; Hinton, 2015). Não se trata de considerar que a máquina compreende uma fotografia da mesma maneira que uma pessoa: ela realiza operações aprendidas com os exemplos e pode falhar diante de condições diferentes daquelas representadas nos dados.

Esses conceitos se relacionam, mas não são sinônimos. O aprendizado de máquina integra o campo da IA; redes neurais são uma das famílias de modelos de aprendizado; e existem redes rasas e profundas. Portanto, nem toda rede neural pertence ao aprendizado profundo. A Figura 2 apresenta um recorte dessas relações. As redes neurais convolucionais, discutidas adiante, podem ser organizadas em arquiteturas profundas para analisar imagens.

A visão computacional é a área voltada à obtenção de informações a partir de imagens e vídeos. Ela define o tipo de problema a resolver, como localizar um objeto, enquanto o aprendizado profundo oferece uma das maneiras de enfrentá-lo. Também há métodos de visão computacional que utilizam operações de pro-

Figura 2: Relações entre conceitos de aprendizado utilizados nesta pesquisa



Fonte: elaboração própria, com base em Goodfellow, Bengio e Courville (2016) e LeCun, Bengio e Hinton (2015).

cessamento de imagens sem uma rede treinada. Essa distinção ajuda a compreender a proposta desta pesquisa: o problema é detectar e contar instrumentos; a abordagem selecionada utiliza uma rede neural treinada para reconhecer seus padrões visuais.

Nesse contexto, uma característica visual pode ser a presença de uma borda, uma textura ou uma combinação de formas. Em instrumentos cirúrgicos, anéis, hastes, curvaturas e extremidades fornecem pistas relevantes. Ao aprender com imagens, porém, o modelo também pode utilizar informações pouco desejáveis, como um fundo associado repetidamente a uma classe. Por isso, ensinar a reconhecer um instrumento exige mais que reunir muitas fotografias: é necessário considerar quais diferenças e semelhanças estão presentes nos exemplos.

2.2 Da imagem digital às características aprendidas

Uma imagem digital pode ser representada por uma grade de elementos chamados pixels. Cada pixel armazena valores relacionados à aparência de uma pequena região da imagem. Em uma representação RGB, há canais correspondentes ao vermelho, ao verde e ao azul; em uma representação em tons de cinza, utiliza-se um valor de intensidade. A resolução indica quantos pixels compõem a

largura e a altura. Uma imagem de 640×640 pixels, por exemplo, possui 409.600 posições nessa grade, antes de considerar seus canais de cor.

Essa representação explica por que a resolução influencia o processamento. Mais pixels podem preservar detalhes, mas também aumentam a quantidade de informação que precisa ser tratada. Os modelos recebem imagens preparadas para um tamanho de entrada definido na configuração. O redimensionamento modifica as dimensões, enquanto o preenchimento com bordas permite ajustar o formato sem necessariamente deformar a proporção do objeto. As caixas de referência precisam acompanhar essas transformações para continuarem posicionadas corretamente.

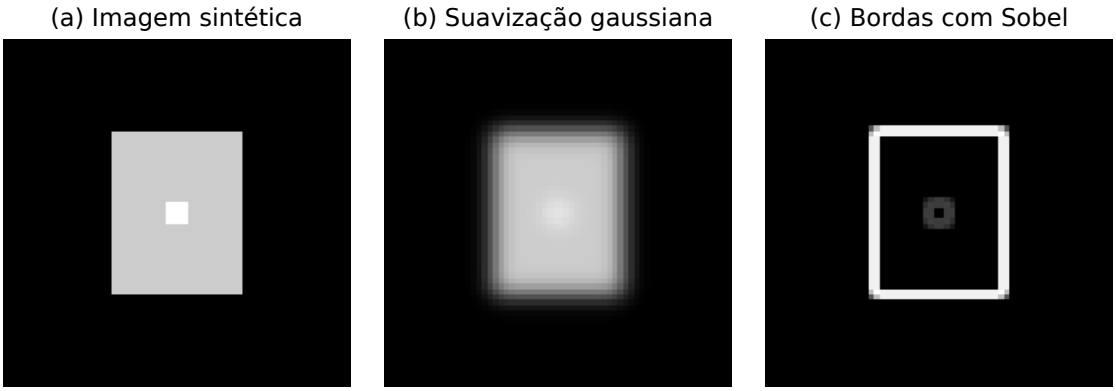
Considere uma fotografia de 2.048×1.536 pixels ajustada proporcionalmente para caber em 640×640. A largura passa a 640 e a altura a 480; o espaço restante pode ser preenchido com bordas. Um detalhe que ocupava dez pixels de largura passa a ocupar aproximadamente três. Esse exemplo mostra por que uma fotografia nítida no arquivo original pode perder informação útil quando apresentada à rede. Aumentar novamente a imagem não recupera automaticamente o detalhe perdido. O tamanho de entrada, portanto, envolve uma escolha entre preservação de informação e custo de processamento.

Uma forma de analisar a grade de pixels é aplicar filtros. Um filtro combina valores de uma pequena vizinhança para produzir uma nova resposta em cada posição. Na suavização por média, por exemplo, uma janela de 3×3 pixels substitui a intensidade central pela média dos nove valores. Isso reduz diferenças locais, mas também pode tornar menos nítidas as bordas. A suavização gaussiana utiliza uma combinação ponderada dos valores próximos, em vez de atribuir a todos a mesma contribuição (OpenCV, 2026b).

Outros filtros realçam mudanças de intensidade. O operador Sobel calcula respostas a variações em direções da imagem, que podem destacar bordas (OpenCV, 2026a). Na Figura 3, a imagem sintética contém uma região clara sobre fundo escuro. A suavização torna sua transição mais gradual; a resposta de bordas destaca as regiões de mudança. Esses filtros fixos são apresentados para explicar a ideia de processamento local, não como etapas adicionais aplicadas às fotografias do experimento.

Nas redes neurais convolucionais, conhecidas pela sigla CNN, do inglês *convolutional neural network*, os filtros têm valores aprendidos durante o treinamento. A aplicação de um filtro em diferentes posições gera um mapa de características: uma nova grade que indica onde o padrão associado ao filtro produz respostas. Diversos filtros geram diferentes mapas, e camadas posteriores combinam essas informações. O compartilhamento dos valores do filtro entre posições

Figura 3: Exemplo didático de suavização e realce de bordas



Fonte: elaboração própria, em imagem sintética, com operações descritas na documentação do OpenCV (OpenCV, 2026b,a).

evita aprender uma operação inteiramente diferente para cada ponto da imagem (Goodfellow; Bengio; Courville, 2016).

As camadas convolucionais são combinadas com outras operações, incluindo funções de ativação, que permitem representar relações não lineares. Em termos intuitivos, a rede não fica limitada a somar sempre as informações da mesma maneira: consegue construir respostas mais complexas a partir dos padrões intermediários. O aprendizado em várias camadas é um dos fundamentos do avanço das redes profundas na análise visual (LeCun; Bengio; Hinton, 2015). Ainda assim, os mapas internos não devem ser interpretados como uma lista garantida de conceitos humanos, como ``dente'', ``anel'' ou ``ponta curva''. Essas são características úteis para explicar o problema, mas não uma descrição previamente conhecida do que cada filtro aprendeu.

2.3 Classificação, detecção e modelos da família YOLO

O tipo de resposta esperado define a tarefa de análise. Na classificação de imagens, o sistema atribui uma categoria, ou um conjunto de categorias, à imagem. Na detecção, localiza cada objeto e informa sua classe. Na segmentação de instâncias, identifica os pixels correspondentes a cada objeto individual. O termo instância significa, nesse caso, um exemplar: duas pinças da mesma classe são duas instâncias. Assim, saber que há pinças em uma fotografia não determina quantas existem nem onde estão; a detecção acrescenta as informações necessárias para a contagem por objeto (Padilla *et al.*, 2021).

Uma caixa delimitadora alinhada aos eixos é um retângulo definido por sua posição, largura e altura. Ela envolve o objeto, mas não acompanha seu contorno. Por isso, uma pinça inclinada pode ter bastante fundo dentro da caixa sem que a

anotação esteja necessariamente incorreta. Já um polígono utilizado na segmentação acompanha o contorno por vários pontos. Sua conversão em caixa utiliza os limites mínimo e máximo nas direções horizontal e vertical, preservando a região envolvente e descartando o detalhamento do contorno.

Quando um instrumento encobre parte de outro, ocorre oclusão. A sobreposição das caixas, entretanto, não comprova que os instrumentos estejam fisicamente sobrepostos: os retângulos podem se cruzar apenas por incluírem áreas de fundo. Da mesma forma, instrumentos empilhados são um caso particular de disposição em que peças ficam sobre outras. Essas distinções são relevantes tanto para anotar quanto para analisar falhas. É preciso reconhecer cada objeto individual visível sem criar uma anotação adicional para cada uma de suas partes.

Para produzir caixas e classes, diferentes detectores organizam o processamento de maneiras distintas. O Faster R-CNN utiliza uma rede de proposta de regiões para indicar áreas potencialmente ocupadas por objetos, que são analisadas para classificação e refinamento das caixas (Ren *et al.*, 2015). A proposta original do YOLO, de Redmon *et al.* (2016), formula a localização e a classificação conjuntamente a partir da imagem completa. O nome *You Only Look Once* expressa essa ideia de uma passagem pela rede para gerar as previsões, em vez de avaliar separadamente uma grande coleção de recortes.

A família YOLO evoluiu desde essa proposta. Em termos gerais, um detector moderno extrai características da imagem, combina informações em diferentes níveis e gera as saídas de localização e classe. A parte responsável por produzir essas saídas é frequentemente chamada de cabeça de detecção. O uso do mesmo nome de família não significa que todas as versões tenham arquitetura ou procedimentos idênticos; a descrição do modelo precisa corresponder à versão efetivamente empregada.

O YOLO26 disponibiliza variantes n, s, m, l e x, associadas a diferentes escalas de tamanho. A variante n é a mais compacta; variantes maiores ampliam a capacidade do modelo e normalmente exigem mais memória e processamento (Ultralytics, 2026d). Capacidade, nesse contexto, está relacionada à quantidade e à organização dos parâmetros que podem ser ajustados. Uma rede maior não corrige automaticamente imagens mal anotadas ou a ausência de exemplos relevantes. A escolha deve considerar o equipamento disponível e o desempenho observado, sem tratar tamanho como garantia de qualidade.

A descrição técnica do YOLO26 também apresenta um caminho de inferência sem uma etapa separada de supressão de não máximos, ou NMS, do inglês *non-maximum suppression* (Jocher *et al.*, 2026). Inferência é o uso do modelo já treinado para analisar uma imagem. Em detectores que utilizam NMS,

essa etapa procura reduzir previsões redundantes sobre um mesmo objeto, considerando suas pontuações e sobreposição. Como o comportamento depende da configuração e da implementação, a avaliação deve registrar o caminho realmente utilizado. Para a contagem, a questão prática é evitar que um único instrumento resulte em várias detecções aceitas.

Além da caixa e da classe, as previsões recebem uma pontuação de confiança, utilizada para selecionar as respostas que serão consideradas. Uma pontuação elevada indica maior confiança segundo o modelo, mas não deve ser tomada automaticamente como probabilidade real de acerto. O limiar de confiança é o valor mínimo exigido para aceitar uma detecção. Escolher esse limiar modifica quais objetos entram na contagem, razão pela qual sua definição precisa ocorrer na validação, antes da avaliação final.

2.4 Treinamento, preparação dos dados e generalização

Na aprendizagem supervisionada, cada exemplo utilizado para ensinar o modelo está associado a uma resposta de referência. Para detectar instrumentos, essa resposta contém as caixas e suas classes. Durante o treinamento, a rede produz previsões, compara-as com as referências e ajusta seus parâmetros. O objetivo é aprender relações que também funcionem em novos exemplos. Essa capacidade de responder adequadamente a dados não utilizados no ajuste é chamada de generalização (Goodfellow; Bengio; Courville, 2016).

A diferença entre previsão e referência é expressa por uma função de perda. Em um detector, podem existir componentes relacionados à localização das caixas e à classificação. A retropropagação calcula como os parâmetros influenciam essa perda; o otimizador utiliza essas informações para atualizá-los. A taxa de aprendizado controla a escala dos ajustes. Atualizações muito grandes podem prejudicar a estabilidade, enquanto atualizações muito pequenas podem tornar o processo lento. Esses elementos fazem parte do procedimento de otimização descrito por Goodfellow, Bengio e Courville (2016).

Os pesos são parâmetros aprendidos; já as configurações escolhidas para conduzir o processo, como taxa de aprendizado, tamanho do lote e limite de épocas, são chamadas de hiperparâmetros. Um lote é um grupo de exemplos processados em uma etapa do treinamento. Uma época corresponde a uma passagem pelo conjunto de treinamento, conforme o procedimento de amostragem utilizado. Por exemplo, uma base com mil imagens, processada em lotes de dez sem descarte de exemplos, resulta em cem lotes por época. Esse cálculo ajuda a relacionar a configuração ao tempo de execução, mas não determina a qualidade do resultado.

Entre os otimizadores está o AdamW, que combina atualização adaptativa dos parâmetros com um procedimento de decaimento de pesos separado dessa atualização (Loshchilov; Hutter, 2019). O decaimento reduz os pesos de forma controlada e participa das estratégias de regularização, utilizadas para limitar ajustes excessivos aos exemplos de treinamento. A escolha de um otimizador é apenas uma parte do experimento: seus valores de configuração e sua interação com os dados também precisam ser considerados.

O treinamento pode começar com pesos pré-treinados, isto é, valores obtidos anteriormente em outra base. Essa estratégia permite aproveitar representações já aprendidas e adaptá-las à nova tarefa, procedimento conhecido como transferência de aprendizagem. O ajuste posterior pode atualizar a rede ou manter parte de seus parâmetros fixos, conforme a configuração (PyTorch, 2026b). Para instrumentos cirúrgicos, reconhecer objetos em uma base genérica constitui um ponto de partida, não uma evidência de que o modelo já distingue as classes selecionadas.

Para verificar o aprendizado, os dados são separados em treinamento, validação e teste. O treinamento ajusta os parâmetros; a validação acompanha o desempenho e orienta escolhas, como a seleção de uma época ou do limiar de confiança; o teste é reservado à avaliação após essas escolhas. Usar o teste repetidamente para selecionar configurações compromete sua independência, pois suas respostas passam a orientar o desenvolvimento (Kapoor; Narayanan, 2023). A validação executada ao fim de uma época, portanto, não deve ser confundida com a avaliação final no conjunto de teste.

Quando o modelo melhora nos dados de treinamento, mas não mantém essa melhora em dados novos, pode estar ocorrendo sobreajuste. A análise das curvas de perda e de validação ajuda a acompanhar esse comportamento, sem que uma oscilação isolada seja suficiente para diagnosticá-lo. A parada antecipada interrompe o treinamento quando o indicador monitorado deixa de melhorar por determinado período, chamado de paciência. Trata-se de uma forma de controle do aprendizado, discutida entre as estratégias de regularização por Goodfellow, Bengio e Courville (2016). O melhor estado salvo durante a execução pode ser diferente daquele produzido na última época.

A independência dos conjuntos também depende de como as fotografias foram obtidas. Uma cópia com outro nome continua representando a mesma cena; um recorte ou uma inversão pode preservar grande parte de seu conteúdo; e fotografias consecutivas podem diferir pouco entre si. Se exemplos fortemente relacionados aparecem no treinamento e no teste, o desempenho pode refletir a familiaridade com aquela captura. Agrupar imagens relacionadas antes da separação reduz esse risco, mas a quantidade de arquivos não deve ser interpretada

automaticamente como quantidade de observações independentes (Kapoor; Narayanan, 2023).

Essa preocupação é especialmente relevante para as imagens hospitalares: variar a posição do instrumento pode acrescentar informação, mas fotografá-lo repetidamente com o mesmo fundo e iluminação não reproduz toda a diversidade de uso. Um identificador calculado a partir dos bytes permite localizar cópias exatas de arquivos. Métodos de similaridade visual podem indicar outras repetições, porém precisam de revisão, pois objetos diferentes também podem se parecer. A limpeza da base deve combinar verificação automática e análise dos casos ambíguos, preservando a correspondência entre cada imagem e suas anotações.

O aumento de dados, ou *data augmentation*, introduz variações nos exemplos de treinamento. Rotações e inversões alteram a orientação; mudanças de escala e deslocamento modificam o enquadramento; ajustes de cor e brilho variam a aparência. O mosaico combina imagens em uma composição, criando novas disposições dos objetos. As anotações precisam ser transformadas junto com as imagens, e a intensidade dessas operações deve preservar exemplos coerentes com a tarefa (Ultralytics, 2026a).

Quando esse aumento ocorre durante o carregamento dos lotes, a base no disco mantém sua quantidade de arquivos. A cada apresentação, uma imagem pode receber uma transformação diferente ou nenhuma transformação, de acordo com as probabilidades configuradas. Assim, afirmar que mil imagens se tornaram dez mil exige especificar o que foi contado: arquivos salvos, apresentações ao modelo ou combinações produzidas. Variações artificiais também não substituem novas fotografias obtidas em condições diferentes. Na avaliação usual, validação e teste recebem a preparação necessária à entrada do modelo, sem as transformações aleatórias utilizadas para diversificar o treinamento.

Outro cuidado é o equilíbrio entre classes e origens. Uma classe pode possuir muitos objetos anotados, mas pouca variedade de cenas; outra pode reunir menos exemplos, porém capturados em condições diversas. Imagens e objetos são unidades diferentes: uma foto com quatro pinças representa uma imagem e quatro anotações. Além disso, exemplos da internet e do hospital podem diferir em fundo, iluminação e enquadramento. Por esse motivo, a distribuição por classe e por origem ajuda a interpretar o que o modelo teve oportunidade de aprender e quais condições estão pouco representadas.

Por fim, a repetição de um experimento depende do registro de suas configurações. A semente inicializa geradores de números pseudoaleatórios, utilizados em operações como a ordem dos exemplos e as transformações. Fixá-la auxilia a repetibilidade, mas não garante resultados idênticos em qualquer dispo-

sitivo ou versão de software. A documentação do PyTorch ressalta que a disponibilidade de operações determinísticas e as diferenças de plataforma também influenciam esse comportamento (PyTorch, 2026a). A metodologia precisa, portanto, registrar tanto a configuração quanto as limitações efetivamente observadas.

2.5 Pesquisas relacionadas à conferência de instrumentos

A avaliação computacional precisa ser relacionada ao problema que motiva a pesquisa. No contexto brasileiro, Freitas, Mendes e Galvão (2016) analisaram a contagem cirúrgica a partir dos relatos de 55 enfermeiros. O estudo examinou como, quando e por quem a contagem era realizada e contribui para compreender a organização desse processo. Seu foco é a prática de conferência, não a avaliação de um detector. Essa distinção é útil porque melhorar o reconhecimento em imagens e melhorar um processo assistencial são objetivos relacionados, mas exigem evidências diferentes.

No contexto do HU-UEL, Moreto (2025) investigou o desenvolvimento de um protótipo para contagem e rastreabilidade de instrumentos, considerando o fluxo do CME. Contagem informa quantos objetos estão presentes; rastreabilidade envolve acompanhar sua identificação e seu percurso no processo. O estudo fornece uma referência local para compreender as conferências no expurgo e no preparo das caixas. A presente pesquisa concentra sua avaliação na detecção e na contagem por fotografias, sem equiparar o reconhecimento de uma categoria à identificação individual de cada peça ao longo de seu histórico de uso.

Na investigação de detectores, Ran *et al.* (2023) propuseram modificações no YOLOv7x e apresentaram a base OSI26. O trabalho considera dificuldades de reconhecimento relacionadas à semelhança entre instrumentos e às condições visuais. Sua contribuição para esta pesquisa é mostrar que a detecção de instrumentos envolve desafios próprios e pode exigir atenção à representação dos objetos, além da escolha de uma arquitetura genérica.

Jiang *et al.* (2023) estudaram uma adaptação do YOLOv5 em imagens de instrumentos, incluindo disposições com e sem empilhamento. A presença de peças sobrepostas aproxima a investigação de uma dificuldade importante para a contagem: localizar objetos distintos quando parte de sua aparência está escondida. Os dois estudos examinam alterações nos detectores, enquanto a presente pesquisa prioriza a preparação da base e a avaliação de uma implementação disponível no recorte de instrumentos selecionado.

Uma contribuição adicional é o estudo experimental de Deol *et al.* (2024), que utilizou YOLOv9 em uma base com 1.004 imagens, 13.213 objetos e 11 ca-

tegorias. Os autores incluíram cenas com vários instrumentos, um subconjunto com sobreposição e uma avaliação em vídeo simulado. Isso aproxima o problema de situações em que a contagem precisa considerar diversos objetos simultaneamente. Por outro lado, a necessidade de validação clínica posterior reconhecida pelos autores reforça a diferença entre demonstrar funcionamento experimental e comprovar adequação ao uso hospitalar.

Esses trabalhos orientam aspectos complementares: a rotina de conferência, o contexto local de aplicação, as dificuldades visuais e a avaliação de cenas com múltiplos objetos. Suas métricas não formam, contudo, uma classificação direta de qual modelo seria melhor para esta pesquisa. Bases, categorias, divisões e condições de captura distintas produzem problemas diferentes. A comparação útil está nos critérios empregados e nas limitações observadas; qualquer comparação numérica entre modelos exige condições de avaliação compatíveis.

2.6 Como avaliar a detecção dos objetos

Avaliar a detecção significa comparar as caixas e as classes previstas com as anotações de referência. Uma previsão precisa localizar o objeto com qualidade suficiente e atribuir-lhe a classe esperada. Para medir a proximidade entre duas caixas, utiliza-se a interseção sobre união, conhecida como IoU, do inglês *intersection over union*. Seu cálculo divide a área comum às caixas pela área total ocupada por ambas, contando a região comum apenas uma vez (Padilla *et al.*, 2021):

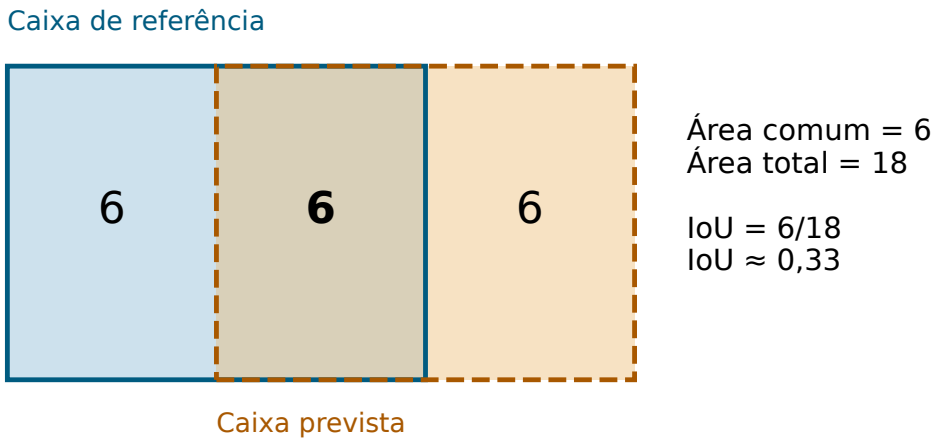
$$\text{IoU}(B_p, B_r) = \frac{|B_p \cap B_r|}{|B_p \cup B_r|}. \tag{1}$$

Na Equação 1, B_p é a caixa prevista e B_r a caixa de referência. O símbolo $\cap$ indica a interseção, ou parte comum; $\cup$ indica a união; e as barras representam área. O resultado varia de zero a um: zero corresponde à ausência de área comum e um à coincidência completa. Quanto maior a sobreposição relativa, maior a IoU. Na Figura 4, cada caixa tem área 12, a parte comum tem área 6 e a união tem área $12 + 12 - 6 = 18$. Assim, a IoU é $6/18$, aproximadamente $0{,}33$.

Um limiar de IoU define a sobreposição mínima exigida para aceitar uma correspondência. Se o limiar for $0{,}50$, as caixas do exemplo não satisfazem o critério. Esse valor não é o limiar de confiança: a confiança seleciona as previsões emitidas pelo modelo; a IoU avalia sua localização em relação à referência. A associação também considera a classe e deve evitar que várias previsões sejam contadas como acertos para um único objeto (Padilla *et al.*, 2021).

Uma detecção corretamente associada é um verdadeiro positivo (VP). Uma previsão sem correspondência válida é um falso positivo (FP), como uma

Figura 4: Cálculo ilustrativo da interseção sobre união entre duas caixas



Fonte: elaboração própria. Áreas expressas em unidades quadradas arbitrárias.

caixa sobre o fundo ou uma detecção duplicada. Um objeto anotado que não recebe correspondência é um falso negativo (FN). Quando a classe está errada, a avaliação por classe registra uma previsão indevida na classe atribuída e a ausência do objeto na classe de referência. Esses termos descrevem erros diferentes e ajudam a interpretar o resultado para além do número total de caixas.

A precisão responde: entre as detecções aceitas, quantas estão corretas? A revocação, também chamada de sensibilidade ou *recall*, responde: entre os objetos que deveriam ser encontrados, quantos foram detectados corretamente? Para denominadores diferentes de zero, calculam-se:

$$P = \frac{VP}{VP + FP}, \qquad R = \frac{VP}{VP + FN}. \tag{2}$$

Considere, como exemplo didático, dez instrumentos anotados e nove detecções, das quais oito corretas. Nesse caso, há $VP = 8$, $FP = 1$ e $FN = 2$. A precisão é $8/9 \approx 88{,}9\%$ e a revocação é $8/10 = 80\%$. A primeira informa a proporção de respostas corretas; a segunda mostra a parcela dos instrumentos encontrados. Se aumentam os falsos positivos mantendo os acertos, a precisão diminui. Se aumentam as omissões mantendo os acertos, a revocação diminui.

O limiar de confiança interfere nesse equilíbrio. Elevar o limiar elimina previsões de menor pontuação, podendo retirar tanto erros quanto acertos; reduzi-lo permite aceitar mais previsões, incluindo potenciais falsos positivos. Em geral, utiliza-se uma curva precisão--revocação para observar o comportamento em vários limiares. A precisão média, AP, resume essa curva de acordo com uma convenção de cálculo, e a média das AP entre as classes é denominada mAP

(Ultralytics, 2026c). Por reunir diferentes pontos de operação, a mAP não é a precisão obtida em um único limiar escolhido para contar objetos.

Na notação mAP@0,50, a localização é avaliada com IoU de $0{,}50$. Já mAP@0,50:0,95 combina avaliações em dez limiares, de $0{,}50$ a $0{,}95$, com intervalos de $0{,}05$. Os critérios mais altos exigem maior coincidência entre as caixas. Essas métricas descrevem a detecção; não representam a porcentagem de imagens com contagem exata (Ultralytics, 2026c). Também é necessário informar quais classes possuem exemplos na avaliação, pois uma classe ausente não fornece evidência de desempenho positivo naquele conjunto.

Os resultados por classe e a matriz de confusão complementam as médias. Essa matriz organiza as correspondências entre categorias de referência e previstas, permitindo identificar trocas recorrentes. Sua interpretação depende da orientação dos eixos e dos critérios de associação empregados. Para esta aplicação, uma média global satisfatória pode esconder dificuldades em categorias menos representadas, tornando necessária a análise conjunta das métricas e de exemplos visuais dos erros.

2.7 Da detecção à avaliação da contagem

Depois de selecionar as detecções, a contagem pode ser obtida somando os objetos atribuídos a cada classe. Para expressar essa operação, considere N imagens e C classes. O índice i identifica uma imagem e c uma classe. Seja D_i o conjunto de detecções aceitas na imagem i. A quantidade prevista para uma classe e o total previsto são:

$$\widehat{n}_{ic} = \sum_{d \in D_i} \mathbf{1}[\text{classe}(d) = c], \qquad \widehat{n}_i = \sum_{c=1}^{C} \widehat{n}_{ic}. \tag{3}$$

O símbolo $\sum$ indica uma soma. Na primeira expressão, percorrem-se as detecções d e acrescenta-se uma unidade quando sua classe é c; a função $\mathbf{1}[\cdot]$ vale um se a condição for verdadeira e zero se for falsa. Na segunda, somam-se as quantidades de todas as classes. O acento sobre $\widehat{n}$ indica que se trata de uma estimativa. Os índices de um a C são uma convenção matemática e não alteram a numeração dos arquivos de anotação. Se a saída contém duas pinças e uma tesoura, as contagens são dois e um, e o total é três.

Para avaliar o total, compara-se a estimativa $\widehat{n}_i$ com a quantidade de referência n_i. O erro absoluto médio, ou MAE, do inglês *mean absolute error*, é

definido por:

$$\mathrm{MAE}_{\mathrm{total}} = \frac{1}{N}\sum_{i=1}^{N} |\widehat{n}_i - n_i|. \tag{4}$$

Primeiro, calcula-se a diferença entre o total previsto e o total real em cada imagem. As barras indicam valor absoluto: um erro de menos dois ou de mais dois contribui com dois. Em seguida, somam-se os erros e divide-se pelo número de imagens. Um MAE menor indica maior proximidade entre os totais; zero significa que todos os totais coincidiram. A unidade é objetos por imagem, e não porcentagem.

Por exemplo, suponha três imagens com totais de referência $(2, 3, 0)$ e previsões $(2, 1, 1)$. Os erros absolutos são $(0, 2, 1)$, e o MAE é $(0 + 2 + 1)/3 = 1$. Isso não significa que houve exatamente um erro em cada fotografia: uma teve total correto, outra apresentou subcontagem de dois e a terceira, sobrecontagem de um. Registrar separadamente omissões e excessos torna a interpretação mais útil para uma tarefa de conferência.

O cálculo também pode ser realizado por classe:

$$\mathrm{MAE}_{c} = \frac{1}{N}\sum_{i=1}^{N} |\widehat{n}_{ic} - n_{ic}|. \tag{5}$$

Aqui, n_{ic} é a quantidade de referência da classe c na imagem i. Essa medida revela, por exemplo, que uma contagem total aparentemente adequada pode esconder trocas entre pinças e tesouras. A base utilizada no denominador deve ficar explícita: calcular a média sobre todas as imagens inclui aquelas em que a classe está ausente. Para uma classe rara, muitos zeros corretos podem reduzir a média mesmo com falhas nas poucas imagens positivas. Informar a quantidade de imagens e objetos avaliados e distinguir os casos de presença e ausência ajuda a evitar essa interpretação equivocada.

Outra pergunta importante é quantas fotografias tiveram a contagem exata. A proporção de imagens com total correto é:

$$E_{\mathrm{total}} = \frac{1}{N}\sum_{i=1}^{N} \mathbf{1}[\widehat{n}_i = n_i]. \tag{6}$$

Cada imagem contribui com um se o total previsto coincide com a referência, ou com zero se existe diferença. A soma é dividida por N; multiplicando o resultado por cem, obtém-se a porcentagem. No exemplo dos totais $(2, 3, 0)$ e $(2, 1, 1)$, apenas a primeira imagem teve acerto, portanto $E_{\mathrm{total}} = 1/3$, ou aproximadamente $33{,}3\%$. Diferentemente do MAE, esse indicador não distingue um erro

de uma unidade de um erro de várias unidades: ambos tornam aquela contagem inexata.

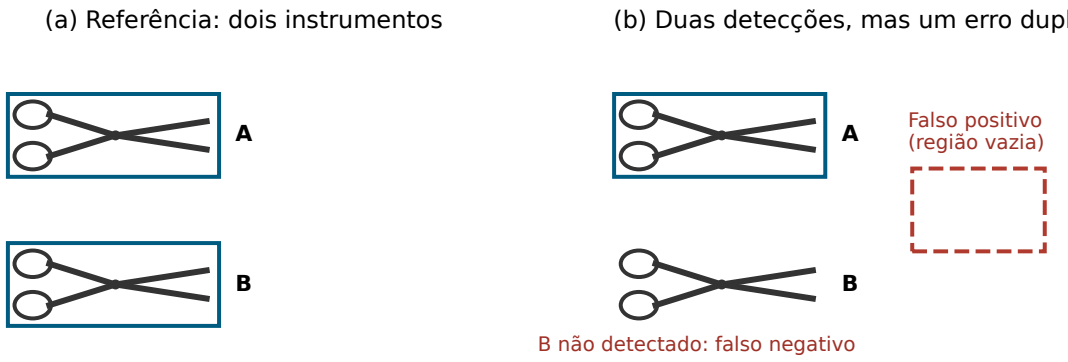
Também é possível exigir que todas as categorias estejam corretas simultaneamente. O vetor de contagens é a lista ordenada das quantidades de cada classe; por exemplo, $(2, 1, 0)$ pode representar duas pinças, uma tesoura e nenhum afastador. Define-se a proporção de vetores exatos por:

$$E_{\text{classes}} = \frac{1}{N} \sum_{i=1}^{N} \mathbf{1}[\widehat{n}_{ic} = n_{ic} \text{ para todo } c]. \tag{7}$$

A condição ``para todo c'' exige coincidência em cada posição da lista. Uma previsão $(1, 2, 0)$ tem o mesmo total de $(2, 1, 0)$, mas falha nesse critério porque troca a composição das classes. Assim, o acerto exato por classe é mais exigente que o acerto apenas do total. Entretanto, nem mesmo a coincidência do vetor garante que todas as caixas estejam corretas: uma omissão e uma detecção indevida na mesma categoria podem se compensar.

A Figura 5 ilustra essa compensação. Há dois instrumentos na referência. Na previsão esquemática, um é corretamente localizado, o outro é omitido e uma região vazia recebe uma caixa. O total continua igual a dois, mas existem um falso negativo e um falso positivo. Se ambos forem atribuídos à mesma categoria, o vetor de contagens também poderá coincidir. Por isso, as medidas de contagem precisam ser analisadas junto com a qualidade das detecções.

Figura 5: Contagem total correta apesar de uma omissão e uma detecção indevida



Fonte: elaboração própria. Representação esquemática de instrumentos e previsões hipotéticas, sem resultados do modelo treinado.

As imagens sem objetos de interesse também contribuem para a avaliação. Nelas, o resultado esperado é zero; qualquer detecção aceita produz uma sobrecontagem. Esse teste permite observar respostas indevidas em fundos, mas um conjunto de bandejas vazias não representa todos os objetos desconhecidos que

poderiam aparecer no ambiente. É necessário explicitar quais situações negativas foram incluídas, assim como a quantidade de imagens com um ou vários instrumentos.

2.8 Interpretação da viabilidade técnica

Os indicadores apresentados respondem a perguntas complementares: a detecção avalia localização e classe; o MAE expressa a diferença média entre quantidades; e o acerto exato informa a frequência de contagens sem divergência numérica. A análise por categoria, origem e número de objetos ajuda a identificar condições em que o desempenho muda. Uma condição pouco representada, como forte oclusão, não pode ser considerada validada apenas pelo resultado global.

As categorias também delimitam a interpretação. Se dois instrumentos específicos pertencem ao grupo ``pinças'', distingui-los não faz parte da tarefa do modelo geral. Um bom resultado nesse grupo, portanto, não demonstra reconhecimento de cada tipo específico. Da mesma forma, resultados com instrumentos isolados não comprovam desempenho equivalente em bandejas completas.

O custo computacional complementa a qualidade das respostas. O tempo de treinamento informa o esforço para obter o modelo; o de inferência, o tempo para analisar novas imagens. A medição deve indicar equipamento, tamanho de entrada e etapas incluídas: somente a rede ou também leitura, preparação e apresentação da imagem. Essas condições impedem transportar diretamente tempos medidos em outro dispositivo.

A viabilidade técnica depende dessas evidências e do cenário pretendido. A avaliação deve mostrar onde a abordagem funciona, onde falha e quais condições ainda exigem investigação. A metodologia apresentada a seguir transforma os conceitos discutidos em procedimentos de preparação dos dados, treinamento e avaliação da detecção e da contagem.

3 METODOLOGIA

Esta pesquisa avalia se um modelo de visão computacional consegue localizar instrumentos cirúrgicos em fotografias e contar quantos exemplares de cada categoria estão presentes. Para isso, foi organizado um experimento com imagens da internet e do Hospital Universitário da Universidade Estadual de Londrina (HU-UEL). Cada fotografia constitui uma entrada para o modelo; cada instrumento marcado nessa fotografia constitui um objeto de referência. Essa distinção permite avaliar separadamente o reconhecimento dos instrumentos e o acerto das quantidades.

O procedimento foi organizado em cinco etapas: seleção das fontes; limpeza e anotação das imagens; reunião e separação dos dados; treinamento do modelo; e avaliação da detecção e da contagem. A sequência parte da preparação dos exemplos que o modelo utilizará para aprender e termina na análise de fotografias reservadas para o teste. Assim, o desempenho foi examinado em dados que não participaram do ajuste dos pesos da rede.

Os instrumentos selecionados têm como referência a caixa de apendicectomia, isto é, o conjunto de materiais utilizado na cirurgia de retirada do apêndice. A aplicação pretendida abrange a conferência de instrumentos no expurgo e no preparo, ambientes que integram o fluxo de processamento de materiais descrito por Moreto (2025). O experimento avalia a contagem em fotografias, sem abranger esterilidade, integridade física ou funcionamento dos instrumentos. Portanto, a viabilidade investigada é a de um apoio computacional à conferência, dentro das condições representadas pela base de imagens.

3.1 Constituição e procedência da base de imagens

A base de imagens reuniu duas origens complementares. Os conjuntos públicos ofereceram exemplos previamente anotados de diferentes instrumentos, enquanto as fotografias do HU-UEL acrescentaram registros dos materiais nos ambientes em que se pretende utilizar a contagem. As fontes da internet receberam os identificadores DS01 a DS07 para permitir acompanhar sua contribuição durante a organização. Esses identificadores são utilizados nas tabelas deste capítulo.

Os conjuntos DS01, DS03, DS04 e DS05 foram obtidos no Roboflow; o DS06, no Kaggle; e o DS07, no Hugging Face. Os endereços das fontes são indicados em nota.[1] O DS02 foi descartado integralmente após a revisão identifi-

[1] DS01: https://universe.roboflow.com/fmsurg/isef-training-dataset-p360u/dataset/1; DS03: https://universe.roboflow.com/surgical-tools-hnzri/surgical_

car imagens já presentes no DS01, inclusive versões com alterações de borda e ampliação. Dessa forma, seis conjuntos externos contribuíram para a base final.

As fotografias do HU-UEL foram organizadas inicialmente por instrumento e, em casos específicos, por composição de objetos. Entre as composições anotadas estão imagens com pinça dente de rato, pinça Backhaus e cúpula, além de imagens contendo uma tesoura Metzenbaum reta e outra curva. Também foram incorporadas 100 fotografias de bandejas vazias como exemplos negativos. Imagens sem instrumentos possuem arquivo de anotação vazio; por isso, a ausência de objetos nesses casos é intencional e não deve ser interpretada como falha de rotulagem.

As fotografias do HU-UEL foram produzidas por uma enfermeira em diferentes dias, ao longo de aproximadamente três semanas, nos ambientes de expurgo e preparo. Foi utilizado um iPhone 17 Pro Max. No primeiro dia, parte das imagens foi registrada em HEIC; posteriormente, o aparelho foi configurado no modo de alta compatibilidade, passando a produzir arquivos JPEG. As primeiras imagens foram aproveitadas após conversão para um formato compatível com o fluxo de anotação. Os registros utilizados mostram instrumentos e superfícies de apoio, sem pessoas ou procedimentos cirúrgicos em andamento.

A produção em dias e ambientes distintos acrescenta variação às fotografias, mas não permite assumir que todos os registros sejam independentes: imagens próximas podem mostrar o mesmo instrumento, sobre a mesma superfície, com pequenas mudanças de posição. Essa característica foi considerada na busca de repetições e na separação dos dados, descritas na Seção 3.3.

A Tabela 1 apresenta a composição após a seleção e a revisão. Essas quantidades descrevem os dados utilizados no experimento, e não resultados de desempenho do modelo. A contagem foi realizada por scripts Python que verificaram os pares de imagens e anotações. Uma fotografia com três instrumentos acrescenta uma unidade ao total de imagens e três ao total de objetos; uma bandeja vazia acrescenta apenas uma imagem.

3.2 Seleção, anotação e padronização dos instrumentos

Antes do treinamento, as imagens e suas anotações passaram por limpeza e conferência. Essa preparação é necessária porque o modelo aprende a partir dos exemplos disponíveis: uma classe incorreta ensina uma associação

tools-6b7ze; DS04: https://universe.roboflow.com/new-workspace-fjl7e/set_1_11/dataset/2; DS05: https://universe.roboflow.com/practicum-ii-iii/suturing-kit-tools; DS06: https://www.kaggle.com/datasets/dilavado/labeled-surgical-tools; DS07: https://huggingface.co/datasets/joonhaim/surgical-tool-recognition-full-multiview.

Tabela 1 – Composição da base consolidada por origem

Origem	Imagens	Objetos anotados
DS01	289	414
DS03	115	129
DS04	249	382
DS05	85	85
DS06	2.964	4.149
DS07	1.008	1.008
Subtotal da internet	4.710	6.167
HU-UEL	5.617	6.547
Total	10.327	12.714

Fonte: elaboração própria, a partir da revisão e contagem dos dados por scripts Python (2026).
Nota: as 100 imagens negativas estão incluídas no total do HU-UEL e não acrescentam objetos.

inadequada, um instrumento sem caixa pode ser interpretado como fundo e uma repetição entre treino e teste pode tornar a avaliação excessivamente favorável. A revisão procurou reduzir esses problemas antes de reunir os conjuntos.

Foram retiradas imagens de baixa qualidade que impediam identificar o instrumento, materiais incompatíveis com a caixa selecionada e versões repetidas reconhecidas durante a inspeção. Entre as repetições estavam imagens com espelhamento, alterações de perspectiva ou regiões cobertas por quadrados escuros, provenientes de aumento de dados aplicado previamente. Sempre que possível, foi preservada a versão original de melhor qualidade. A seleção considerou o conteúdo da fotografia, e não apenas seu nome ou o nome da classe no conjunto de origem. Dúvidas sobre instrumentos específicos foram esclarecidas com a enfermeira colaboradora.

Instrumentos visualmente semelhantes, mas fora do escopo, não foram incluídos apenas para aumentar o volume da base. Quando sua presença poderia gerar supervisão contraditória, optou-se pela retirada da imagem, inclusive se ela também apresentasse um objeto desejado. Um exemplo foi o afastador Army-Navy, cuja aparência em determinadas posições se aproxima daquela do Farabeuf. Essa escolha delimita o domínio do experimento: o detector não é avaliado como classificador universal de instrumentos semelhantes aos selecionados.

A revisão dos conjuntos externos foi realizada com apoio do CVAT e de inspeções no Roboflow. As fotografias do HU-UEL foram anotadas no X-AnyLabeling. Anotar uma imagem, neste estudo, significa traçar um retângulo que envolva cada instrumento e atribuir a ele uma classe. Esses retângulos, ou caixas delimitadoras, constituem as referências utilizadas para ensinar e avaliar

o detector. Foram utilizadas caixas horizontais, com lados paralelos às bordas da fotografia, mesmo quando o instrumento estava inclinado.

As anotações foram exportadas no formato YOLO para detecção. Cada linha do arquivo TXT representa um objeto e contém o identificador da classe, as coordenadas do centro da caixa, sua largura e sua altura. As quatro medidas são divididas pelas dimensões da imagem, ficando normalizadas entre zero e um. Por exemplo, uma largura de 0,25 representa um quarto da largura da fotografia. A imagem e seu TXT compartilham o mesmo nome-base, permitindo associá-los sem depender da ordem dos arquivos na pasta.

Nos conjuntos com polígonos, a conversão para detecção utilizou os menores e maiores valores de cada coordenada para obter a caixa envolvente de cada instância. Esse procedimento conserva a extensão espacial do contorno anotado, mas não verifica sua pertinência semântica. Por isso, caixas que abrangiam componentes indesejados, como tubos conectados ao bico de aspiração ou partes além do cabo de bisturi, foram submetidas à revisão manual. No DS07, as anotações convertidas de JSONL foram inspecionadas visualmente, e foram mantidas as classes correspondentes a porta-agulhas e cabos de bisturi.

Os instrumentos selecionados foram organizados em sete categorias gerais para o treinamento. Durante a preparação, foram identificados 17 tipos ou variantes de instrumentos, incluindo Kelly, Mayo e Metzenbaum retas e curvas. Essa identificação orientou a padronização das anotações e sua associação às categorias utilizadas pelo modelo. A Tabela 2 apresenta a quantidade de objetos anotados em cada uma das sete categorias utilizadas no treinamento. Os valores correspondem à base consolidada, reunindo as divisões de treino, validação e teste.

A organização em categorias gerais reúne exemplos sob um número menor de rótulos e concentra a avaliação na localização dos objetos e na contagem. Entretanto, o agrupamento não torna todos os integrantes de uma categoria visualmente semelhantes. Por isso, a pesquisa examina o desempenho obtido nessa configuração, sem pressupor vantagem em relação a uma classificação mais detalhada.

Diferenças de tamanho não originaram classes distintas. Porta-agulhas, cúpulas e bicos de aspiração foram mantidos em categorias próprias. Os exemplares Yankauer aceitos na conferência foram reunidos à categoria de bicos de aspiração. Os nomes em português são utilizados na apresentação do trabalho, enquanto os identificadores em inglês são empregados nos arquivos de treinamento.

A representação é desigual entre classes e origens. Por exemplo, as pinças anatômicas e os cabos de bisturi da base consolidada provêm exclusivamente

Tabela 2 – Quantidade de objetos anotados por categoria na base consolidada

Categoria	Objetos anotados
Pinças	4.907
Tesouras	3.976
Afastadores	848
Porta-agulhas	760
Cabos de bisturi	1.673
Bicos de aspiração	244
Cúpulas	306
Total	12.714

Fonte: elaboração própria, a partir da revisão e contagem dos dados por scripts Python (2026).

da internet. Consequentemente, um resultado agregado satisfatório não demonstra desempenho hospitalar para todas as classes. Essa diferença deve ser considerada na análise dos erros e na apresentação dos resultados por origem.

3.3 Consolidação, verificação e separação dos dados

Neste estudo, consolidação significa reunir os conjuntos selecionados em uma única base organizada, compatibilizando nomes de classes, formatos de anotação e estrutura de pastas. Esse processo foi executado por scripts Python sobre cópias dos arquivos, preservando os conjuntos originais. Cada imagem consolidada manteve uma identificação de sua origem, de suas classes e da divisão à qual foi destinada. A preparação ocorreu no Windows, e a base organizada foi transferida para o Mac utilizado no treinamento.

A conferência automática verificou se cada imagem podia ser aberta, se possuía a anotação correspondente e se os identificadores de classe estavam previstos no mapeamento. Também foram examinadas as coordenadas das caixas, incluindo dimensões positivas e limites válidos. Os arquivos vazios foram tratados separadamente para distinguir as bandejas sem instrumentos de uma possível ausência de anotação. Também foi verificado se a conversão dos identificadores específicos para as categorias gerais preservava as imagens, as coordenadas das caixas e a divisão atribuída a cada exemplo.

A busca por repetições combinou comparação de arquivos, comparação dos pixels decodificados e semelhança visual. Para isso, foram utilizados resumos digitais, chamados *hashes*: o SHA-256 permitiu conferir a integridade dos arquivos comparados, enquanto o dHash forneceu uma assinatura simplificada da aparência. Assinaturas perceptuais próximas indicaram candidatos à revisão,

mas não foram tratadas como prova suficiente de duplicação. Fotografias de instrumentos diferentes sobre o mesmo fundo podem apresentar grande semelhança nessa representação.

Os candidatos foram examinados visualmente para distinguir cópias de fotografias diferentes. Quando uma mesma imagem apareceu em resoluções distintas, a versão de melhor qualidade foi priorizada. Fotografias relacionadas por repetição ou sequência identificada foram reunidas em grupos destinados à mesma divisão. Dessa forma, procurou-se evitar que uma versão fosse utilizada no aprendizado e outra muito próxima fosse usada para avaliar o mesmo modelo.

O agrupamento procura reduzir a dependência entre dados usados para aprender e dados usados para avaliar. Como discutem Kapoor e Narayanan (2023), falhas na separação podem produzir conclusões excessivamente otimistas. Entretanto, a ausência de grupos cadastrados em mais de uma divisão não comprova independência de todas as sessões de aquisição. A base contém imagens de instrumentos reposicionados em cenários semelhantes, e os registros disponíveis não permitem reconstruir integralmente todas as sessões das fontes externas. Essa restrição permanece como limitação do experimento.

Após a organização, a base foi separada em treino, validação e teste. O treino fornece os exemplos utilizados para ajustar os pesos da rede. A validação acompanha o aprendizado e permite selecionar o estado do modelo e o limiar de confiança. O teste permanece reservado para avaliar o procedimento após essas escolhas. A distribuição final se aproxima de 80%, 10% e 10%, respectivamente, com pequenos ajustes necessários para manter os grupos identificados na mesma divisão.

A Tabela 3 apresenta as quantidades efetivas. Essas divisões foram utilizadas no treinamento e na avaliação do modelo de sete categorias gerais. Entre os exemplos negativos, 80 bandejas vazias pertencem ao treino, dez à validação e dez ao teste. A separação por grupos reduz um risco de dependência, mas não equivale a uma divisão completa por dia, paciente ou hospital: as fontes disponíveis não fornecem todos esses metadados.

Tabela 3 – Distribuição das imagens e dos objetos por divisão

Divisão	Imagens	Objetos anotados
Treino	8.304	10.044
Validação	1.015	1.293
Teste	1.008	1.377
Total	10.327	12.714

Fonte: elaboração própria, a partir da revisão e contagem dos dados por scripts Python (2026).

3.4 Ambiente computacional e configuração do treinamento

O ambiente de execução utilizou um Mac mini com chip Apple M4 e 16 GB de memória unificada, com aceleração pela interface Metal Performance Shaders (MPS) do PyTorch. O ambiente utilizado compreende Python 3.13, PyTorch 2.15.0 e Ultralytics 8.4.192, em arquitetura arm64. A configuração foi mantida após os testes de instalação para evitar mudanças de dependências durante o experimento.

Antes do treinamento principal, foi executado um piloto de três épocas com 10% das imagens de treino. Sua finalidade foi verificar o carregamento das imagens e dos rótulos, a execução na GPU por MPS, o comportamento do consumo de memória e o tempo necessário para processar os lotes. Essa etapa permitiu verificar a execução do procedimento no equipamento disponível antes de iniciar uma tarefa mais longa.

O treinamento foi iniciado com o YOLO26n e pesos pré-treinados, utilizando toda a divisão de treino. Portanto, o aprendizado principal começou a partir do pré-treinamento, e não dos pesos obtidos no piloto. Como apresentado na fundamentação, a letra *n* identifica a variante de menor porte da família utilizada, que também inclui variantes maiores. Foi priorizada uma configuração compatível com a memória e o tempo disponíveis, sem supor que ela apresentaria o melhor desempenho entre todas as alternativas.

O pré-treinamento fornece uma inicialização que já aprendeu características visuais em outra base. Durante a adaptação aos instrumentos cirúrgicos, os pesos podem ser atualizados, pois não foi configurado congelamento de camadas. Essa escolha reduz a necessidade de iniciar o aprendizado com parâmetros aleatórios, mas não substitui a presença de exemplos adequados das classes e dos cenários de interesse (PyTorch, 2026b).

A configuração do treinamento está sintetizada na Tabela 4. O limite de 50 épocas foi definido considerando os recursos e o tempo disponíveis, e não como valor ótimo estabelecido por busca sistemática. A parada antecipada foi configurada com tolerância de dez épocas sem melhora no critério de validação da implementação. O treinamento completou as 50 épocas previstas, e sua duração e evolução são apresentadas no capítulo de resultados.

O AdamW emprega decaimento de pesos desacoplado da atualização adaptativa, conforme a formulação de Loshchilov e Hutter (2019). Sua adoção neste experimento representa uma escolha explícita de otimização, sem reproduzir integralmente a receita de pré-treinamento do YOLO26. A taxa de aprendizagem foi configurada com aquecimento e redução linear, sem busca automática de hiperparâmetros. As definições operacionais dos argumentos são apresentadas

Tabela 4 – Parâmetros definidos para o treinamento principal

Parâmetro	Configuração
Modelo e tarefa	YOLO26n; detecção de caixas horizontais
Classes e fração do treino	7 categorias; 100% da divisão
Épocas e tolerância de parada	Máximo de 50; tolerância de 10
Dimensão de entrada configurada	640 pixels
Lote físico / lote nominal	4 / 64
Otimizador	AdamW
Taxa inicial / fator final	0,001 / 0,01
Decaimento de pesos configurado	0,0005
Parâmetro de momento	0,9
Aquecimento	3 épocas
Semente	42
Dispositivo e precisão mista	MPS; precisão mista desativada
Processos auxiliares / cache de imagens	0 / desativado
Salvamento periódico	A cada 5 épocas

Fonte: elaboração própria, a partir da configuração do treinamento (2026).
Nota: o lote nominal é uma referência interna para a otimização; não equivale ao número de imagens simultaneamente processadas no dispositivo.

na documentação do software (Ultralytics, 2026b).

O tamanho de entrada foi configurado em 640 pixels para limitar o custo de processamento e utilizar uma dimensão usual da implementação. Durante o carregamento, as imagens são adaptadas às entradas do modelo por redimensionamento e, conforme a transformação aplicada, preenchimento ou recorte. Os arquivos de origem não são alterados por esse processamento. Não foi ativado treinamento com tamanhos variáveis entre lotes. A redução de resolução pode remover detalhes de pontas, serrilhas e instrumentos pequenos; por isso, o tamanho escolhido constitui uma condição do experimento, e não uma resolução comprovadamente ideal.

O lote físico foi limitado a quatro imagens, isto é, quatro entradas processadas de cada vez. O lote nominal de 64 é uma referência interna da implementação para a otimização e não indica que 64 imagens estejam simultaneamente carregadas na GPU. O cache de imagens e os processos auxiliares de carregamento foram desativados, assim como a precisão mista. Essas decisões priorizam uma configuração de execução compatível com o Mac utilizado; não foram comparadas sistematicamente com outras combinações.

A semente foi fixada em 42 e foi configurada execução determinística. A semente controla as sequências de escolhas aleatórias, contribuindo para documentar o experimento. Entretanto, algumas operações do MPS não dispõem de implementação determinística, e o próprio ambiente apresentou aviso dessa

limitação. Assim, a configuração favorece a repetibilidade, mas não garante resultados numericamente idênticos em todas as execuções (PyTorch, 2026a).

Durante o treino, a validação foi realizada ao final de cada época. Foram registrados os argumentos efetivos, as versões dos programas, as perdas e as métricas de validação, além dos pesos do último estado e do estado considerado melhor pelo critério da implementação. O conjunto de teste não participou dessa seleção. Esses registros permitiram conferir a configuração executada e acompanhar a evolução do aprendizado.

3.5 Aumento de dados durante o treinamento

O aumento de dados cria variações das imagens durante o aprendizado, procurando reduzir a dependência de posições e aparências muito específicas (Goodfellow; Bengio; Courville, 2016). Neste experimento, essas transformações foram configuradas para ocorrer durante o treino, sem salvar uma nova coleção permanente de fotografias. Assim, a mesma imagem pode ser apresentada de formas diferentes em épocas distintas, com atualização correspondente das caixas.

Foram configurados espelhamentos horizontal e vertical com probabilidade de 0,5 cada, rotações de até aproximadamente $\pm 15°$, translação relativa de até 0,1 e variação de escala de 0,25. Essas operações procuram representar mudanças de orientação, posição e tamanho aparente. As variações de matiz, saturação e brilho, controladas pelos parâmetros HSV, foram definidas como 0,015, 0,3 e 0,2. Elas introduzem diferenças de cor e iluminação, sem demonstrar, por si só, que o modelo será robusto a todas as condições do hospital.

A transformação mosaic foi configurada com probabilidade de 0,5 para compor entradas a partir de diferentes imagens. Sua aplicação busca ampliar a variedade de composições, mas não reproduz necessariamente oclusões e interações físicas entre instrumentos em uma bandeja real. MixUp, Copy-Paste, cisalhamento e perspectiva adicional foram desativados. A documentação da Ultralytics descreve essas operações e seus parâmetros (Ultralytics, 2026a).

O mosaic foi desativado antes da época 41, permanecendo desativado nas dez últimas épocas do treinamento. Essa alteração foi confirmada nos registros de execução. As imagens dos lotes transformados também permitiram inspecionar exemplos do aumento de dados e das caixas correspondentes. Como não foi realizada uma comparação isolando essa transformação, sua contribuição individual para o desempenho não foi determinada.

As 8.304 imagens de treino permanecem como quantidade física de referência. Repetições ao longo das épocas e variações geradas durante o processa-

mento não são contabilizadas como fotografias independentes. Validação e teste não recebem a política aleatória de aumento de dados do treino, embora também necessitem do pré-processamento de entrada. Essa distinção evita confundir expansão de apresentações do mesmo material com aumento da diversidade original da amostra.

3.6 Protocolo de avaliação da detecção e da contagem

A avaliação foi realizada após o encerramento do treinamento e examinou duas perguntas complementares: o modelo localiza e classifica os instrumentos corretamente? As detecções aceitas produzem a quantidade correta por imagem e por categoria? Essas perguntas foram analisadas em conjunto, pois uma quantidade correta pode resultar da compensação entre uma omissão e uma detecção indevida.

Foram utilizados os pesos selecionados pelo critério de validação do treinamento. O limiar de confiança para a contagem foi definido exclusivamente no conjunto de validação, examinando 19 valores entre 0,05 e 0,95, em intervalos de 0,05. O critério principal foi minimizar a soma dos erros absolutos de contagem por categoria. Em caso de empate, o procedimento priorizava a maior quantidade de imagens com todas as contagens por categoria corretas e, persistindo o empate, o maior limiar. O valor selecionado foi 0,45 e permaneceu fixo durante o teste.

As predições foram obtidas com dimensão de entrada configurada em 640 pixels, uma imagem por chamada e sem aumento de dados na avaliação. Para detecção, foram calculados precisão, revocação, mAP a 0,50 de interseção sobre união e mAP de 0,50 a 0,95. As métricas foram interpretadas conforme as definições da fundamentação e os critérios discutidos por Padilla *et al.* (2021). A avaliação padrão da implementação foi registrada separadamente das medidas calculadas no limiar de confiança escolhido para a contagem (Ultralytics, 2026c).

No ponto de operação da contagem, a correspondência entre previsões e referências considerou a categoria e uma interseção sobre união mínima de 0,50, sem permitir que várias previsões fossem associadas como acertos a um único objeto. Esse procedimento permitiu identificar detecções corretas, previsões indevidas e objetos não recuperados.

As métricas de contagem foram calculadas por um script Python a partir das anotações de referência e das predições. Para cada imagem, foram comparadas as quantidades totais e por categoria. Foram obtidos o erro absoluto médio do total, os erros por categoria, a proporção de imagens com total correto e a proporção com acerto simultâneo em todas as categorias. Esta última medida

compara o vetor de contagens, isto é, a lista de quantidades na ordem fixa das sete categorias.

Também foram identificadas as imagens com contagem inferior ou superior à referência. As fotografias sem instrumentos foram incluídas para verificar previsões indevidas em bandejas vazias. Os resultados foram separados por origem e categoria, com indicação dos números de imagens e objetos. A ausência de exemplos positivos de uma categoria em determinado subconjunto não foi interpretada como desempenho perfeito.

O número de objetos por fotografia foi obtido das anotações. A análise distinguiu cenas vazias, com um objeto, com dois ou três e com quatro ou mais objetos. Essa separação permitiu examinar diferenças de desempenho conforme a quantidade de instrumentos representada, sem atribuir essas diferenças exclusivamente ao número de objetos, pois as categorias e as condições das imagens também variam.

A revisão visual compreendeu 62 imagens: 30 selecionadas entre os maiores erros de contagem por categoria, duas com contagem correta e falha de correspondência espacial, 20 casos de acerto sorteados e dez imagens sem objetos. Foram examinados omissões, detecções excedentes, trocas de categoria e problemas de localização, além de condições como sobreposição, reflexos e baixo contraste. Por se tratar de uma seleção dirigida, essa revisão não foi utilizada para estimar a frequência dessas condições em todo o teste.

A sobreposição física foi examinada visualmente. A interseção entre caixas não foi utilizada como prova de oclusão, pois retângulos de objetos separados também podem se sobrepor. As possíveis condições associadas às falhas foram discutidas qualitativamente, sem atribuição de causalidade apenas pela inspeção. As inconsistências de referência identificadas nessa revisão foram documentadas, mantendo-se os resultados da avaliação original.

O custo computacional foi descrito pela duração registrada do treinamento e por medições de processamento no Mac utilizado. Foram medidas 50 chamadas completas, com uma imagem por chamada, após três execuções de aquecimento. A medição incluiu leitura, pré-processamento, inferência e pós-processamento, com sincronização do dispositivo. Foram calculados média, mediana, percentil 95 e maior tempo observado. Esses valores não incluem as etapas de captura e conferência em uma aplicação hospitalar completa.

A viabilidade foi discutida a partir da qualidade das detecções, do acerto das contagens, das falhas observadas e do custo de processamento. Não foi definido um limite clínico de aceitação. Portanto, a interpretação se restringe às condições representadas no experimento e não equivale à validação de um sistema para substituir a conferência profissional ou assegurar a ausência de

materiais retidos no paciente.

4 RESULTADOS E DISCUSSÃO

Este capítulo apresenta os resultados do modelo YOLO26n treinado para detectar instrumentos e contar os objetos de sete categorias gerais. A análise procura responder em quais condições essa abordagem apresentou resultados favoráveis e quais dificuldades ainda limitam sua aplicação. Para isso, são examinados o aprendizado durante o treinamento, a localização dos objetos, a contagem por imagem e os exemplos de acertos e falhas observados no teste.

A avaliação utilizou 1.008 imagens reservadas para teste, com 1.377 objetos anotados: 559 fotografias do HU-UEL e 449 imagens de fontes da internet. Esses dados foram mantidos separados das 8.304 imagens de treinamento e das 1.015 imagens de validação. Os resultados a seguir se referem às categorias gerais, como pinças e tesouras, e não à distinção entre todos os instrumentos específicos que compõem cada categoria. Assim, identificar uma pinça como pertencente à categoria correta não significa, por si só, reconhecer se ela é uma Kelly, uma Kocher ou outro instrumento desse grupo.

4.1 Evolução do treinamento

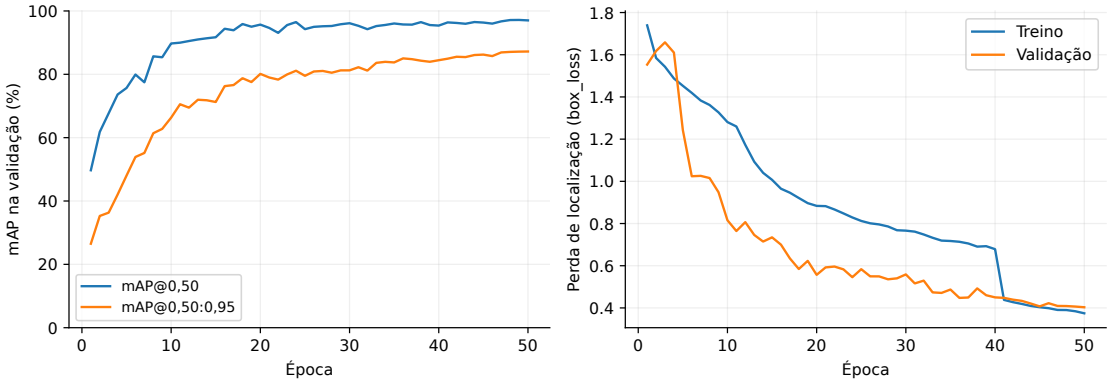
O treinamento foi concluído em 50 épocas, com duração aproximada de 8 horas e 43 minutos no Mac mini M4 com 16 GB de memória. Em cada época, o modelo percorreu o conjunto de treinamento e, em seguida, foi avaliado no conjunto de validação. Essa avaliação intermediária permitiu acompanhar o aprendizado sem utilizar o conjunto de teste para escolher os pesos do modelo.

A Figura 6 apresenta dois aspectos dessa evolução. À esquerda, as medidas de precisão média das detecções aumentam ao longo das épocas. À direita, diminui a perda de localização, que expressa o desajuste entre as caixas previstas e as caixas de referência utilizadas pelo algoritmo. A redução dessa perda indica que o treinamento passou a produzir delimitações mais próximas das anotações, embora ela não deva ser interpretada como uma porcentagem de acertos.

Na última época, a validação alcançou mAP@0,50 de 97,02% e mAP@0,50:0,95 de 87,20%. Este último foi o maior valor registrado nas 50 épocas. A diferença entre as duas medidas é esperada: a primeira admite uma correspondência espacial menos exigente, enquanto a segunda reúne avaliações com diferentes exigências de sobreposição entre as caixas. Conforme discutido por Padilla *et al.* (2021), a interpretação do desempenho depende do critério de correspondência empregado. Por esse motivo, uma única medida de detecção não resume todos os aspectos da qualidade do modelo.

As curvas mostram avanço do aprendizado, mas não demonstram que 50

Figura 6: Evolução das métricas de validação e da perda de localização durante o treinamento



Fonte: elaboração própria, com base nos registros do treinamento.

épocas constituem a duração ideal para qualquer configuração. Também não permitem atribuir o resultado a uma técnica isolada de aumento de dados, pois não foi realizado um experimento que comparasse o treinamento com e sem cada transformação. A alteração das condições de aumento de dados ao final do treinamento, incluindo o encerramento do mosaico, deve ser considerada ao interpretar mudanças nas perdas. O resultado obtido corresponde ao conjunto de escolhas adotado neste experimento. Como não houve comparação com uma classificação mais detalhada, os resultados não permitem atribuir ao agrupamento em categorias gerais um ganho de desempenho.

4.2 Escolha do limiar de confiança para a contagem

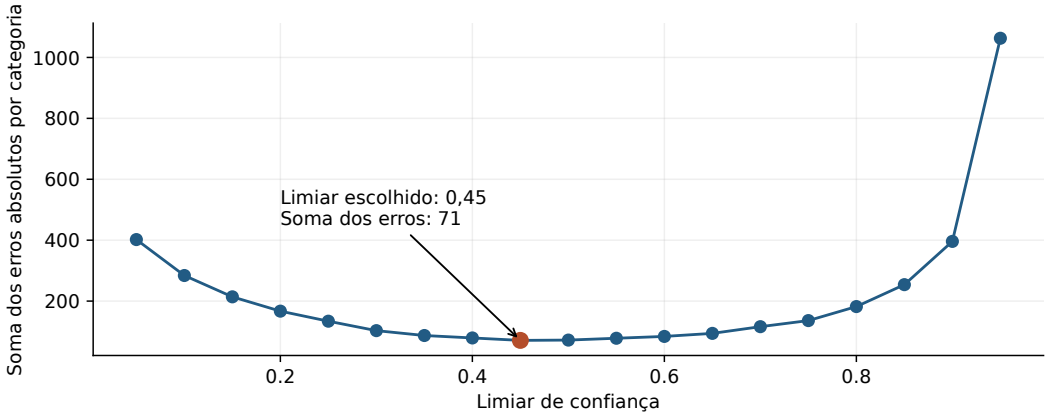
Antes de contar os objetos no teste, foi necessário definir quais detecções seriam aceitas. Cada previsão recebe um valor de confiança; um limiar muito baixo permite incluir previsões incertas, enquanto um limiar muito alto pode descartar instrumentos que o modelo detectou com menor confiança. Essa escolha influencia diretamente tanto os objetos acrescentados indevidamente quanto os objetos que deixam de ser contados.

Foram avaliados 19 limiares, de 0,05 a 0,95, em intervalos de 0,05, exclusivamente no conjunto de validação. O critério principal foi minimizar a soma dos erros absolutos de contagem por categoria. Nesse cálculo, para cada imagem, comparou-se a quantidade prevista com a quantidade de referência em cada uma das sete categorias, somando as diferenças sem permitir que um excesso em uma categoria compensasse uma falta em outra.

O menor erro entre os valores examinados ocorreu no limiar 0,45, com soma de 71 erros absolutos por categoria e contagem correta em todas as cate-

gorias de 972 das 1.015 imagens de validação. A Figura 7 mostra a variação do erro. O limiar 0,50 apresentou resultado próximo, com soma de 72, mas não superou o critério escolhido. Portanto, 0,45 foi adotado no teste; trata-se da melhor opção dentro da grade examinada, e não de uma demonstração de que seja o melhor valor possível em qualquer conjunto de imagens.

Figura 7: Erro de contagem por categoria em função do limiar de confiança na validação



Fonte: elaboração própria, com base na calibração no conjunto de validação.

A escolha anterior ao teste preserva a finalidade desse conjunto: avaliar uma configuração já definida. Ajustar repetidamente o limiar a partir dos erros de teste reduziria a independência dessa avaliação. A revisão visual posterior foi empregada para compreender as falhas, sem modificar o limiar nem recalcular os resultados apresentados neste capítulo.

4.3 Desempenho na detecção dos instrumentos

Na avaliação padrão de detecção no teste, o modelo alcançou mAP@0,50 de 98,06% e mAP@0,50:0,95 de 86,73%. O resultado mais alto no primeiro critério mostra que a identificação com sobreposição mínima de 50% foi mais favorável do que a avaliação que também exige delimitações mais próximas da referência. Assim, o modelo pode localizar a região do instrumento e ainda apresentar diferenças no tamanho ou na posição da caixa.

Para examinar o funcionamento da contagem, a Tabela 5 apresenta a precisão e a revocação calculadas com confiança de 0,45 e sobreposição mínima de 50%. A precisão informa a proporção de detecções aceitas que corresponderam a objetos da categoria correta. A revocação informa a proporção dos objetos de referência que foi recuperada pelo modelo. Esses valores em um limiar fixo não devem ser confundidos com a precisão média, que considera a ordenação das previsões por confiança.

Tabela 5 – Detecção por categoria no ponto de operação adotado para a contagem

Categoria	Objetos	Acertos	Precisão (%)	Revocação (%)
Pinças	509	497	97,26	97,64
Tesouras	451	442	99,33	98,00
Afastadores	81	78	91,76	96,30
Porta-agulhas	76	71	98,61	93,42
Cabos de bisturi	209	188	92,61	89,95
Bicos de aspiração	21	20	100,00	95,24
Cúpulas	30	30	96,77	100,00

Fonte: elaboração própria. Objetos: quantidade na referência original; acertos: detecções associadas à categoria correta com IoU $\geq 0{,}50$. Confiança $\geq 0{,}45$. A referência contém duas classificações incorretas discutidas na Seção 4.6.

Os cabos de bisturi apresentaram a menor revocação: 188 dos 209 objetos foram recuperados segundo o critério de correspondência. Também ocorreram 15 detecções incorretas nessa categoria. Nos afastadores, a precisão foi de 91,76%, com sete detecções incorretas, enquanto três objetos não foram recuperados. Esses resultados indicam dificuldades diferentes: além de deixar de detectar objetos, o modelo pode gerar mais de uma previsão ou atribuir a categoria a uma região que não corresponde a um instrumento desejado.

As tesouras apresentaram precisão de 99,33% e revocação de 98,00%, com maior quantidade de objetos de referência do que os bicos de aspiração e as cúpulas. Para estas duas últimas categorias, os resultados favoráveis precisam ser interpretados à luz dos 21 e 30 objetos disponíveis no teste. A precisão de 100% dos bicos de aspiração significa que não houve detecção incorreta dessa categoria neste conjunto; não significa ausência de falhas em novas situações. Da mesma forma, todas as cúpulas de referência foram recuperadas, mas houve uma detecção adicional incorreta.

4.4 Contagem total e contagem por categoria

A contagem total coincidiu com a referência em 972 das 1.008 imagens, correspondendo a 96,43%. Nas demais, houve subcontagem em 21 imagens e sobrecontagem em 15. O erro absoluto médio foi de 0,0536 objeto por imagem, calculado a partir da soma de 54 diferenças absolutas dividida pelas 1.008 imagens. Esse valor é uma média: não representa uma fração física de instrumento em cada fotografia e pode reunir muitos acertos com alguns erros maiores.

Ao exigir simultaneamente a quantidade correta em todas as sete categorias, o número de imagens com acerto diminuiu para 964, ou 95,63%. Essa exigência corresponde à coincidência do vetor de contagens: além do total, cada posição da lista de quantidades por categoria deve estar correta. A diferença de

oito imagens em relação ao acerto total mostra por que contar corretamente o conjunto não garante reconhecer corretamente sua composição. Um objeto atribuído à categoria errada pode preservar o total, mas altera duas posições dessa lista.

A soma dos erros absolutos por categoria foi de 76, equivalente à média de 0,0754 por imagem. Essa medida foi maior do que o erro da contagem total porque não permite compensações entre categorias. Considerando todas as imagens em conjunto, foram previstos 1.367 objetos, dez a menos do que os 1.377 da referência. Contudo, a diferença de dez no total agregado ocultaria erros locais de sentidos opostos. Para a conferência de uma fotografia, a comparação por imagem é mais informativa do que apenas somar todas as previsões do conjunto.

Além disso, a contagem correta não assegura uma delimitação correta. Uma previsão pode produzir o número esperado de objetos, mas apresentar uma caixa com sobreposição insuficiente em relação à referência. A avaliação conjunta das contagens e das detecções evita tratar esses casos como equivalentes a uma identificação inteiramente correta.

4.5 Origem das imagens e quantidade de objetos na cena

A Tabela 6 separa os resultados pela origem das imagens. O acerto da contagem total foi de 98,39% nas fotografias do HU-UEL e de 93,99% nas imagens da internet. A coincidência das quantidades em todas as categorias também foi maior no subconjunto hospitalar.

Tabela 6 – Resultados de contagem por origem das imagens de teste

Origem	Imagens	Objetos	Total correto	Vetor correto	MAE total
HU-UEL	559	647	98,39%	98,21%	0,0197
Internet	449	730	93,99%	92,43%	0,0958
Conjunto	1.008	1.377	96,43%	95,63%	0,0536

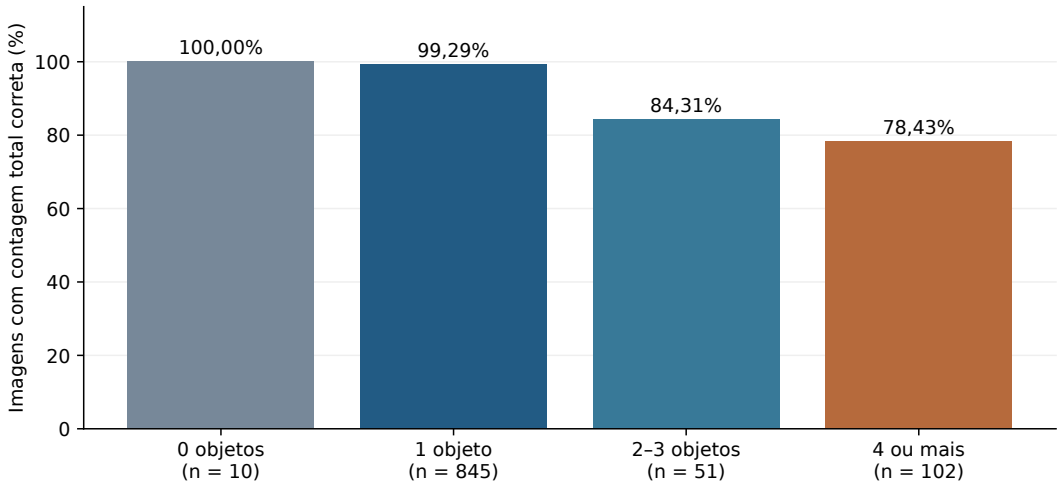
Fonte: elaboração própria. Total correto e vetor correto representam proporções de imagens. MAE total: erro absoluto médio da quantidade total por imagem.

Essa diferença não demonstra que a origem hospitalar, isoladamente, tenha causado o melhor desempenho. Os subconjuntos diferem na composição de categorias, no número de objetos, no enquadramento e nas condições de captura. As fotografias hospitalares também podem compartilhar características visuais das sessões de aquisição presentes na base. Portanto, o resultado descreve o conjunto reservado para teste, sem equivaler a uma avaliação prospectiva em novos dias, ambientes ou rotinas de trabalho.

Há ainda uma restrição de cobertura: o subconjunto de teste do HU-UEL não contém cabos de bisturi anotados. Consequentemente, os resultados dessa categoria são provenientes das imagens da internet e não demonstram seu desempenho em fotografias hospitalares. Para porta-agulhas, bicos de aspiração e cúpulas do HU-UEL, foram avaliados, respectivamente, 18, 15 e 28 objetos, todos recuperados sem previsões adicionais dessas categorias nesse subconjunto. Embora favoráveis, essas observações abrangem amostras pequenas e condições limitadas de aquisição.

A quantidade de objetos na cena revela outra diferença importante. Das 1.008 imagens de teste, 845, ou 83,83%, contêm apenas um objeto. Nesse grupo, a contagem total foi correta em 839 imagens, correspondendo a 99,29%. Nas cenas com dois ou três objetos, o acerto foi de 84,31%; nas cenas com quatro ou mais, foi de 78,43%, como mostra a Figura 8.

Figura 8: Acerto da contagem total conforme a quantidade de objetos de referência na cena



Fonte: elaboração própria. O valor de n indica a quantidade de imagens em cada grupo.

O erro absoluto médio também aumentou entre esses grupos: foi de 0,0107 nas imagens com um objeto, 0,1765 nas imagens com dois ou três e 0,3529 nas imagens com quatro ou mais. Esses números mostram uma associação entre cenas com mais objetos e maior dificuldade no conjunto avaliado. Como a composição das categorias e as condições das fotografias também variam, não é possível atribuir toda a diferença apenas ao número de instrumentos.

O grupo com quatro ou mais objetos reúne 102 imagens, das quais 100 possuem quatro objetos, uma possui cinco e uma possui dez. Assim, ele representa principalmente cenas com quatro instrumentos, e não bandejas completas com grande concentração de itens. As dez imagens sem objetos apresentaram contagem zero corretamente. Esse resultado é útil para verificar bandejas vazias,

mas não demonstra que o modelo rejeitaria qualquer objeto estranho ou instrumento fora das categorias de interesse.

4.6 Análise visual dos acertos e das falhas

Para compreender os resultados numéricos, foram examinadas visualmente 62 imagens: 30 selecionadas entre os maiores erros de contagem por categoria, duas com contagem correta e falha de correspondência espacial, 20 casos de acerto sorteados e dez imagens sem objetos. Essa seleção reúne situações úteis para análise, mas não constitui uma amostra aleatória de todo o teste. Portanto, a frequência de uma dificuldade nessa revisão não pode ser generalizada para todas as imagens.

Nos exemplos de acerto, as caixas delimitaram os instrumentos e receberam as categorias esperadas, inclusive em fotografias do HU-UEL. Nas falhas, foram observadas situações com instrumentos próximos ou sobrepostos, objetos visualmente semelhantes e regiões de baixo contraste. Essas observações ajudam a formular explicações para os erros, mas não isolam experimentalmente a contribuição de cada fator.

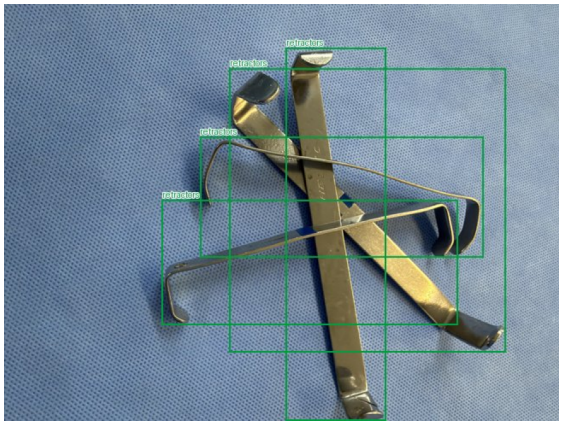
A Figura 9 apresenta dois casos. Na imagem dos afastadores Farabeuf, quatro objetos de referência resultaram em sete previsões. A proximidade e a sobreposição dos instrumentos dificultam distinguir suas partes e associá-las a um único objeto. No segundo exemplo, havia um cabo de bisturi de interesse e cinco lâminas; o modelo contou cinco objetos como cabos, incluindo quatro lâminas indevidamente. Esse caso mostra que uma categoria pode receber previsões de objetos com partes visualmente semelhantes, ainda que esses objetos não devam participar da contagem.

Também ocorreram omissões em fotografias com vários cabos de bisturi. Em um caso com cinco cabos lado a lado, foram detectados somente os dois externos. Em outro, com dez objetos de referência, foram previstos três. Esses exemplos ajudam a explicar por que a diferença entre o total previsto e o total de referência pode ser elevada em algumas imagens, apesar do erro médio reduzido no conjunto completo.

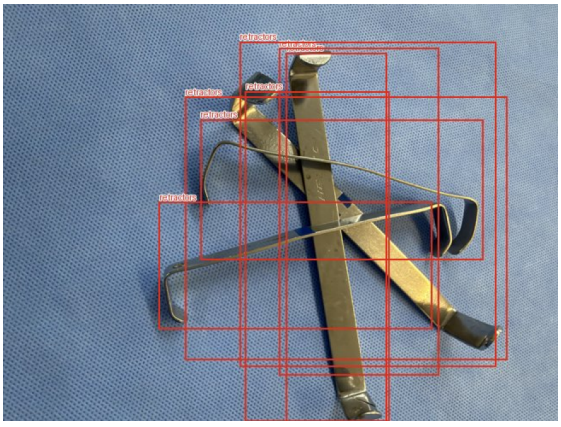
A revisão identificou ainda duas classificações incorretas na própria referência: duas imagens de pinça Kelly reta estavam anotadas como porta-agulhas. Nessas imagens, a previsão da categoria pinças era compatível com a identificação visual, mas foi penalizada pela comparação automática com a anotação original. Os resultados deste capítulo foram mantidos conforme essa avaliação original, sem uma reavaliação após correção. A limitação afeta a interpretação das métricas por categoria; a quantidade de objetos dessas duas imagens, porém,

Figura 9: Exemplos de sobrecontagem em afastadores e de confusão entre cabo de bisturi e lâminas

(a) Farabeuf: referência



(a) Farabeuf: predição



(b) Cabo e lâminas: referência



(b) Cabo e lâminas: predição



Fonte: elaboração própria a partir das imagens do conjunto de teste e das saídas do modelo. À esquerda, referência em verde; à direita, previsões em vermelho. Os identificadores em inglês correspondem às categorias utilizadas no processamento.

permanece a mesma. Assim, a referência também deve ser examinada antes de atribuir todo desacordo ao modelo.

Em outros dois casos, a categoria e a contagem estavam corretas, mas a caixa prevista não atingiu a sobreposição mínima exigida. A inspeção confirmou que se tratava de instrumentos distintos: uma pinça dente de rato e uma pinça anatômica. Apesar da semelhança visual das fotografias, elas não devem ser consideradas cópias do mesmo objeto. Esses casos reforçam a separação entre acertar a quantidade, acertar a categoria e delimitar adequadamente a região do instrumento.

4.7 Tempo de processamento e alcance dos resultados

O tempo de processamento foi medido em 50 imagens de teste, após três chamadas de aquecimento, com uma imagem por chamada e sincronização do processamento no dispositivo. A medição da chamada completa incluiu a leitura da imagem, o pré-processamento, a inferência e o pós-processamento. A média foi de 29,24 ms por imagem e a mediana de 24,22 ms. O percentil 95 foi de 48,81 ms, indicando que aproximadamente 95% dos tempos medidos ficaram abaixo desse valor. O maior tempo observado foi de 281,13 ms, evidenciando que a duração não foi constante.

Esses valores sugerem rapidez para processar fotografias nas condições avaliadas. Entretanto, não incluem o tempo necessário para organizar os instrumentos, capturar a fotografia, transferi-la e conferir o resultado em uma aplicação completa. Também não equivalem a uma taxa de quadros validada em vídeo contínuo. O ganho de tempo na rotina hospitalar dependeria dessas etapas e exigiria uma avaliação própria do fluxo de trabalho.

A literatura oferece exemplos de detecção de instrumentos em condições distintas. Deol *et al.* (2024) avaliaram uma abordagem baseada em YOLOv9 com imagens contendo combinações de instrumentos, inclusive sobreposição e cenas com até 34 objetos. Esse tipo de cenário evidencia a importância de avaliar conjuntos mais densos. Contudo, diferenças no número de categorias, nas imagens, nas divisões dos dados e no protocolo impedem interpretar os valores de desempenho dos dois estudos como uma comparação direta de superioridade entre modelos.

A separação de imagens relacionadas entre treino, validação e teste também interfere na confiabilidade da avaliação. Kapoor e Narayanan (2023) discutem como o vazamento de informação pode produzir estimativas excessivamente favoráveis em pesquisas com aprendizado de máquina. Nesta pesquisa, foram empregados agrupamentos e verificações de similaridade para reduzir esse risco.

Esses procedimentos, porém, não demonstram independência completa entre todas as sessões de aquisição nem eliminam semelhanças que possam ter permanecido entre fotografias. Uma avaliação posterior com novas sessões de captura constitui uma forma importante de examinar essa limitação.

Outro limite é que as sete categorias gerais abrangem instrumentos diferentes. O bom resultado de pinças ou tesouras não informa se o modelo consegue distinguir instrumentos próximos dentro desses grupos. Da mesma forma, o experimento não permite comparar o YOLO26n com variantes maiores ou atribuir seu desempenho a uma escolha isolada de treinamento, pois essas comparações não integram os resultados apresentados. A configuração de execução determinística também encontrou uma operação sem implementação determinística no dispositivo MPS; portanto, a fixação da semente não assegura reprodução numérica idêntica de todas as etapas.

Os resultados sustentam uma viabilidade técnica inicial da detecção e da contagem por categorias gerais nas condições examinadas, especialmente em imagens com um instrumento e nas fotografias hospitalares representadas no teste. Essa conclusão é mais restrita do que afirmar que o sistema está pronto para conferir uma caixa cirúrgica completa. A redução do acerto nas cenas com vários objetos, a cobertura desigual das categorias e as falhas observadas em instrumentos próximos mostram a necessidade de ampliar a avaliação antes de propor seu uso como apoio à rotina. Assim, a principal contribuição desta etapa é demonstrar o potencial da abordagem e identificar, com dados de detecção e contagem, as condições que ainda exigem melhoria.

5 CONCLUSÃO

Este trabalho avaliou a viabilidade técnica da detecção e da contagem automática de instrumentos cirúrgicos por visão computacional, considerando o apoio à conferência no expurgo e no preparo de caixas cirúrgicas. Para isso, foi organizada uma base com imagens de fontes públicas e fotografias do HU-UEL, seguida de treinamento e avaliação do modelo YOLO26n em sete categorias gerais. O estudo concentrou-se em instrumentos selecionados da caixa de apendicectomia e em sua representação por fotografias, sem abranger a implantação de um sistema na rotina hospitalar.

A preparação dos dados constituiu uma parte importante da pesquisa. A reunião de fontes diferentes exigiu revisar imagens, conferir anotações, padronizar categorias e identificar repetições. A base consolidada reuniu 10.327 imagens e 12.714 objetos anotados, distribuídos entre treinamento, validação e teste. Esse processo permitiu construir um conjunto compatível com a tarefa proposta e evidenciou que a qualidade da avaliação depende também das referências utilizadas, não apenas do modelo escolhido.

No conjunto de teste, composto por 1.008 imagens e 1.377 objetos de referência, o modelo alcançou mAP@0,50 de 98,06% e mAP@0,50:0,95 de 86,73%. Com o limiar de confiança definido na validação, a contagem total coincidiu com a referência em 96,43% das imagens, enquanto a quantidade de todas as categorias esteve simultaneamente correta em 95,63%. O erro absoluto médio da contagem total foi de 0,0536 objeto por imagem. Esses resultados mostram que a abordagem conseguiu localizar e contar os instrumentos com resultados favoráveis em grande parte das condições representadas no teste.

Entretanto, o desempenho não foi uniforme. Nas imagens com um objeto, o acerto da contagem total foi de 99,29%, diminuindo para 84,31% nas cenas com dois ou três e para 78,43% naquelas com quatro ou mais. Como a maior parte do teste contém instrumentos isolados, o resultado global não deve ser interpretado como demonstração de desempenho equivalente em caixas completas. A revisão visual também identificou dificuldades com instrumentos próximos ou sobrepostos e com objetos de aparência semelhante, incluindo confusões entre cabos de bisturi e lâminas.

Os resultados das fotografias do HU-UEL foram favoráveis, mas também apresentam limites de cobertura. Algumas categorias possuem poucos exemplos de teste, e os cabos de bisturi não estão representados por imagens hospitalares nesse conjunto. A presença de fotografias obtidas em condições semelhantes também restringe a generalização para novas sessões de captura. Por isso, não

é possível estender automaticamente os resultados a todos os instrumentos, ambientes ou disposições que poderiam ocorrer na prática.

Quanto ao processamento, o treinamento foi concluído em aproximadamente 8 horas e 43 minutos no Mac mini M4 com 16 GB de memória. Nas 50 chamadas completas medidas após o aquecimento, o tempo médio foi de 29,24 ms por imagem. Essa duração indica que o processamento das fotografias foi rápido no equipamento utilizado, mas não representa o tempo de uma conferência hospitalar completa, que também envolve organização dos materiais, captura da imagem e verificação das respostas.

Considerando essas evidências, o objetivo de avaliar a viabilidade técnica foi alcançado: o experimento demonstrou potencial para apoiar a contagem por categorias gerais e permitiu identificar condições em que o desempenho diminui. Não foi demonstrada, contudo, a adequação do modelo para substituir a conferência profissional, reconhecer todos os tipos específicos de instrumentos ou assegurar a ausência de materiais retidos no paciente. A contribuição do estudo está na base organizada, no procedimento de avaliação e na identificação dos limites que devem orientar uma possível continuidade.

Como trabalhos futuros, destacam-se a ampliação das fotografias de bandejas com vários instrumentos, a avaliação em novas sessões de captura e o reforço das categorias menos representadas no ambiente hospitalar. Também poderão ser investigados o reconhecimento de instrumentos específicos e o uso de uma interface que apresente as contagens para conferência pelos profissionais. Essas etapas permitiriam aproximar a avaliação experimental das necessidades do serviço e examinar se o potencial observado se mantém em condições mais diversas de utilização.

REFERÊNCIAS

BRASIL. MINISTÉRIO DA SAÚDE. **Documento de referência para o Programa Nacional de Segurança do Paciente**. Brasília, DF: Ministério da Saúde, 2014. 40 p. ISBN 978-85-334-2130-1. Disponível em: https://bvsms.saude.gov.br/bvs/publicacoes/documento_referencia_programa_nacional_seguranca.pdf. Acesso em: 30 out. 2026.

DEOL, Ekamjit S.; HENNING, Grant; BASOURAKOS, Spyridon; VASDEV, Ranveer M. S.; SHARMA, Vidit; KAVOUSSI, Nicholas L.; KARNES, R. Jeffrey; LEIBOVICH, Bradley C.; BOORJIAN, Stephen A.; KHANNA, Abhinav. Artificial intelligence model for automated surgical instrument detection and counting: an experimental proof-of-concept study. **Patient Safety in Surgery**, v. 18, 24, 2024. DOI: 10.1186/s13037-024-00406-y. Disponível em: https://link.springer.com/article/10.1186/s13037-024-00406-y. Acesso em: 1 nov. 2026.

FREITAS, Patrícia Scotini; MENDES, Karina Dal Sasso; GALVÃO, Cristina Maria. Processo de contagem cirúrgica: evidências para a segurança do paciente. **Revista Gaúcha de Enfermagem**, v. 37, n. 4, e66877, 2016. DOI: 10.1590/1983-1447.2016.04.66877. Disponível em: https://www.scielo.br/j/rgenf/a/r3t9YfDf5vSzD4PDNmMBHHL/?lang=pt. Acesso em: 1 nov. 2026.

GAWANDE, Atul A.; STUDDERT, David M.; ORAV, E. John; BRENNAN, Troyen A.; ZINNER, Michael J. Risk Factors for Retained Instruments and Sponges after Surgery. **The New England Journal of Medicine**, v. 348, n. 3, p. 229–235, 2003. DOI: 10.1056/NEJMsa021721. Disponível em: https://doi.org/10.1056/NEJMsa021721. Acesso em: 1 nov. 2026.

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. **Deep Learning**. Cambridge, MA: MIT Press, 2016. Disponível em: https://www.deeplearningbook.org/. Acesso em: 31 out. 2026.

JIANG, Kaile; PAN, Shuwan; YANG, Luxuan; YU, Jie; LIN, Yuanda; WANG, Huaiqian. Surgical Instrument Recognition Based on Improved YOLOv5. **Applied Sciences**, Basel, v. 13, n. 21, 11709, 2023. DOI: 10.3390/app132111709. Disponível em: https://www.mdpi.com/2076-3417/13/21/11709. Acesso em: 30 out. 2026.

JOCHER, Glenn; QIU, Jing; LIU, Mengyu; LYU, Shuai; AKYON, Fatih Cagatay; KALFAOGLU, Muhammet Esat. **Ultralytics YOLO26: Unified Real-Time End-to-End Vision Models**. Preprint. Versão 1. arXiv. 2 jun. 2026. DOI: 10.48550/arXiv.2606.03748. Disponível em: https://arxiv.org/abs/2606.03748v1. Acesso em: 31 out. 2026.

KAPOOR, Sayash; NARAYANAN, Arvind. Leakage and the reproducibility crisis in machine-learning-based science. **Patterns**, v. 4, n. 9, 100804, 2023. DOI: 10.1016/j.patter.2023.100804. Disponível em: https://doi.org/10.1016/j.patter.2023.100804. Acesso em: 31 out. 2026.

LECUN, Yann; BENGIO, Yoshua; HINTON, Geoffrey. Deep learning. **Nature**, v. 521, n. 7553, p. 436–444, 2015. DOI: 10.1038/nature14539. Disponível em: https://www.nature.com/articles/nature14539. Acesso em: 1 nov. 2026.

LOSHCHILOV, Ilya; HUTTER, Frank. Decoupled Weight Decay Regularization. *In:* INTERNATIONAL Conference on Learning Representations. [*S. l.: s. n.*], 2019. Versão dos autores do artigo publicado na ICLR 2019. Disponível em: https://arxiv.org/abs/1711.05101v3. Acesso em: 31 out. 2026.

MORETO, Suellen Louro. **Desenvolvimento de protótipo para contagem e rastreabilidade de instrumental cirúrgico com visão computacional**. 2025. Dissertação (Mestrado em Enfermagem) – Universidade Estadual de Londrina, Londrina.

OPENCV. **Image Gradients**. Documentação da versão 4.13.0. Disponível em: https://docs.opencv.org/4.13.0/d5/d0f/tutorial_py_gradients.html. Acesso em: 1 nov. 2026.

OPENCV. **Smoothing Images**. Documentação da versão 4.13.0. Disponível em: https://docs.opencv.org/4.13.0/d4/d13/tutorial_py_filtering.html. Acesso em: 1 nov. 2026.

ORGANIZAÇÃO MUNDIAL DA SAÚDE. **Segundo desafio global para a segurança do paciente: cirurgias seguras salvam vidas (orientações para cirurgia segura da OMS)**. Tradução: Marcela Sánchez Nilo e Irma Angélica Durán. Rio de Janeiro: Organização Pan-Americana da Saúde, Ministério da Saúde e Agência Nacional de Vigilância Sanitária, 2009. 211 p. ISBN 978-85-87943-97-2. Disponível em: https://bvsms.saude.gov.br/bvs/publicacoes/seguranca_paciente_cirurgias_seguras_salvam_vidas.pdf. Acesso em: 30 out. 2026.

PADILLA, Rafael; PASSOS, Wesley L.; DIAS, Thadeu L. B.; NETTO, Sergio L.; SILVA, Eduardo A. B. da. A Comparative Analysis of Object Detection Metrics with a Companion Open-Source Toolkit. **Electronics**, Basel, v. 10, n. 3, 279, 2021. DOI: 10.3390/electronics10030279. Disponível em: https://www.mdpi.com/2079-9292/10/3/279. Acesso em: 31 out. 2026.

PYTORCH. **Reproducibility**. Documentação da versão 2.15. Disponível em: https://docs.pytorch.org/docs/2.15/notes/randomness.html. Acesso em: 1 nov. 2026.

PYTORCH. **Transfer Learning for Computer Vision Tutorial**. Disponível em: https://docs.pytorch.org/tutorials/beginner/transfer_learning_tutorial.html. Acesso em: 1 nov. 2026.

RAN, Boping; HUANG, Bo; LIANG, Shunpan; HOU, Yulei. Surgical Instrument Detection Algorithm Based on Improved YOLOv7x. **Sensors**, Basel, v. 23, n. 11, 5037, 2023. DOI: 10.3390/s23115037. Disponível em: https://www.mdpi.com/1424-8220/23/11/5037. Acesso em: 30 out. 2026.

REDMON, Joseph; DIVVALA, Santosh; GIRSHICK, Ross; FARHADI, Ali. You Only Look Once: Unified, Real-Time Object Detection. *In:* IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2016, Las Vegas. **Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition**. Las Vegas: IEEE, 2016. p. 779–788. Disponível em: https://openaccess.thecvf.com/content_cvpr_2016/html/Redmon_You_Only_Look_CVPR_2016_paper.html. Acesso em: 30 out. 2026.

REN, Shaoqing; HE, Kaiming; GIRSHICK, Ross; SUN, Jian. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks. *In:* ADVANCES in Neural Information Processing Systems. [*S. l.*]: Curran Associates, Inc., 2015. v. 28. Disponível em: https://proceedings.neurips.cc/paper/2015/hash/14bfa6bb14875e45bba028a21ed38046-Abstract.html. Acesso em: 1 nov. 2026.

ULTRALYTICS. **Data Augmentation using Ultralytics YOLO**. Documentação técnica atualizável, sem data de publicação identificada. Disponível em: https://docs.ultralytics.com/guides/yolo-data-augmentation/. Acesso em: 31 out. 2026.

ULTRALYTICS. **Model Training with Ultralytics YOLO**. Documentação técnica atualizável, sem data de publicação identificada. Disponível em: https://docs.ultralytics.com/modes/train/. Acesso em: 31 out. 2026.

ULTRALYTICS. **Model Validation with Ultralytics YOLO**. Disponível em: https://docs.ultralytics.com/modes/val/. Acesso em: 1 nov. 2026.

ULTRALYTICS. **Ultralytics YOLO26**. Disponível em: https://docs.ultralytics.com/models/yolo26/. Acesso em: 1 nov. 2026.