

UNIVERSIDADE ESTADUAL DO NORTE DO PARANÁ
***CAMPUS* LUIZ MENEGHEL**
CENTRO DE CIÊNCIAS TECNOLÓGICAS
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

Nome Completo Estudante

Título: subtítulo (quando houver)

BANDEIRANTES
ANO

Nome Completo do Estudante

Título: subtítulo (quando houver)

Área de Concentração:
Linha de Pesquisa:
Orientador(a):

BANDEIRANTES
ANO

Ficha catalográfica

Nome Completo Estudante

Título: subtítulo (quando houver)

Trabalho de Conclusão de Curso apresentado ao Curso de Bacharelado em Ciência da Computação da Universidade Estadual do Norte do Paraná, *Campus* Luiz Meneghel, Centro de Ciências Tecnológicas, como requisito parcial para obtenção do título de Bacharel em Ciência da Computação.

Área de Concentração:

Linha de Pesquisa:

Orientador(a):

Banca Examinadora

Nome do/a Professor/a (Orientador/a)
Universidade Estadual do Norte do Paraná (UENP)
UENP | *Campus* Luiz Meneghel

Nome do/a Professor/a (membro interno)
Universidade Estadual do Norte do Paraná (UENP)
UENP | *Campus* Luiz Meneghel

Nome do/a Professor/a (membro externo)
Nome da Universidade (NDU)
Sigla da Universidade | Lotação do docente

Bandeirantes, 00 do MÊS DE ano.

Dedico este trabalho a... *(opcional)*

Agradecimentos

Para o desenvolvimento desta pesquisa, eu agradeço a... *(opcional)*

Epígrafe *(opcional)*

Exemplo de epígrafe:

"A verdadeira viagem de descobrimento
não consiste em procurar novas
paisagens, mas em ter novos olhos"

– **Marcel Proust**

SOBRENOME, Nome Completo com. **Título**: subtítulo (quando houver). Ano. 8 f. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) – Centro de Ciências Tecnológicas, Universidade Estadual do Norte do Paraná, Bandeirantes, Ano.

Resumo

Sugere-se que no resumo contenha uma breve introdução/contextualização da pesquisa, apresentando suscintamente seus objetivos, os resultados obtidos e algumas considerações ou conclusões acerca da pesquisa. Quantidade de caracteres sugeridos: entre 150 e 500.

Norma de referência: ABNT NBR 6028 – Resumo, resenha e recensão (2021).

Palavras-chave: Palavra 1. Palavra 2. Palavra 3. Palavra 4. Palavra 5.

SURNAME, Full Name. **Title**: subtitle (if applicable). Year. 8 p. Undergraduate Thesis (Bachelor's in Computer Science) – Center of Technological Sciences, Northern Paraná State University, Bandeirantes, Year

Absctract

It is suggested that the summary contains a brief introduction/contextualization of the research, briefly presenting its objectives, the results obtained and some considerations or conclusions about the research. Number of suggested characters: between 150 and 500.

Reference standard: ABNT NBR 6028 – Summary, review and review (2021).

Keywords: Word 1. Word 2. Word 3. Word 4. Word 5.

Lista de ilustrações *(opcional)*

Exemplos:

Figura 1 – Título da figura..... 1
Figura 2 – Título da figura..... 2

Lista de tabelas *(opcional)*

Exemplos:

Tabela 1 – Título da figura..... 1
Tabela 2 – Título da figura..... 2

Lista de abreviaturas e siglas *(opcional)*

Exemplos:

ABRV	Associação Brasileira de Radiologia Veterinária
CAPES	Coordenadoria de Aperfeiçoamento de Pessoal de Nível Superior
CNPq	Conselho Nacional de Desenvolvimento Científico e Tecnológico
CRBio-7	Conselho Regional de Biologia da 7ª Região (Paraná)
CREA-PR	Conselho Regional de Engenharia e Agronomia do Paraná
COREN-PR	Conselho Regional de Enfermagem do Paraná
IBGE	Instituto Brasileiro de Geografia e Estatística
SBC	Sociedade Brasileira de Computação

Lista de símbolos *(opcional)*

Exemplos:

$\forall$ Quantificação universal
$\exists$ Quantificação existencial
$\emptyset$ Conjunto nulo ou vazio
$\cup$ União teórica de conjuntos
$\surd$ Raiz quadrada
∞ Infinito
π Pi
$\sum$ Somatório

SUMÁRIO

O sumário é o elemento que sintetiza e direciona os conteúdos contidos em determinado trabalho. *Exemplo:*

1 INTRODUÇÃO..... 14
1.1 Aspecto introdutório A (quando houver)..... 14
1.2 Aspecto metodológico..... 14
1.3 Aspecto introdutório C (quando houver)..... 14

2 DESENVOLVIMENTO..... 15
2.1 Tópico do desenvolvimento A.....
2.1.1 Tópico avançado A (quando houver).....
2.1.2 Tópico avançado B (quando houver).....
2.1.3 Tópico avançado C (quando houver).....
2.2 Tópico do desenvolvimento B.....
2.2.1 Tópico avançado A (quando houver).....
2.2.2 Tópico avançado B (quando houver).....
2.2.3 Tópico avançado C (quando houver).....
2.3 Tópico do desenvolvimento C.....
2.3.1 Tópico avançado A (quando houver).....
2.3.2 Tópico avançado B (quando houver)..... 16
2.3.3 Tópico avançado C (quando houver).....

3 CONCLUSÃO.....

REFERÊNCIAS.....

1 INTRODUÇÃO

Antes que uma cirurgia seja realizada, os instrumentos necessários precisam estar disponíveis, organizados e conferidos. Após o uso, esses materiais retornam a um fluxo de recebimento, limpeza, preparo e esterilização que permite sua utilização em novos procedimentos. Nesse percurso, reconhecer cada peça e verificar as quantidades são tarefas que conectam o trabalho de diferentes profissionais. No Hospital Universitário da Universidade Estadual de Londrina (HU-UEL), o estudo de Moreto (2025) descreve conferências tanto na recepção do material utilizado quanto no preparo dos conjuntos que serão encaminhados à esterilização.

Esses conjuntos são frequentemente organizados em caixas cirúrgicas: recipientes que reúnem instrumentos selecionados para atender a determinado procedimento ou especialidade. Cada caixa possui uma composição de tipos e quantidades definida pelo serviço. Assim, uma caixa destinada a uma cirurgia cardíaca pode reunir instrumentos diferentes daqueles utilizados em neurocirurgia ou em uma apendicectomia, procedimento de retirada do apêndice. A caixa de apendicectomia adotada como referência nesta pesquisa delimita os objetos de interesse, entre eles pinças, tesouras e afastadores. Essa delimitação permite estudar um conjunto concreto de materiais, associado a uma necessidade hospitalar, em vez de tentar reconhecer indiscriminadamente todos os instrumentos existentes.

A conferência desses materiais tem importância tanto para a organização do serviço quanto para a segurança do cuidado. Durante a cirurgia, a contagem de instrumentos, compressas e agulhas integra as medidas recomendadas pela Organização Mundial da Saúde para prevenir que materiais permaneçam inadvertidamente no paciente (Organização Mundial da Saúde, 2009). No Brasil, a segurança cirúrgica também faz parte das ações do Programa Nacional de Segurança do Paciente (Brasil, 2014). A conferência realizada no processamento dos instrumentos e a contagem durante a operação, contudo, correspondem a momentos diferentes. O presente estudo se concentra no primeiro contexto: o apoio à identificação e à contagem de instrumentos fora do paciente, a partir de fotografias.

Esse contexto envolve o Centro de Material e Esterilização (CME), setor responsável pelo processamento dos materiais utilizados na assistência. No fluxo descrito por Moreto (2025), o expurgo recebe os instrumentos utilizados, que passam pela conferência e pela limpeza; na área de preparo, outra conferência acompanha a organização e o fechamento das caixas. O registro individual das peças nesses pontos evidencia uma tarefa repetitiva que motiva a investigação de recur-

sos de apoio. Nesta pesquisa, a aplicação é pretendida em ambos os ambientes, e as fotografias hospitalares foram obtidas tanto no expurgo quanto na área de preparo. A questão é saber se um computador pode extrair de uma imagem informações suficientemente confiáveis sobre quais instrumentos estão presentes e em que quantidade.

A área da computação que estuda a obtenção de informações a partir de imagens é chamada de visão computacional. Suas aplicações incluem o reconhecimento de objetos e a análise de imagens médicas, entre outras tarefas em que informações visuais precisam ser interpretadas. Uma das abordagens utilizadas é o aprendizado de máquina: em vez de escrever uma regra para cada possível aparência de um objeto, são apresentados exemplos a um modelo computacional, que ajusta seu funcionamento para reconhecer padrões. As redes neurais são modelos formados por operações interligadas, com valores ajustáveis durante esse aprendizado. Quando utilizam múltiplas camadas de processamento para aprender representações dos dados, integram o campo do aprendizado profundo (Goodfellow; Bengio; Courville, 2016).

Para a conferência de instrumentos, não basta reconhecer que uma fotografia contém uma pinça. É necessário localizar cada objeto individual, inclusive quando vários aparecem juntos. Essa tarefa é chamada de detecção de objetos. Uma forma usual de apresentar seu resultado é desenhar um retângulo ao redor de cada objeto e associá-lo a uma classe, isto é, à categoria que o identifica. O retângulo recebe o nome de caixa delimitadora. Quando cada instrumento é localizado uma única vez e recebe a identificação correta, essas detecções podem ser somadas para obter a quantidade total e a quantidade por categoria.

A Figura 1 exemplifica essa representação em uma fotografia do conjunto hospitalar. A marcação foi realizada para indicar o objeto de interesse e sua categoria.

Para aprender a realizar essa tarefa, o modelo recebe imagens acompanhadas de marcações que indicam a posição e a classe dos objetos. Essas marcações são as anotações de referência: exemplos revisados que orientam o aprendizado e permitem, posteriormente, comparar a resposta do modelo com os objetos efetivamente presentes na imagem. A qualidade desse material importa porque uma caixa mal posicionada, uma classe incorreta ou um instrumento não marcado pode comprometer o aprendizado e a avaliação. Por isso, preparar uma base de imagens envolve selecionar os exemplos, conferir as marcações e organizar nomes e categorias antes do treinamento.

Entre os modelos desenvolvidos para detectar objetos estão o Faster R-CNN e os modelos da família *You Only Look Once* (YOLO). No Faster R-CNN, o processamento inclui a proposta de regiões que podem conter objetos e a análise

Figura 1: Exemplo de instrumento identificado por uma caixa delimitadora



Fonte: elaboração própria, a partir de fotografia do conjunto HU-UEL (2026).

dessas regiões para classificá-los e ajustar sua localização (Ren *et al.*, 2015). A proposta original do YOLO reúne a estimativa das posições e das classes em um processamento da imagem completa, com ênfase na rapidez da detecção (Redmon *et al.*, 2016). Essas abordagens oferecem caminhos distintos para o mesmo problema; a escolha entre elas depende da aplicação, dos dados e dos recursos disponíveis.

Neste estudo, foi selecionada a família YOLO por combinar a localização e a identificação dos objetos em uma solução que permite construir a contagem a partir das detecções. A escolha também encontra apoio em pesquisas sobre instrumentos cirúrgicos, como as de Ran *et al.* (2023) e Jiang *et al.* (2023), que investigaram adaptações de versões anteriores dessa família. Seus resultados motivam a investigação, mas não antecipam o desempenho nas fotografias utilizadas aqui. O modelo adotado é o YOLO26n, variante compacta da família YOLO26. Essa família disponibiliza variantes de diferentes tamanhos, identificadas por n, s, m, l e x, com diferentes necessidades de processamento (Ultralytics, 2026d). A opção inicial pela variante n considera a execução do treinamento no equipamento disponível, mantendo a qualidade das detecções como uma questão a ser avaliada experimentalmente.

Essa avaliação exige separar o aprendizado da verificação de seus resultados. As imagens de treinamento são utilizadas para ajustar o modelo; as de validação permitem acompanhar o aprendizado e orientar escolhas de configuração; e as de teste são reservadas para avaliar o desempenho após essas escolhas. Também é necessário preparar as imagens para a entrada da rede. Fotografias de dimensões diferentes são redimensionadas e, quando necessário, recebem

preenchimento nas bordas para se adequar ao tamanho de processamento adotado. Esse procedimento facilita a execução computacional, mas pode reduzir detalhes relevantes para distinguir instrumentos semelhantes. As decisões de preparação e avaliação, portanto, fazem parte do problema investigado, e não apenas da execução do programa.

1.1 Problema de pesquisa e justificativa

A possibilidade de contar instrumentos por imagens é atraente, mas seu uso depende de reconhecer os objetos apesar das variações presentes nas fotografias. Instrumentos metálicos podem produzir reflexos; peças diferentes podem ter formatos semelhantes; e um objeto pode esconder parte de outro. Essas condições dificultam a localização e a identificação, como discutido nos estudos de Ran *et al.* (2023) e Jiang *et al.* (2023). Por isso, a existência de um detector capaz de reconhecer objetos em outras aplicações não é suficiente para concluir que ele atenderá à conferência pretendida no hospital.

A pergunta que orienta esta pesquisa é: em que medida um modelo da família YOLO é tecnicamente viável para identificar e contar instrumentos selecionados da caixa de apendicectomia, nas condições representadas pelas fotografias de avaliação, visando ao apoio à conferência no expurgo e no preparo de caixas cirúrgicas?

Neste contexto, avaliar a viabilidade significa examinar a qualidade das detecções, os erros de contagem, os recursos computacionais empregados e as situações em que o modelo apresenta dificuldades. Acertar somente o total de objetos não é suficiente. Em uma imagem com dois instrumentos, por exemplo, o modelo pode deixar de reconhecer um deles e marcar indevidamente outra região, produzindo duas detecções apesar do erro. Também pode localizar ambos e trocar suas classes. A análise precisa, portanto, considerar tanto o total quanto a identificação e a localização dos objetos que deram origem à contagem. Os indicadores e os procedimentos utilizados para essa análise são apresentados na metodologia.

A contribuição pretendida é oferecer evidências sobre as possibilidades e os limites dessa abordagem em um conjunto relacionado à rotina do HU-UEL. Para isso, foram reunidas imagens de bases disponíveis na internet e fotografias hospitalares, com revisão dos objetos e de suas anotações. A combinação dessas fontes fornece exemplos para o treinamento, enquanto a avaliação deve mostrar até que ponto o modelo consegue lidar com imagens que não foram utilizadas para ajustá-lo. O estudo trata a contagem automática como um possível recurso de apoio à conferência profissional, sem pressupor que o desempenho

em fotografias demonstre, por si só, redução de acidentes ou prontidão para uso assistencial.

1.2 Objetivos

O objetivo geral é avaliar a viabilidade técnica da identificação e da contagem automática de instrumentos selecionados da caixa de apendicectomia, por meio de um modelo da família YOLO, visando ao apoio à conferência no expurgo e no preparo de caixas cirúrgicas.

Para alcançar esse objetivo, foram definidos os seguintes objetivos específicos:

a) organizar e revisar as imagens da internet e do HU-UEL, padronizando as categorias e as anotações dos objetos;
b) preparar os conjuntos de treinamento, validação e teste, com controle de duplicatas e agrupamento das imagens relacionadas identificadas;
c) treinar um modelo YOLO para localizar e identificar os instrumentos nas categorias gerais adotadas;
d) avaliar a detecção e a contagem, considerando os resultados totais, os resultados por categoria e a frequência de imagens com contagem correta;
e) analisar os erros e os recursos computacionais empregados, identificando condições favoráveis e limitações para a aplicação pretendida.

1.3 Delimitação do estudo

O experimento principal utiliza fotografias estáticas e sete categorias gerais: pinças, tesouras, afastadores, porta-agulhas, cabos de bisturi, bicos de aspiração e cúpulas. As cúpulas são recipientes que também integram a contagem dos objetos de interesse. A base preserva, adicionalmente, a identificação específica dos instrumentos, incluindo variantes retas e curvas quando previstas, para permitir análises ou experimentos posteriores. A correspondência entre os instrumentos e as categorias utilizadas no treinamento é apresentada na metodologia. Diferenças de tamanho não originam classes distintas.

A seleção foi limitada aos objetos de interesse para os quais se obtiveram imagens. A pinça Collin coração não integra a configuração atual por ausência de exemplos. Além disso, as pinças anatômicas e os cabos de bisturi estão representados somente por imagens da internet na base consolidada. Essas diferenças de cobertura devem ser consideradas ao interpretar os resultados, especialmente quando se discute a aplicação no ambiente hospitalar.

As fotografias incluem instrumentos isolados, alguns conjuntos com vários

objetos e bandejas vazias. Embora tenham sido obtidas imagens nos dois ambientes de aplicação pretendidos, o estudo não equivale a uma implantação do sistema no fluxo de trabalho. A avaliação se refere aos objetos visíveis nas fotografias e às condições representadas no conjunto de teste. A conferência integral de uma caixa, o reconhecimento de materiais totalmente encobertos e a demonstração de benefícios durante o uso hospitalar exigem avaliações próprias. Dessa forma, a pesquisa busca estabelecer uma base experimental para decidir como a contagem por visão computacional pode avançar em direção à aplicação pretendida.

2 FUNDAMENTAÇÃO TEÓRICA

Reconhecer uma tesoura em uma fotografia parece uma tarefa simples para quem conhece o instrumento. Para um computador, entretanto, a imagem é inicialmente um conjunto de números. Transformar esses números em informações como a posição, o tipo e a quantidade de objetos exige um método de análise. Este capítulo apresenta esse percurso: começa pelas relações entre inteligência artificial e aprendizado, explica como imagens podem ser processadas por redes neurais e chega aos critérios utilizados para avaliar a detecção e a contagem. Os exemplos numéricos e os esquemas são didáticos; os resultados do experimento são tratados em capítulo próprio.

2.1 Inteligência artificial, aprendizado e visão computacional

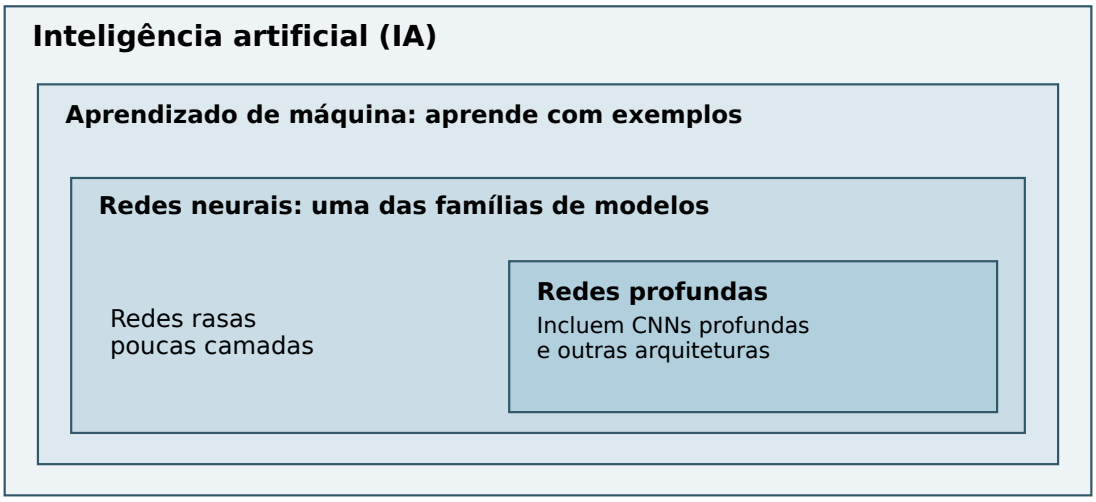
A inteligência artificial (IA) reúne métodos destinados a realizar tarefas que envolvem capacidades como reconhecer padrões e tomar decisões. Uma de suas abordagens é o aprendizado de máquina, também chamado de *machine learning* (ML): o sistema ajusta um modelo a partir de dados, em vez de depender somente de regras definidas manualmente. Uma rede neural artificial é uma família de modelos que combina operações numéricas interligadas. Seus parâmetros, entre eles os pesos das conexões, determinam como as informações são transformadas e podem ser ajustados durante o aprendizado (Goodfellow; Bengio; Courville, 2016).

Aprendizado profundo, ou *deep learning* (DL), refere-se ao aprendizado de representações por múltiplas camadas de processamento. A saída de uma camada fornece informações para as seguintes, permitindo combinar padrões mais simples em representações mais complexas (LeCun; Bengio; Hinton, 2015). Não se trata de considerar que a máquina compreende uma fotografia da mesma maneira que uma pessoa: ela realiza operações aprendidas com os exemplos e pode falhar diante de condições diferentes daquelas representadas nos dados.

Esses conceitos se relacionam, mas não são sinônimos. O aprendizado de máquina integra o campo da IA; redes neurais são uma das famílias de modelos de aprendizado; e existem redes rasas e profundas. Portanto, nem toda rede neural pertence ao aprendizado profundo. A Figura 2 apresenta um recorte dessas relações. As redes neurais convolucionais, discutidas adiante, podem ser organizadas em arquiteturas profundas para analisar imagens.

A visão computacional é a área voltada à obtenção de informações a partir de imagens e vídeos. Ela define o tipo de problema a resolver, como localizar um objeto, enquanto o aprendizado profundo oferece uma das maneiras de enfrentá-

Figura 2: Relações entre conceitos de aprendizado utilizados nesta pesquisa



Fonte: elaboração própria, com base em Goodfellow, Bengio e Courville (2016) e LeCun, Bengio e Hinton (2015).

lo. Também há métodos de visão computacional que utilizam operações de processamento de imagens sem uma rede treinada. Essa distinção ajuda a compreender a proposta desta pesquisa: o problema é detectar e contar instrumentos; a abordagem selecionada utiliza uma rede neural treinada para reconhecer seus padrões visuais.

Nesse contexto, uma característica visual pode ser a presença de uma borda, uma textura ou uma combinação de formas. Em instrumentos cirúrgicos, anéis, hastes, curvaturas e extremidades fornecem pistas relevantes. Ao aprender com imagens, porém, o modelo também pode utilizar informações pouco desejáveis, como um fundo associado repetidamente a uma classe. Por isso, ensinar a reconhecer um instrumento exige mais que reunir muitas fotografias: é necessário considerar quais diferenças e semelhanças estão presentes nos exemplos.

2.2 Da imagem digital às características aprendidas

Uma imagem digital pode ser representada por uma grade de elementos chamados pixels. Cada pixel armazena valores relacionados à aparência de uma pequena região da imagem. Em uma representação RGB, há canais correspondentes ao vermelho, ao verde e ao azul; em uma representação em tons de cinza, utiliza-se um valor de intensidade. A resolução indica quantos pixels compõem a

largura e a altura. Uma imagem de 640×640 pixels, por exemplo, possui 409.600 posições nessa grade, antes de considerar seus canais de cor.

Essa representação explica por que a resolução influencia o processamento. Mais pixels podem preservar detalhes, mas também aumentam a quantidade de informação que precisa ser tratada. Os modelos recebem imagens preparadas para um tamanho de entrada definido na configuração. O redimensionamento modifica as dimensões, enquanto o preenchimento com bordas permite ajustar o formato sem necessariamente deformar a proporção do objeto. As caixas de referência precisam acompanhar essas transformações para continuarem posicionadas corretamente.

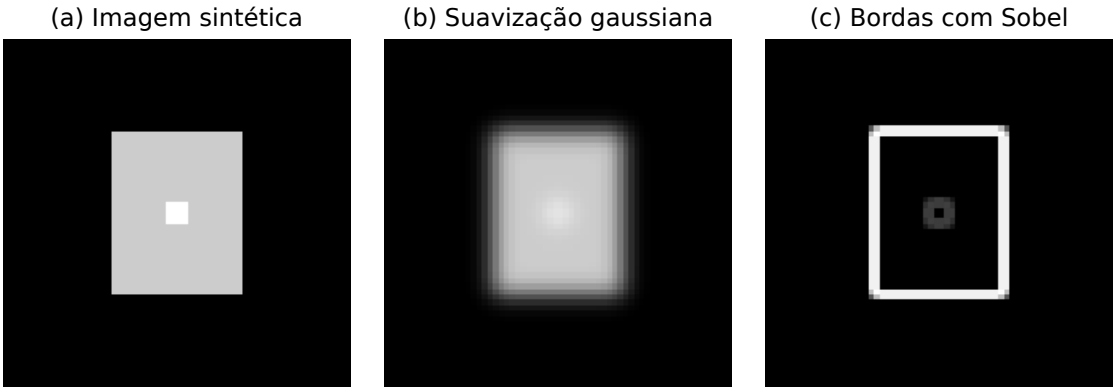
Considere uma fotografia de 2.048×1.536 pixels ajustada proporcionalmente para caber em 640×640. A largura passa a 640 e a altura a 480; o espaço restante pode ser preenchido com bordas. Um detalhe que ocupava dez pixels de largura passa a ocupar aproximadamente três. Esse exemplo mostra por que uma fotografia nítida no arquivo original pode perder informação útil quando apresentada à rede. Aumentar novamente a imagem não recupera automaticamente o detalhe perdido. O tamanho de entrada, portanto, envolve uma escolha entre preservação de informação e custo de processamento.

Uma forma de analisar a grade de pixels é aplicar filtros. Um filtro combina valores de uma pequena vizinhança para produzir uma nova resposta em cada posição. Na suavização por média, por exemplo, uma janela de 3×3 pixels substitui a intensidade central pela média dos nove valores. Isso reduz diferenças locais, mas também pode tornar menos nítidas as bordas. A suavização gaussiana utiliza uma combinação ponderada dos valores próximos, em vez de atribuir a todos a mesma contribuição (OpenCV, 2026b).

Outros filtros realçam mudanças de intensidade. O operador Sobel calcula respostas a variações em direções da imagem, que podem destacar bordas (OpenCV, 2026a). Na Figura 3, a imagem sintética contém uma região clara sobre fundo escuro. A suavização torna sua transição mais gradual; a resposta de bordas destaca as regiões de mudança. Esses filtros fixos são apresentados para explicar a ideia de processamento local, não como etapas adicionais aplicadas às fotografias do experimento.

Nas redes neurais convolucionais, conhecidas pela sigla CNN, do inglês *convolutional neural network*, os filtros têm valores aprendidos durante o treinamento. A aplicação de um filtro em diferentes posições gera um mapa de características: uma nova grade que indica onde o padrão associado ao filtro produz respostas. Diversos filtros geram diferentes mapas, e camadas posteriores combinam essas informações. O compartilhamento dos valores do filtro entre posições

Figura 3: Exemplo didático de suavização e realce de bordas



Fonte: elaboração própria, em imagem sintética, com operações descritas na documentação do OpenCV (OpenCV, 2026b,a).

evita aprender uma operação inteiramente diferente para cada ponto da imagem (Goodfellow; Bengio; Courville, 2016).

As camadas convolucionais são combinadas com outras operações, incluindo funções de ativação, que permitem representar relações não lineares. Em termos intuitivos, a rede não fica limitada a somar sempre as informações da mesma maneira: consegue construir respostas mais complexas a partir dos padrões intermediários. O aprendizado em várias camadas é um dos fundamentos do avanço das redes profundas na análise visual (LeCun; Bengio; Hinton, 2015). Ainda assim, os mapas internos não devem ser interpretados como uma lista garantida de conceitos humanos, como ``dente'', ``anel'' ou ``ponta curva''. Essas são características úteis para explicar o problema, mas não uma descrição previamente conhecida do que cada filtro aprendeu.

2.3 Classificação, detecção e modelos da família YOLO

O tipo de resposta esperado define a tarefa de análise. Na classificação de imagens, o sistema atribui uma categoria, ou um conjunto de categorias, à imagem. Na detecção, localiza cada objeto e informa sua classe. Na segmentação de instâncias, identifica os pixels correspondentes a cada objeto individual. O termo instância significa, nesse caso, um exemplar: duas pinças da mesma classe são duas instâncias. Assim, saber que há pinças em uma fotografia não determina quantas existem nem onde estão; a detecção acrescenta as informações necessárias para a contagem por objeto (Padilla *et al.*, 2021).

Uma caixa delimitadora alinhada aos eixos é um retângulo definido por sua posição, largura e altura. Ela envolve o objeto, mas não acompanha seu contorno. Por isso, uma pinça inclinada pode ter bastante fundo dentro da caixa sem que a

anotação esteja necessariamente incorreta. Já um polígono utilizado na segmentação acompanha o contorno por vários pontos. Sua conversão em caixa utiliza os limites mínimo e máximo nas direções horizontal e vertical, preservando a região envolvente e descartando o detalhamento do contorno.

Quando um instrumento encobre parte de outro, ocorre oclusão. A sobreposição das caixas, entretanto, não comprova que os instrumentos estejam fisicamente sobrepostos: os retângulos podem se cruzar apenas por incluírem áreas de fundo. Da mesma forma, instrumentos empilhados são um caso particular de disposição em que peças ficam sobre outras. Essas distinções são relevantes tanto para anotar quanto para analisar falhas. É preciso reconhecer cada objeto individual visível sem criar uma anotação adicional para cada uma de suas partes.

Para produzir caixas e classes, diferentes detectores organizam o processamento de maneiras distintas. O Faster R-CNN utiliza uma rede de proposta de regiões para indicar áreas potencialmente ocupadas por objetos, que são analisadas para classificação e refinamento das caixas (Ren *et al.*, 2015). A proposta original do YOLO, de Redmon *et al.* (2016), formula a localização e a classificação conjuntamente a partir da imagem completa. O nome *You Only Look Once* expressa essa ideia de uma passagem pela rede para gerar as previsões, em vez de avaliar separadamente uma grande coleção de recortes.

A família YOLO evoluiu desde essa proposta. Em termos gerais, um detector moderno extrai características da imagem, combina informações em diferentes níveis e gera as saídas de localização e classe. A parte responsável por produzir essas saídas é frequentemente chamada de cabeça de detecção. O uso do mesmo nome de família não significa que todas as versões tenham arquitetura ou procedimentos idênticos; a descrição do modelo precisa corresponder à versão efetivamente empregada.

O YOLO26 disponibiliza variantes n, s, m, l e x, associadas a diferentes escalas de tamanho. A variante n é a mais compacta; variantes maiores ampliam a capacidade do modelo e normalmente exigem mais memória e processamento (Ultralytics, 2026d). Capacidade, nesse contexto, está relacionada à quantidade e à organização dos parâmetros que podem ser ajustados. Uma rede maior não corrige automaticamente imagens mal anotadas ou a ausência de exemplos relevantes. A escolha deve considerar o equipamento disponível e o desempenho observado, sem tratar tamanho como garantia de qualidade.

A descrição técnica do YOLO26 também apresenta um caminho de inferência sem uma etapa separada de supressão de não máximos, ou NMS, do inglês *non-maximum suppression* (Jocher *et al.*, 2026). Inferência é o uso do modelo já treinado para analisar uma imagem. Em detectores que utilizam NMS,

essa etapa procura reduzir previsões redundantes sobre um mesmo objeto, considerando suas pontuações e sobreposição. Como o comportamento depende da configuração e da implementação, a avaliação deve registrar o caminho realmente utilizado. Para a contagem, a questão prática é evitar que um único instrumento resulte em várias detecções aceitas.

Além da caixa e da classe, as previsões recebem uma pontuação de confiança, utilizada para selecionar as respostas que serão consideradas. Uma pontuação elevada indica maior confiança segundo o modelo, mas não deve ser tomada automaticamente como probabilidade real de acerto. O limiar de confiança é o valor mínimo exigido para aceitar uma detecção. Escolher esse limiar modifica quais objetos entram na contagem, razão pela qual sua definição precisa ocorrer na validação, antes da avaliação final.

2.4 Treinamento, preparação dos dados e generalização

Na aprendizagem supervisionada, cada exemplo utilizado para ensinar o modelo está associado a uma resposta de referência. Para detectar instrumentos, essa resposta contém as caixas e suas classes. Durante o treinamento, a rede produz previsões, compara-as com as referências e ajusta seus parâmetros. O objetivo é aprender relações que também funcionem em novos exemplos. Essa capacidade de responder adequadamente a dados não utilizados no ajuste é chamada de generalização (Goodfellow; Bengio; Courville, 2016).

A diferença entre previsão e referência é expressa por uma função de perda. Em um detector, podem existir componentes relacionados à localização das caixas e à classificação. A retropropagação calcula como os parâmetros influenciam essa perda; o otimizador utiliza essas informações para atualizá-los. A taxa de aprendizado controla a escala dos ajustes. Atualizações muito grandes podem prejudicar a estabilidade, enquanto atualizações muito pequenas podem tornar o processo lento. Esses elementos fazem parte do procedimento de otimização descrito por Goodfellow, Bengio e Courville (2016).

Os pesos são parâmetros aprendidos; já as configurações escolhidas para conduzir o processo, como taxa de aprendizado, tamanho do lote e limite de épocas, são chamadas de hiperparâmetros. Um lote é um grupo de exemplos processados em uma etapa do treinamento. Uma época corresponde a uma passagem pelo conjunto de treinamento, conforme o procedimento de amostragem utilizado. Por exemplo, uma base com mil imagens, processada em lotes de dez sem descarte de exemplos, resulta em cem lotes por época. Esse cálculo ajuda a relacionar a configuração ao tempo de execução, mas não determina a qualidade do resultado.

Entre os otimizadores está o AdamW, que combina atualização adaptativa dos parâmetros com um procedimento de decaimento de pesos separado dessa atualização (Loshchilov; Hutter, 2019). O decaimento reduz os pesos de forma controlada e participa das estratégias de regularização, utilizadas para limitar ajustes excessivos aos exemplos de treinamento. A escolha de um otimizador é apenas uma parte do experimento: seus valores de configuração e sua interação com os dados também precisam ser considerados.

O treinamento pode começar com pesos pré-treinados, isto é, valores obtidos anteriormente em outra base. Essa estratégia permite aproveitar representações já aprendidas e adaptá-las à nova tarefa, procedimento conhecido como transferência de aprendizagem. O ajuste posterior pode atualizar a rede ou manter parte de seus parâmetros fixos, conforme a configuração (PyTorch, 2026b). Para instrumentos cirúrgicos, reconhecer objetos em uma base genérica constitui um ponto de partida, não uma evidência de que o modelo já distingue as classes selecionadas.

Para verificar o aprendizado, os dados são separados em treinamento, validação e teste. O treinamento ajusta os parâmetros; a validação acompanha o desempenho e orienta escolhas, como a seleção de uma época ou do limiar de confiança; o teste é reservado à avaliação após essas escolhas. Usar o teste repetidamente para selecionar configurações compromete sua independência, pois suas respostas passam a orientar o desenvolvimento (Kapoor; Narayanan, 2023). A validação executada ao fim de uma época, portanto, não deve ser confundida com a avaliação final no conjunto de teste.

Quando o modelo melhora nos dados de treinamento, mas não mantém essa melhora em dados novos, pode estar ocorrendo sobreajuste. A análise das curvas de perda e de validação ajuda a acompanhar esse comportamento, sem que uma oscilação isolada seja suficiente para diagnosticá-lo. A parada antecipada interrompe o treinamento quando o indicador monitorado deixa de melhorar por determinado período, chamado de paciência. Trata-se de uma forma de controle do aprendizado, discutida entre as estratégias de regularização por Goodfellow, Bengio e Courville (2016). O melhor estado salvo durante a execução pode ser diferente daquele produzido na última época.

A independência dos conjuntos também depende de como as fotografias foram obtidas. Uma cópia com outro nome continua representando a mesma cena; um recorte ou uma inversão pode preservar grande parte de seu conteúdo; e fotografias consecutivas podem diferir pouco entre si. Se exemplos fortemente relacionados aparecem no treinamento e no teste, o desempenho pode refletir a familiaridade com aquela captura. Agrupar imagens relacionadas antes da separação reduz esse risco, mas a quantidade de arquivos não deve ser interpretada

automaticamente como quantidade de observações independentes (Kapoor; Narayanan, 2023).

Essa preocupação é especialmente relevante para as imagens hospitalares: variar a posição do instrumento pode acrescentar informação, mas fotografá-lo repetidamente com o mesmo fundo e iluminação não reproduz toda a diversidade de uso. Um identificador calculado a partir dos bytes permite localizar cópias exatas de arquivos. Métodos de similaridade visual podem indicar outras repetições, porém precisam de revisão, pois objetos diferentes também podem se parecer. A limpeza da base deve combinar verificação automática e análise dos casos ambíguos, preservando a correspondência entre cada imagem e suas anotações.

O aumento de dados, ou *data augmentation*, introduz variações nos exemplos de treinamento. Rotações e inversões alteram a orientação; mudanças de escala e deslocamento modificam o enquadramento; ajustes de cor e brilho variam a aparência. O mosaico combina imagens em uma composição, criando novas disposições dos objetos. As anotações precisam ser transformadas junto com as imagens, e a intensidade dessas operações deve preservar exemplos coerentes com a tarefa (Ultralytics, 2026a).

Quando esse aumento ocorre durante o carregamento dos lotes, a base no disco mantém sua quantidade de arquivos. A cada apresentação, uma imagem pode receber uma transformação diferente ou nenhuma transformação, de acordo com as probabilidades configuradas. Assim, afirmar que mil imagens se tornaram dez mil exige especificar o que foi contado: arquivos salvos, apresentações ao modelo ou combinações produzidas. Variações artificiais também não substituem novas fotografias obtidas em condições diferentes. Na avaliação usual, validação e teste recebem a preparação necessária à entrada do modelo, sem as transformações aleatórias utilizadas para diversificar o treinamento.

Outro cuidado é o equilíbrio entre classes e origens. Uma classe pode possuir muitos objetos anotados, mas pouca variedade de cenas; outra pode reunir menos exemplos, porém capturados em condições diversas. Imagens e objetos são unidades diferentes: uma foto com quatro pinças representa uma imagem e quatro anotações. Além disso, exemplos da internet e do hospital podem diferir em fundo, iluminação e enquadramento. Por esse motivo, a distribuição por classe e por origem ajuda a interpretar o que o modelo teve oportunidade de aprender e quais condições estão pouco representadas.

Por fim, a repetição de um experimento depende do registro de suas configurações. A semente inicializa geradores de números pseudoaleatórios, utilizados em operações como a ordem dos exemplos e as transformações. Fixá-la auxilia a repetibilidade, mas não garante resultados idênticos em qualquer dispo-

sitivo ou versão de software. A documentação do PyTorch ressalta que a disponibilidade de operações determinísticas e as diferenças de plataforma também influenciam esse comportamento (PyTorch, 2026a). A metodologia precisa, portanto, registrar tanto a configuração quanto as limitações efetivamente observadas.

2.5 Pesquisas relacionadas à conferência de instrumentos

A avaliação computacional precisa ser relacionada ao problema que motiva a pesquisa. No contexto brasileiro, Freitas, Mendes e Galvão (2016) analisaram a contagem cirúrgica a partir dos relatos de 55 enfermeiros. O estudo examinou como, quando e por quem a contagem era realizada e contribui para compreender a organização desse processo. Seu foco é a prática de conferência, não a avaliação de um detector. Essa distinção é útil porque melhorar o reconhecimento em imagens e melhorar um processo assistencial são objetivos relacionados, mas exigem evidências diferentes.

No contexto do HU-UEL, Moreto (2025) investigou o desenvolvimento de um protótipo para contagem e rastreabilidade de instrumentos, considerando o fluxo do CME. Contagem informa quantos objetos estão presentes; rastreabilidade envolve acompanhar sua identificação e seu percurso no processo. O estudo fornece uma referência local para compreender as conferências no expurgo e no preparo das caixas. A presente pesquisa concentra sua avaliação na detecção e na contagem por fotografias, sem equiparar o reconhecimento de uma categoria à identificação individual de cada peça ao longo de seu histórico de uso.

Na investigação de detectores, Ran *et al.* (2023) propuseram modificações no YOLOv7x e apresentaram a base OSI26. O trabalho considera dificuldades de reconhecimento relacionadas à semelhança entre instrumentos e às condições visuais. Sua contribuição para esta pesquisa é mostrar que a detecção de instrumentos envolve desafios próprios e pode exigir atenção à representação dos objetos, além da escolha de uma arquitetura genérica.

Jiang *et al.* (2023) estudaram uma adaptação do YOLOv5 em imagens de instrumentos, incluindo disposições com e sem empilhamento. A presença de peças sobrepostas aproxima a investigação de uma dificuldade importante para a contagem: localizar objetos distintos quando parte de sua aparência está escondida. Os dois estudos examinam alterações nos detectores, enquanto a presente pesquisa prioriza a preparação da base e a avaliação de uma implementação disponível no recorte de instrumentos selecionado.

Uma contribuição adicional é o estudo experimental de Deol *et al.* (2024), que utilizou YOLOv9 em uma base com 1.004 imagens, 13.213 objetos e 11 ca-

tegorias. Os autores incluíram cenas com vários instrumentos, um subconjunto com sobreposição e uma avaliação em vídeo simulado. Isso aproxima o problema de situações em que a contagem precisa considerar diversos objetos simultaneamente. Por outro lado, a necessidade de validação clínica posterior reconhecida pelos autores reforça a diferença entre demonstrar funcionamento experimental e comprovar adequação ao uso hospitalar.

Esses trabalhos orientam aspectos complementares: a rotina de conferência, o contexto local de aplicação, as dificuldades visuais e a avaliação de cenas com múltiplos objetos. Suas métricas não formam, contudo, uma classificação direta de qual modelo seria melhor para esta pesquisa. Bases, categorias, divisões e condições de captura distintas produzem problemas diferentes. A comparação útil está nos critérios empregados e nas limitações observadas; qualquer comparação numérica entre modelos exige condições de avaliação compatíveis.

2.6 Como avaliar a detecção dos objetos

Avaliar a detecção significa comparar as caixas e as classes previstas com as anotações de referência. Uma previsão precisa localizar o objeto com qualidade suficiente e atribuir-lhe a classe esperada. Para medir a proximidade entre duas caixas, utiliza-se a interseção sobre união, conhecida como IoU, do inglês *intersection over union*. Seu cálculo divide a área comum às caixas pela área total ocupada por ambas, contando a região comum apenas uma vez (Padilla *et al.*, 2021):

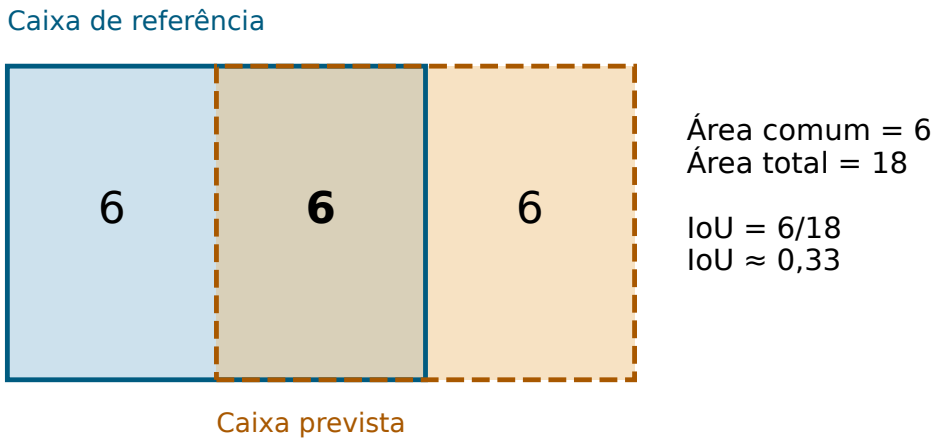
$$\text{IoU}(B_p, B_r) = \frac{|B_p \cap B_r|}{|B_p \cup B_r|}. \tag{1}$$

Na Equação 1, B_p é a caixa prevista e B_r a caixa de referência. O símbolo $\cap$ indica a interseção, ou parte comum; $\cup$ indica a união; e as barras representam área. O resultado varia de zero a um: zero corresponde à ausência de área comum e um à coincidência completa. Quanto maior a sobreposição relativa, maior a IoU. Na Figura 4, cada caixa tem área 12, a parte comum tem área 6 e a união tem área $12 + 12 - 6 = 18$. Assim, a IoU é $6/18$, aproximadamente $0{,}33$.

Um limiar de IoU define a sobreposição mínima exigida para aceitar uma correspondência. Se o limiar for $0{,}50$, as caixas do exemplo não satisfazem o critério. Esse valor não é o limiar de confiança: a confiança seleciona as previsões emitidas pelo modelo; a IoU avalia sua localização em relação à referência. A associação também considera a classe e deve evitar que várias previsões sejam contadas como acertos para um único objeto (Padilla *et al.*, 2021).

Uma detecção corretamente associada é um verdadeiro positivo (VP). Uma previsão sem correspondência válida é um falso positivo (FP), como uma

Figura 4: Cálculo ilustrativo da interseção sobre união entre duas caixas



Fonte: elaboração própria. Áreas expressas em unidades quadradas arbitrárias.

caixa sobre o fundo ou uma detecção duplicada. Um objeto anotado que não recebe correspondência é um falso negativo (FN). Quando a classe está errada, a avaliação por classe registra uma previsão indevida na classe atribuída e a ausência do objeto na classe de referência. Esses termos descrevem erros diferentes e ajudam a interpretar o resultado para além do número total de caixas.

A precisão responde: entre as detecções aceitas, quantas estão corretas? A revocação, também chamada de sensibilidade ou *recall*, responde: entre os objetos que deveriam ser encontrados, quantos foram detectados corretamente? Para denominadores diferentes de zero, calculam-se:

$$P = \frac{VP}{VP + FP}, \qquad R = \frac{VP}{VP + FN}. \tag{2}$$

Considere, como exemplo didático, dez instrumentos anotados e nove detecções, das quais oito corretas. Nesse caso, há $VP = 8$, $FP = 1$ e $FN = 2$. A precisão é $8/9 \approx 88{,}9\%$ e a revocação é $8/10 = 80\%$. A primeira informa a proporção de respostas corretas; a segunda mostra a parcela dos instrumentos encontrados. Se aumentam os falsos positivos mantendo os acertos, a precisão diminui. Se aumentam as omissões mantendo os acertos, a revocação diminui.

O limiar de confiança interfere nesse equilíbrio. Elevar o limiar elimina previsões de menor pontuação, podendo retirar tanto erros quanto acertos; reduzi-lo permite aceitar mais previsões, incluindo potenciais falsos positivos. Em geral, utiliza-se uma curva precisão--revocação para observar o comportamento em vários limiares. A precisão média, AP, resume essa curva de acordo com uma convenção de cálculo, e a média das AP entre as classes é denominada mAP

(Ultralytics, 2026c). Por reunir diferentes pontos de operação, a mAP não é a precisão obtida em um único limiar escolhido para contar objetos.

Na notação mAP@0,50, a localização é avaliada com IoU de $0{,}50$. Já mAP@0,50:0,95 combina avaliações em dez limiares, de $0{,}50$ a $0{,}95$, com intervalos de $0{,}05$. Os critérios mais altos exigem maior coincidência entre as caixas. Essas métricas descrevem a detecção; não representam a porcentagem de imagens com contagem exata (Ultralytics, 2026c). Também é necessário informar quais classes possuem exemplos na avaliação, pois uma classe ausente não fornece evidência de desempenho positivo naquele conjunto.

Os resultados por classe e a matriz de confusão complementam as médias. Essa matriz organiza as correspondências entre categorias de referência e previstas, permitindo identificar trocas recorrentes. Sua interpretação depende da orientação dos eixos e dos critérios de associação empregados. Para esta aplicação, uma média global satisfatória pode esconder dificuldades em categorias menos representadas, tornando necessária a análise conjunta das métricas e de exemplos visuais dos erros.

2.7 Da detecção à avaliação da contagem

Depois de selecionar as detecções, a contagem pode ser obtida somando os objetos atribuídos a cada classe. Para expressar essa operação, considere N imagens e C classes. O índice i identifica uma imagem e c uma classe. Seja D_i o conjunto de detecções aceitas na imagem i. A quantidade prevista para uma classe e o total previsto são:

$$\widehat{n}_{ic} = \sum_{d \in D_i} \mathbf{1}[\text{classe}(d) = c], \qquad \widehat{n}_i = \sum_{c=1}^{C} \widehat{n}_{ic}. \tag{3}$$

O símbolo $\sum$ indica uma soma. Na primeira expressão, percorrem-se as detecções d e acrescenta-se uma unidade quando sua classe é c; a função $\mathbf{1}[\cdot]$ vale um se a condição for verdadeira e zero se for falsa. Na segunda, somam-se as quantidades de todas as classes. O acento sobre $\widehat{n}$ indica que se trata de uma estimativa. Os índices de um a C são uma convenção matemática e não alteram a numeração dos arquivos de anotação. Se a saída contém duas pinças e uma tesoura, as contagens são dois e um, e o total é três.

Para avaliar o total, compara-se a estimativa $\widehat{n}_i$ com a quantidade de referência n_i. O erro absoluto médio, ou MAE, do inglês *mean absolute error*, é

definido por:

$$\mathrm{MAE}_{\mathrm{total}} = \frac{1}{N}\sum_{i=1}^{N} |\widehat{n}_i - n_i|. \tag{4}$$

Primeiro, calcula-se a diferença entre o total previsto e o total real em cada imagem. As barras indicam valor absoluto: um erro de menos dois ou de mais dois contribui com dois. Em seguida, somam-se os erros e divide-se pelo número de imagens. Um MAE menor indica maior proximidade entre os totais; zero significa que todos os totais coincidiram. A unidade é objetos por imagem, e não porcentagem.

Por exemplo, suponha três imagens com totais de referência $(2, 3, 0)$ e previsões $(2, 1, 1)$. Os erros absolutos são $(0, 2, 1)$, e o MAE é $(0 + 2 + 1)/3 = 1$. Isso não significa que houve exatamente um erro em cada fotografia: uma teve total correto, outra apresentou subcontagem de dois e a terceira, sobrecontagem de um. Registrar separadamente omissões e excessos torna a interpretação mais útil para uma tarefa de conferência.

O cálculo também pode ser realizado por classe:

$$\mathrm{MAE}_{c} = \frac{1}{N}\sum_{i=1}^{N} |\widehat{n}_{ic} - n_{ic}|. \tag{5}$$

Aqui, n_{ic} é a quantidade de referência da classe c na imagem i. Essa medida revela, por exemplo, que uma contagem total aparentemente adequada pode esconder trocas entre pinças e tesouras. A base utilizada no denominador deve ficar explícita: calcular a média sobre todas as imagens inclui aquelas em que a classe está ausente. Para uma classe rara, muitos zeros corretos podem reduzir a média mesmo com falhas nas poucas imagens positivas. Informar a quantidade de imagens e objetos avaliados e distinguir os casos de presença e ausência ajuda a evitar essa interpretação equivocada.

Outra pergunta importante é quantas fotografias tiveram a contagem exata. A proporção de imagens com total correto é:

$$E_{\mathrm{total}} = \frac{1}{N}\sum_{i=1}^{N} \mathbf{1}[\widehat{n}_i = n_i]. \tag{6}$$

Cada imagem contribui com um se o total previsto coincide com a referência, ou com zero se existe diferença. A soma é dividida por N; multiplicando o resultado por cem, obtém-se a porcentagem. No exemplo dos totais $(2, 3, 0)$ e $(2, 1, 1)$, apenas a primeira imagem teve acerto, portanto $E_{\mathrm{total}} = 1/3$, ou aproximadamente $33{,}3\%$. Diferentemente do MAE, esse indicador não distingue um erro

de uma unidade de um erro de várias unidades: ambos tornam aquela contagem inexata.

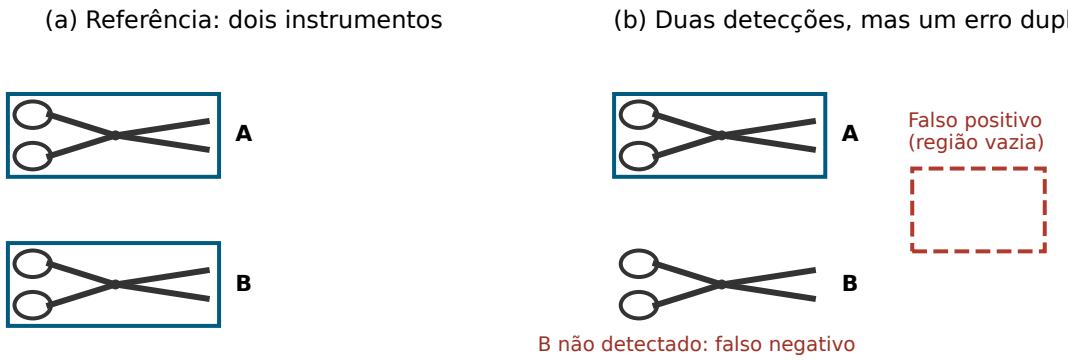
Também é possível exigir que todas as categorias estejam corretas simultaneamente. O vetor de contagens é a lista ordenada das quantidades de cada classe; por exemplo, $(2, 1, 0)$ pode representar duas pinças, uma tesoura e nenhum afastador. Define-se a proporção de vetores exatos por:

$$E_{\text{classes}} = \frac{1}{N} \sum_{i=1}^{N} \mathbf{1}[\widehat{n}_{ic} = n_{ic} \text{ para todo } c]. \tag{7}$$

A condição ``para todo c'' exige coincidência em cada posição da lista. Uma previsão $(1, 2, 0)$ tem o mesmo total de $(2, 1, 0)$, mas falha nesse critério porque troca a composição das classes. Assim, o acerto exato por classe é mais exigente que o acerto apenas do total. Entretanto, nem mesmo a coincidência do vetor garante que todas as caixas estejam corretas: uma omissão e uma detecção indevida na mesma categoria podem se compensar.

A Figura 5 ilustra essa compensação. Há dois instrumentos na referência. Na previsão esquemática, um é corretamente localizado, o outro é omitido e uma região vazia recebe uma caixa. O total continua igual a dois, mas existem um falso negativo e um falso positivo. Se ambos forem atribuídos à mesma categoria, o vetor de contagens também poderá coincidir. Por isso, as medidas de contagem precisam ser analisadas junto com a qualidade das detecções.

Figura 5: Contagem total correta apesar de uma omissão e uma detecção indevida



Fonte: elaboração própria. Representação esquemática de instrumentos e previsões hipotéticas, sem resultados do modelo treinado.

As imagens sem objetos de interesse também contribuem para a avaliação. Nelas, o resultado esperado é zero; qualquer detecção aceita produz uma sobrecontagem. Esse teste permite observar respostas indevidas em fundos, mas um conjunto de bandejas vazias não representa todos os objetos desconhecidos que

poderiam aparecer no ambiente. É necessário explicitar quais situações negativas foram incluídas, assim como a quantidade de imagens com um ou vários instrumentos.

2.8 Interpretação da viabilidade técnica

Os indicadores apresentados respondem a perguntas complementares: a detecção avalia localização e classe; o MAE expressa a diferença média entre quantidades; e o acerto exato informa a frequência de contagens sem divergência numérica. A análise por categoria, origem e número de objetos ajuda a identificar condições em que o desempenho muda. Uma condição pouco representada, como forte oclusão, não pode ser considerada validada apenas pelo resultado global.

As categorias também delimitam a interpretação. Se dois instrumentos específicos pertencem ao grupo ``pinças'', distingui-los não faz parte da tarefa do modelo geral. Um bom resultado nesse grupo, portanto, não demonstra reconhecimento de cada tipo específico. Da mesma forma, resultados com instrumentos isolados não comprovam desempenho equivalente em bandejas completas.

O custo computacional complementa a qualidade das respostas. O tempo de treinamento informa o esforço para obter o modelo; o de inferência, o tempo para analisar novas imagens. A medição deve indicar equipamento, tamanho de entrada e etapas incluídas: somente a rede ou também leitura, preparação e apresentação da imagem. Essas condições impedem transportar diretamente tempos medidos em outro dispositivo.

A viabilidade técnica depende dessas evidências e do cenário pretendido. A avaliação deve mostrar onde a abordagem funciona, onde falha e quais condições ainda exigem investigação. A metodologia apresentada a seguir transforma os conceitos discutidos em procedimentos de preparação dos dados, treinamento e avaliação da detecção e da contagem.

3 METODOLOGIA

Este trabalho adota uma abordagem quantitativa, de caráter aplicado e experimental, para avaliar a detecção e a contagem de instrumentos cirúrgicos em fotografias. A unidade de entrada do sistema é uma imagem, enquanto a unidade de anotação é cada instrumento individualmente delimitado. O procedimento compreende a seleção das fontes, a revisão das imagens e anotações, a consolidação das classes, a separação dos dados e o treinamento de um detector. A avaliação considera tanto a localização dos objetos quanto as quantidades obtidas a partir das detecções.

O escopo é delimitado por instrumentos associados à caixa de apendicectomia adotada como referência. A investigação não abrange o reconhecimento irrestrito de materiais cirúrgicos nem a verificação de esterilidade, integridade física ou utilização de cada instrumento. A viabilidade examinada é computacional e condicionada às imagens disponíveis; não corresponde à validação de um dispositivo para uso assistencial.

3.1 Constituição e procedência da base de imagens

A base foi constituída por duas origens: conjuntos obtidos na internet e fotografias disponibilizadas por uma enfermeira do Hospital Universitário da Universidade Estadual de Londrina (HU-UEL). As fontes externas foram identificadas internamente como DS01 a DS07 para preservar sua procedência durante a preparação. Essa identificação é operacional e não substitui a referência ao conjunto original, à sua versão e às condições de uso.

Os conjuntos DS01, DS03, DS04 e DS05 foram obtidos no Roboflow, e o DS06, no Kaggle. O DS07 foi incorporado a partir de imagens cujas anotações haviam sido convertidas de JSONL para o formato YOLO. O DS02 foi integralmente descartado após a identificação de conteúdo repetido em relação ao DS01, incluindo versões com diferenças de borda ou ampliação. Assim, seis conjuntos externos contribuíram para a consolidação. A identificação bibliográfica completa dessas fontes permanece em conferência documental.

As fotografias do HU-UEL foram organizadas inicialmente por instrumento e, em casos específicos, por composição de objetos. Entre as composições anotadas estão imagens com pinça dente de rato, pinça Backhaus e cúpula, além de imagens contendo uma tesoura Metzenbaum reta e outra curva. Também foram incorporadas 100 fotografias de bandejas vazias como exemplos negativos. Imagens sem instrumentos possuem arquivo de anotação vazio; por isso, a ausência de objetos nesses casos é intencional e não deve ser interpretada como falha de

rotulagem.

Os registros fornecidos para o estudo representam instrumentos e superfícies de apoio. Não se atribui a essas fotografias a condição de registros de procedimentos cirúrgicos em andamento. Datas, dispositivos e organização das sessões de aquisição devem acompanhar a documentação da coleta para permitir interpretar sua diversidade. A disponibilização por uma profissional do hospital não é apresentada neste trabalho como parecer de comitê de ética ou como autorização institucional formal.

A Tabela 1 apresenta a composição registrada no manifesto da revisão v3. As quantidades correspondem ao material após a seleção, e não ao volume originalmente baixado. A distinção entre imagens e objetos é necessária porque uma fotografia pode conter várias instâncias, inclusive de uma mesma classe.

Tabela 1 – Composição da base consolidada por origem

Origem	Imagens	Objetos anotados
DS01	289	414
DS03	115	129
DS04	249	382
DS05	85	85
DS06	2.964	4.149
DS07	1.008	1.008
Subtotal da internet	4.710	6.167
HU-UEL	5.617	6.547
Total	10.327	12.714

Fonte: elaboração própria, com base nos manifestos da revisão v3 (2026).
Nota: as 100 imagens negativas estão incluídas no total do HU-UEL e não acrescentam objetos.

3.2 Seleção, anotação e padronização dos instrumentos

A seleção foi orientada pela correspondência com os instrumentos definidos para o estudo, pela possibilidade de identificação visual e pela adequação das anotações. Foram retiradas imagens de baixa qualidade que impediam a inspeção, exemplos incompatíveis com a caixa de referência e versões repetidas identificadas durante a revisão. O processo considerou conteúdo e aparência, e não apenas nomes de arquivos ou rótulos originais. Dúvidas sobre determinados instrumentos foram submetidas à apreciação da enfermeira colaboradora; não foi realizado um estudo formal de concordância entre múltiplos anotadores.

Instrumentos visualmente semelhantes, mas fora do escopo, não foram incluídos apenas para aumentar o volume da base. Quando sua presença poderia gerar supervisão contraditória, optou-se pela retirada da imagem, inclusive

se ela também apresentasse um objeto desejado. Um exemplo foi o afastador Army-Navy, cuja aparência em determinadas posições se aproxima daquela do Farabeuf. Essa escolha delimita o domínio do experimento: o detector não é avaliado como classificador universal de instrumentos semelhantes aos selecionados.

A revisão dos conjuntos externos foi realizada com apoio do CVAT e de inspeções no Roboflow. As imagens do HU-UEL foram anotadas no X-AnyLabeling com caixas delimitadoras horizontais, uma por objeto. O arquivo exportado associa a cada caixa um identificador de classe e quatro coordenadas normalizadas, correspondentes ao centro, à largura e à altura. As anotações foram organizadas de forma que cada imagem e seu arquivo de rótulos compartilhassem o mesmo nome-base.

Nos conjuntos com polígonos, a conversão para detecção utilizou os menores e maiores valores de cada coordenada para obter a caixa envolvente de cada instância. Esse procedimento conserva a extensão espacial do contorno anotado, mas não verifica sua pertinência semântica. Por isso, caixas que abrangiam componentes indesejados, como tubos conectados ao bico de aspiração ou partes além do cabo de bisturi, foram submetidas à revisão manual. No DS07, as anotações convertidas de JSONL foram inspecionadas visualmente, e foram mantidas as classes correspondentes a porta-agulhas e cabos de bisturi.

Foram preservadas duas taxonomias. A específica distingue 17 classes, incluindo versões retas e curvas de Kelly, Mayo e Metzenbaum. A geral reúne os mesmos objetos em sete categorias, utilizadas no primeiro treinamento. Diferenças de tamanho não originam classes distintas. O porta-agulhas permanece separado das tesouras, apesar da semelhança visual de alguns modelos. A pinça Collin coração não integra a configuração inicial por falta de imagens, e a Kocher curva não integra o conjunto de instrumentos selecionado.

A Tabela 2 explicita a correspondência entre as taxonomias e a quantidade de objetos em cada categoria geral. Os nomes em português são utilizados na apresentação do trabalho; os identificadores em inglês são empregados nos arquivos de treinamento. As duas organizações mantêm as mesmas caixas e divisões, alterando apenas os identificadores de classe. Portanto, não constituem duas bases independentes.

A representação é desigual entre classes e origens. Por exemplo, as pinças anatômicas e os cabos de bisturi da base consolidada provêm exclusivamente da internet. Consequentemente, um resultado agregado satisfatório não demonstra desempenho hospitalar para todas as classes. Essa diferença deve ser considerada na análise dos erros e na apresentação dos resultados por origem.

Tabela 2 – Correspondência entre classes específicas e categorias gerais

Categoria geral	Classes específicas representadas	Objetos
Pinças	Allis; anatômica; Backhaus; Kelly curva; Kelly reta; Foerster; dente de rato; Kocher reta	4.907
Tesouras	Mayo curva; Mayo reta; Metzenbaum curva; Metzenbaum reta	3.976
Afastadores	Farabeuf	848
Porta-agulhas	Porta-agulhas	760
Cabos de bisturi	Cabo de bisturi	1.673
Bicos de aspiração	Bico de aspiração, incluindo exemplares Yankauer aceitos na revisão	244
Cúpulas	Cúpula	306
Total	17 classes específicas e 7 categorias gerais	12.714

Fonte: elaboração própria, com base no mapeamento de classes e no manifesto de objetos da revisão v3 (2026).

3.3 Consolidação, verificação e separação dos dados

A consolidação foi executada por scripts Python sobre cópias dos conjuntos selecionados. Os arquivos brutos foram mantidos separados da base de trabalho. Foram produzidos manifestos de imagens e objetos, mapas de classes e registros de exclusões, de forma a vincular cada arquivo consolidado à origem e à divisão atribuída. A organização foi preparada no Windows e transferida para o Mac utilizado no treinamento.

A verificação combinou comparação de nomes-base, leitura dos rótulos, conferência das classes e validação geométrica das caixas. Foram calculados resumos criptográficos SHA-256 para conferir integridade de arquivos, além de resumos dos pixels decodificados e assinaturas perceptuais dHash para investigar repetições. Esses mecanismos têm finalidades distintas: igualdade criptográfica verifica o conteúdo comparado, enquanto proximidade perceptual apenas indica candidatos que exigem inspeção. Fundos semelhantes podem produzir assinaturas próximas mesmo quando os objetos são diferentes.

Na revisão complementar, pares entre divisões com distância de Hamming de até dois bits em assinaturas dHash de 64 bits foram selecionados para inspeção visual. Essa busca resultou em 373 pares candidatos envolvendo 197 imagens; a sequência de 42 imagens do DS07 foi acrescentada à coleta visual, totalizando 239 imagens examinadas nessa etapa. Esses números descrevem candidatos e material revisado, não quantidades de duplicatas. Vários pares do DS06 foram reconhecidos como cenas distintas sobre fundos semelhantes.

A revisão também identificou uma imagem do DS05 com três caixas para um único objeto. Duas caixas coincidentes abrangiam praticamente toda a fo-

tografia, enquanto a terceira delimitava o instrumento; as duas primeiras foram removidas. Em outro caso, foi excluída a versão de menor resolução de uma fotografia repetida do DS04, juntamente com seu rótulo. Imagens relacionadas já identificadas foram mantidas na mesma divisão, e 42 fotografias de uma sequência de cabo de bisturi do DS07 foram reunidas em um único grupo de treino.

O agrupamento procura reduzir a dependência entre dados usados para aprender e dados usados para avaliar. Como discutem Kapoor e Narayanan (2023), falhas na separação podem produzir conclusões excessivamente otimistas. Entretanto, a ausência de grupos cadastrados em mais de uma divisão não comprova independência de todas as sessões de aquisição. A base contém imagens de instrumentos reposicionados em cenários semelhantes, e os registros disponíveis não permitem reconstruir integralmente todas as sessões das fontes externas. Essa restrição permanece como limitação do experimento.

A divisão preserva conjuntos de treino, validação e teste, com as quantidades da Tabela 3. A distribuição foi ajustada pelas revisões de grupos e duplicatas, em vez de se refazer uma separação aleatória apenas para obter percentuais exatos. A mesma atribuição foi mantida nas duas taxonomias. Entre as imagens negativas, 80 pertencem ao treino, dez à validação e dez ao teste.

Tabela 3 – Distribuição das imagens e dos objetos por divisão

Divisão	Imagens	Objetos anotados
Treino	8.304	10.044
Validação	1.015	1.293
Teste	1.008	1.377
Total	10.327	12.714

Fonte: elaboração própria, com base nos manifestos da revisão v3 (2026).

3.4 Ambiente computacional e configuração do treinamento

O ambiente de execução utiliza um Mac mini com chip Apple M4 e 16 GB de memória unificada, com aceleração pela interface Metal Performance Shaders (MPS) do PyTorch. O ambiente informado nos testes compreende Python 3.13, PyTorch 2.15.0 e Ultralytics 8.4.192, em arquitetura arm64. A configuração foi mantida após os testes de instalação para evitar mudanças de dependências durante o experimento.

Antes da execução principal, foi realizado um piloto de três épocas com uma fração de 10% do conjunto de treino, destinado a verificar carregamento, uso do dispositivo e funcionamento do procedimento. Esse piloto não foi adotado como resultado definitivo de viabilidade, nem seus pesos foram utilizados como

ponto de partida do treinamento principal. Para este, selecionou-se o YOLO26n com pesos pré-treinados e utilização integral da divisão de treino.

A variante de menor porte foi escolhida em razão do recurso computacional disponível e do tempo de execução observado no piloto. Essa escolha não pressupõe superioridade em relação a modelos maiores. Da mesma forma, o uso de pré-treinamento constitui uma estratégia de inicialização e adaptação, sem garantir precisão para instrumentos não representados adequadamente nos dados.

A configuração principal está sintetizada na Tabela 4. O limite de 50 épocas foi definido como orçamento inicial de treinamento, e não como valor ótimo estabelecido por busca sistemática. A parada antecipada foi configurada com tolerância de dez épocas sem melhora no critério de validação da implementação. A quantidade efetivamente executada, a época selecionada e a duração serão informadas a partir dos registros, após o encerramento.

Tabela 4 – Parâmetros definidos para o treinamento principal

Parâmetro	Configuração
Modelo e tarefa	YOLO26n; detecção de caixas horizontais
Classes e fração do treino	7 categorias; 100% da divisão
Épocas e tolerância de parada	Máximo de 50; tolerância de 10
Dimensão de entrada configurada	640 pixels
Lote físico / lote nominal	4 / 64
Otimizador	AdamW
Taxa inicial / fator final	0,001 / 0,01
Decaimento de pesos solicitado	0,0005
Parâmetro de momento	0,9
Aquecimento	3 épocas
Semente	42
Dispositivo e precisão mista	MPS; precisão mista desativada
Processos auxiliares / cache de imagens	0 / desativado
Salvamento periódico	A cada 5 épocas

Fonte: elaboração própria, com base no script de treinamento da revisão v3 (2026).
Nota: o lote nominal é uma referência interna para a otimização; não equivale ao número de imagens simultaneamente processadas no dispositivo.

O AdamW emprega decaimento de pesos desacoplado da atualização adaptativa, conforme a formulação de Loshchilov e Hutter (2019). Sua adoção neste experimento representa uma escolha explícita de otimização, sem reproduzir integralmente a receita de pré-treinamento do YOLO26. A taxa de aprendizagem foi configurada com aquecimento e redução linear, sem busca automática de hiperparâmetros. As definições operacionais dos argumentos são apresentadas na documentação do software (Ultralytics, 2026b).

A dimensão de entrada é aplicada durante o carregamento e o processa-

mento das imagens. Os arquivos preservados na base não foram recomprimidos nem redimensionados por essa etapa. Entretanto, a redução para a entrada da rede pode eliminar detalhes de instrumentos finos, aspecto que será examinado na análise dos erros. O processamento utiliza lote físico de quatro imagens, sem cache de imagens em memória e sem processos auxiliares de carregamento, priorizando a execução no equipamento disponível.

A semente foi fixada e foi solicitada execução determinística. Isso favorece a rastreabilidade, mas não implica reprodução bit a bit, pois determinadas operações do ambiente MPS podem não dispor de implementação determinística. Os argumentos efetivos, as versões dos pacotes e os caminhos dos arquivos são registrados junto à execução. O treinamento preserva o último estado e o estado selecionado pelo critério de validação da biblioteca; o conjunto de teste não participa dessa seleção.

3.5 Aumento de dados durante o treinamento

O aumento de dados foi configurado para aplicação durante o treinamento, sem produzir uma nova coleção permanente de fotografias. A estratégia procura introduzir variações de aparência e disposição dos objetos e constitui uma forma de regularização (Goodfellow; Bengio; Courville, 2016). A política solicitada compreende espelhamentos horizontal e vertical com probabilidade de 0,5 cada, rotações de até aproximadamente $\pm 15°$, translação relativa de 0,1 e variação de escala de 0,25. Os parâmetros de matiz, saturação e valor foram definidos, respectivamente, como 0,015, 0,3 e 0,2.

A transformação mosaic foi configurada com probabilidade de 0,5 para compor entradas a partir de diferentes imagens. Sua aplicação busca ampliar a variedade de composições, mas não reproduz necessariamente oclusões e interações físicas entre instrumentos em uma bandeja real. MixUp, Copy-Paste, cisalhamento e perspectiva adicional foram desativados. A documentação da Ultralytics descreve essas operações e seus parâmetros (Ultralytics, 2026a).

Foi prevista a desativação do mosaic nas dez últimas épocas da agenda programada. Caso a parada antecipada ocorra antes dessa etapa, não se pode afirmar que o modelo tenha passado por esse período final sem mosaic. As transformações efetivamente carregadas, inclusive componentes opcionais dependentes do ambiente, são registradas para conferir a correspondência com a configuração solicitada. Exemplos de lotes transformados permitem inspecionar cortes e caixas produzidos durante o treinamento.

As 8.304 imagens de treino permanecem como quantidade física de referência. Repetições ao longo das épocas e variações geradas durante o processa-

mento não são contabilizadas como fotografias independentes. Validação e teste não recebem a política aleatória de aumento de dados do treino, embora também necessitem do pré-processamento de entrada. Essa distinção evita confundir expansão de apresentações do mesmo material com aumento da diversidade original da amostra.

3.6 Protocolo de avaliação da detecção e da contagem

A avaliação será realizada após o encerramento do treinamento. A seleção do estado do modelo e o ajuste do limiar de confiança utilizarão a validação, preservando o teste para a aplicação do procedimento escolhido. O limiar determina quais predições serão aceitas para a contagem; sua definição deve considerar omissões e falsas detecções, sem utilizar o teste para procurar a configuração mais favorável.

Para detecção, serão examinados precisão, revocação, mAP com interseção sobre união de 0,50 e mAP no intervalo de 0,50 a 0,95, com os resultados discriminados por categoria. A interpretação seguirá as definições apresentadas na fundamentação e as distinções entre métricas discutidas por Padilla *et al.* (2021). As opções efetivas de inferência e associação de predições serão registradas, pois não devem ser inferidas exclusivamente a partir da designação YOLO26.

Para contagem, as detecções aceitas serão agregadas por imagem e por categoria. Serão calculados o erro absoluto médio e a proporção de imagens com contagem total correta, acompanhados dos resultados por classe. Também será examinada a coincidência do vetor de contagens das categorias, que exige acerto simultâneo em todas elas. Essa análise é mais restritiva que o acerto do total: uma falsa detecção e uma omissão podem compensar-se numericamente sem que os objetos tenham sido reconhecidos corretamente.

A análise qualitativa distinguirá omissões, contagens excedentes, confusões entre categorias e problemas de localização. Serão considerados o número de objetos na cena, sua sobreposição e a origem das imagens, conforme a informação disponível. Resultados do HU-UEL e da internet serão apresentados separadamente quando houver suporte amostral, evitando atribuir desempenho hospitalar a uma categoria avaliada apenas em imagens externas.

O custo computacional será descrito a partir do equipamento e das condições reais de execução. A duração do treinamento e, quando medido, o tempo de inferência deverão indicar o que foi incluído na medição, como carregamento, pré-processamento e pós-processamento. Tempos obtidos em outros dispositivos ou bases não serão empregados como resultados deste experimento.

A interpretação da viabilidade combinará desempenho de detecção, erros

de contagem, condições de falha e custo computacional. Não foi estabelecido um limiar clínico de aceitação nem será atribuída aprovação assistencial ao modelo. A conclusão deverá permanecer limitada aos cenários avaliados e à necessidade de conferência humana. Fotografias futuras de uma nova sessão poderão ampliar a avaliação externa, desde que não sejam utilizadas para ajustar o mesmo modelo que será avaliado nelas.

4 RESULTADOS E DISCUSSÃO

[VERSÃO PRELIMINAR: a caracterização da base está preenchida com dados dos manifestos; os resultados do treinamento e da avaliação permanecem pendentes.]

A apresentação dos resultados distingue a base obtida após a preparação dos dados do desempenho do detector. As contagens do material disponível descrevem a amostra experimental, mas não demonstram, por si mesmas, a eficácia da identificação ou da contagem automática. Essa distinção orienta a análise da composição da base e a posterior interpretação das métricas do modelo.

4.1 Composição da base e cobertura das categorias

O manifesto consolidado da revisão v3 registra 10.327 imagens e 12.714 objetos. A Tabela 5 discrimina a contribuição de cada origem para as categorias gerais. Seus valores representam instâncias anotadas em toda a base, abrangendo treino, validação e teste; não correspondem ao número de imagens de cada categoria nem a predições realizadas pelo modelo.

Tabela 5 – Objetos anotados por categoria geral e origem

Categoria	HU-UEL	Internet	Total
Pinças	3.498	1.409	4.907
Tesouras	1.617	2.359	3.976
Cabos de bisturi	0	1.673	1.673
Afastadores	815	33	848
Porta-agulhas	182	578	760
Cúpulas	285	21	306
Bicos de aspiração	150	94	244
Total	6.547	6.167	12.714

Fonte: elaboração própria, com base nos manifestos de imagens e objetos da revisão v3 (2026).
Nota: são contagens de referência de toda a base. Fotografias negativas não acrescentam objetos à tabela.

As categorias de pinças e tesouras concentram o maior número de objetos, enquanto bicos de aspiração e cúpulas possuem menor representação. A diferença exige que o desempenho seja examinado por categoria, pois uma medida agregada pode ocultar erros nos grupos menos representados. Entretanto, quantidade de anotações e diversidade visual não são equivalentes: várias fotografias de um mesmo instrumento ou cenário podem acrescentar menos variação do que imagens obtidas em condições distintas.

A contribuição das origens também é desigual. As cúpulas e os afastadores são representados predominantemente por fotografias do HU-UEL; os cabos de bisturi, exclusivamente por imagens externas. Logo, a base atual não permite medir a recuperação de cabos de bisturi em fotografias hospitalares com exemplos positivos dessa categoria. A ausência de predições equivocadas em imagens hospitalares sem cabos, caso observada, não substitui essa avaliação.

O agrupamento em categorias gerais reduz a quantidade de rótulos de saída, mas mantém a heterogeneidade visual dentro de cada grupo. A categoria de pinças reúne oito classes específicas, com distribuições diferentes entre origens. Em particular, as pinças anatômicas não possuem exemplos do HU-UEL na consolidação atual. Portanto, mesmo um resultado favorável para a categoria geral não demonstraria desempenho uniforme em todos os seus subtipos.

Quanto à composição das cenas, o manifesto registra 8.568 imagens com um objeto, 1.659 com mais de um objeto e 100 sem objetos anotados. A presença de cenas com múltiplas instâncias permite examinar contagem além do caso de um único instrumento, mas não implica que todas essas imagens apresentem oclusão. A dificuldade de cada cena depende também da disposição, da escala e da visibilidade dos objetos. A avaliação deverá explicitar essa diferença em vez de tratar toda imagem com vários instrumentos como uma cena complexa equivalente.

Essas características delimitam as conclusões possíveis. A combinação de imagens hospitalares e externas amplia a cobertura disponível para o treinamento, mas este experimento, sem uma comparação controlada entre bases, não demonstra que a mistura das origens seja a causa de eventual melhoria. Sua contribuição deverá ser discutida junto aos erros observados e à representatividade dos cenários efetivamente avaliados.

4.2 Evolução do treinamento e seleção do modelo

[PENDENTE R01: inserir os resultados reais do treinamento principal.]

4.3 Desempenho de detecção e contagem

[PENDENTE R02: concluir a seleção do limiar na validação e executar a avaliação reservada de teste.]

4.4 Análise dos erros e condições de aplicação

[PENDENTE R03: analisar predições reais e selecionar exemplos rastreá-

veis de acertos e erros.]

4.5 Síntese da viabilidade e limitações

[PENDENTE R04: redigir a síntese após reunir desempenho, erros e custo computacional.]

REFERÊNCIAS

BRASIL. MINISTÉRIO DA SAÚDE. **Documento de referência para o Programa Nacional de Segurança do Paciente**. Brasília, DF: Ministério da Saúde, 2014. 40 p. ISBN 978-85-334-2130-1. Disponível em: https://bvsms.saude.gov.br/bvs/publicacoes/documento_referencia_programa_nacional_seguranca.pdf. Acesso em: 30 out. 2026.

DEOL, Ekamjit S.; HENNING, Grant; BASOURAKOS, Spyridon; VASDEV, Ranveer M. S.; SHARMA, Vidit; KAVOUSSI, Nicholas L.; KARNES, R. Jeffrey; LEIBOVICH, Bradley C.; BOORJIAN, Stephen A.; KHANNA, Abhinav. Artificial intelligence model for automated surgical instrument detection and counting: an experimental proof-of-concept study. **Patient Safety in Surgery**, v. 18, 24, 2024. DOI: 10.1186/s13037-024-00406-y. Disponível em: https://link.springer.com/article/10.1186/s13037-024-00406-y. Acesso em: 1 nov. 2026.

FREITAS, Patrícia Scotini; MENDES, Karina Dal Sasso; GALVÃO, Cristina Maria. Processo de contagem cirúrgica: evidências para a segurança do paciente. **Revista Gaúcha de Enfermagem**, v. 37, n. 4, e66877, 2016. DOI: 10.1590/1983-1447.2016.04.66877. Disponível em: https://www.scielo.br/j/rgenf/a/r3t9YfDf5vSzD4PDNmMBHHL/?lang=pt. Acesso em: 1 nov. 2026.

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. **Deep Learning**. Cambridge, MA: MIT Press, 2016. Disponível em: https://www.deeplearningbook.org/. Acesso em: 31 out. 2026.

JIANG, Kaile; PAN, Shuwan; YANG, Luxuan; YU, Jie; LIN, Yuanda; WANG, Huaiqian. Surgical Instrument Recognition Based on Improved YOLOv5. **Applied Sciences**, Basel, v. 13, n. 21, 11709, 2023. DOI: 10.3390/app132111709. Disponível em: https://www.mdpi.com/2076-3417/13/21/11709. Acesso em: 30 out. 2026.

JOCHER, Glenn; QIU, Jing; LIU, Mengyu; LYU, Shuai; AKYON, Fatih Cagatay; KALFAOGLU, Muhammet Esat. **Ultralytics YOLO26: Unified Real-Time End-to-End Vision Models**. Preprint. Versão 1. arXiv. 2 jun. 2026. DOI: 10.48550/arXiv.2606.03748. Disponível em: https://arxiv.org/abs/2606.03748v1. Acesso em: 31 out. 2026.

KAPOOR, Sayash; NARAYANAN, Arvind. Leakage and the reproducibility crisis in machine-learning-based science. **Patterns**, v. 4, n. 9, 100804, 2023. DOI: 10.1016/j.patter.2023.100804. Disponível em: https://doi.org/10.1016/j.patter.2023.100804. Acesso em: 31 out. 2026.

LECUN, Yann; BENGIO, Yoshua; HINTON, Geoffrey. Deep learning. **Nature**, v. 521, n. 7553, p. 436–444, 2015. DOI: 10.1038/nature14539. Disponível em: https://www.nature.com/articles/nature14539. Acesso em: 1 nov. 2026.

LOSHCHILOV, Ilya; HUTTER, Frank. Decoupled Weight Decay Regularization. *In:* INTERNATIONAL Conference on Learning Representations. [*S. l.: s. n.*], 2019. Versão dos autores do artigo publicado na ICLR 2019. Disponível em: https://arxiv.org/abs/1711.05101v3. Acesso em: 31 out. 2026.

MORETO, Suellen Louro. **Desenvolvimento de protótipo para contagem e rastreabilidade de instrumental cirúrgico com visão computacional**. 2025. Dissertação (Mestrado em Enfermagem) – Universidade Estadual de Londrina, Londrina.

OPENCV. **Image Gradients**. Documentação da versão 4.13.0. Disponível em: https://docs.opencv.org/4.13.0/d5/d0f/tutorial_py_gradients.html. Acesso em: 1 nov. 2026.

OPENCV. **Smoothing Images**. Documentação da versão 4.13.0. Disponível em: https://docs.opencv.org/4.13.0/d4/d13/tutorial_py_filtering.html. Acesso em: 1 nov. 2026.

ORGANIZAÇÃO MUNDIAL DA SAÚDE. **Segundo desafio global para a segurança do paciente: cirurgias seguras salvam vidas (orientações para cirurgia segura da OMS)**. Tradução: Marcela Sánchez Nilo e Irma Angélica Durán. Rio de Janeiro: Organização Pan-Americana da Saúde, Ministério da Saúde e Agência Nacional de Vigilância Sanitária, 2009. 211 p. ISBN 978-85-87943-97-2. Disponível em: https://bvsms.saude.gov.br/bvs/publicacoes/seguranca_paciente_cirurgias_seguras_salvam_vidas.pdf. Acesso em: 30 out. 2026.

PADILLA, Rafael; PASSOS, Wesley L.; DIAS, Thadeu L. B.; NETTO, Sergio L.; SILVA, Eduardo A. B. da. A Comparative Analysis of Object Detection Metrics with a Companion Open-Source Toolkit. **Electronics**, Basel, v. 10, n. 3, 279, 2021. DOI: 10.3390/electronics10030279. Disponível em: https://www.mdpi.com/2079-9292/10/3/279. Acesso em: 31 out. 2026.

PYTORCH. **Reproducibility**. Documentação da versão 2.15. Disponível em: https://docs.pytorch.org/docs/2.15/notes/randomness.html. Acesso em: 1 nov. 2026.

PYTORCH. **Transfer Learning for Computer Vision Tutorial**. Disponível em: https://docs.pytorch.org/tutorials/beginner/transfer_learning_tutorial.html. Acesso em: 1 nov. 2026.

RAN, Boping; HUANG, Bo; LIANG, Shunpan; HOU, Yulei. Surgical Instrument Detection Algorithm Based on Improved YOLOv7x. **Sensors**, Basel, v. 23, n. 11, 5037, 2023. DOI: 10.3390/s23115037. Disponível em: https://www.mdpi.com/1424-8220/23/11/5037. Acesso em: 30 out. 2026.

REDMON, Joseph; DIVVALA, Santosh; GIRSHICK, Ross; FARHADI, Ali. You Only Look Once: Unified, Real-Time Object Detection. *In:* IEEE CONFERENCE

ON COMPUTER VISION AND PATTERN RECOGNITION, 2016, Las Vegas. **Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition**. Las Vegas: IEEE, 2016. p. 779–788. Disponível em: https://openaccess.thecvf.com/content_cvpr_2016/html/Redmon_You_Only_Look_CVPR_2016_paper.html. Acesso em: 30 out. 2026.

REN, Shaoqing; HE, Kaiming; GIRSHICK, Ross; SUN, Jian. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks*. In:* ADVANCES in Neural Information Processing Systems. [*S. l.*]: Curran Associates, Inc., 2015. v. 28. Disponível em: https://proceedings.neurips.cc/paper/2015/hash/14bfa6bb14875e45bba028a21ed38046-Abstract.html. Acesso em: 1 nov. 2026.

ULTRALYTICS. **Data Augmentation using Ultralytics YOLO**. Documentação técnica atualizável, sem data de publicação identificada. Disponível em: https://docs.ultralytics.com/guides/yolo-data-augmentation/. Acesso em: 31 out. 2026.

ULTRALYTICS. **Model Training with Ultralytics YOLO**. Documentação técnica atualizável, sem data de publicação identificada. Disponível em: https://docs.ultralytics.com/modes/train/. Acesso em: 31 out. 2026.

ULTRALYTICS. **Model Validation with Ultralytics YOLO**. Disponível em: https://docs.ultralytics.com/modes/val/. Acesso em: 1 nov. 2026.

ULTRALYTICS. **Ultralytics YOLO26**. Disponível em: https://docs.ultralytics.com/models/yolo26/. Acesso em: 1 nov. 2026.

GLOSSÁRIO *(opcional)*

Glossário é uma ferramenta linguística/terminológica para apresentação do significado de palavras ou preferencialmente termos. A palavra tem sua existência no contexto geral, enquanto o termo conta com um significado particular, dependendo da área em que se encontra vinculado. Na apresentação dos termos e significado, sugere-se que sejam apresentadas fontes, contudo, em caso de significados atribuídos pelo próprio autor ou significados contextuais, a apresentação da fonte não é totalmente aplicável.

Exemplos:

Bibliografia: no contexto de trabalhos acadêmicos, a bibliografia muitas vezes está relacionada com o conjunto de insumos que determinada pessoa se apropriou, para a elaboração de uma pesquisa. A bibliografia pode ser lida também como um conjunto ordenado de materiais sobre determinado assunto. Em uma pesquisa, a bibliografia não precisa necessariamente ter sido citada para demonstrar relevância no trabalho, ela muitas vezes é vista também como sugestões para se aprofundar em determinado tópico, diferentemente das referências.

Dissertação: no Brasil, a dissertação é comumente relativa à materialização para a defesa de uma pesquisa à nível de mestrado.

Referência: a principal diferença da referência para a bibliografia, é a citação. As referências, como seu próprio termo diz, são documentos citados para a composição ou apresentação de determinada fonte. Em um trabalho acadêmico, às referências se configuram com uma relação de materiais citados ao longo de uma pesquisa, são a sua base teórica ou metodológica.

APÊNDICE – *(opcional)*

O apêndice é composto por um conteúdo original, inédito e de autoria própria, necessário ou utilizado para enriquecer a compreensão da leitura da pesquisa.

ANEXO *(opcional)*

O anexo é composto por um conteúdo de terceiros ou de autoria própria, necessário ou utilizado para enriquecer a compreensão da leitura da pesquisa.

ÍNDICE *(opcional)*

O índice configura-se, de modo geral, como um instrumento que reúne e muitas vezes direciona o leitor para trechos do documento. Normalmente, segmentando partes ou assuntos possivelmente de interesse do público. Uma diferença do índice e do sumário é de que o sumário apresenta a divisão formal do documento, enquanto o índice exige um processo mais complexo de indexação para sua elaboração.