

UNIVERSIDADE ESTADUAL DO NORTE DO PARANÁ
***CAMPUS* LUIZ MENEGHEL**
CENTRO DE CIÊNCIAS TECNOLÓGICAS
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

Nome Completo Estudante

Título: subtítulo (quando houver)

BANDEIRANTES
ANO

Nome Completo do Estudante

Título: subtítulo (quando houver)

Área de Concentração:
Linha de Pesquisa:
Orientador(a):

BANDEIRANTES
ANO

Ficha catalográfica

Nome Completo Estudante

Título: subtítulo (quando houver)

Trabalho de Conclusão de Curso apresentado ao Curso de Bacharelado em Ciência da Computação da Universidade Estadual do Norte do Paraná, *Campus* Luiz Meneghel, Centro de Ciências Tecnológicas, como requisito parcial para obtenção do título de Bacharel em Ciência da Computação.

Área de Concentração:

Linha de Pesquisa:

Orientador(a):

Banca Examinadora

Nome do/a Professor/a (Orientador/a)
Universidade Estadual do Norte do Paraná (UENP)
UENP | *Campus* Luiz Meneghel

Nome do/a Professor/a (membro interno)
Universidade Estadual do Norte do Paraná (UENP)
UENP | *Campus* Luiz Meneghel

Nome do/a Professor/a (membro externo)
Nome da Universidade (NDU)
Sigla da Universidade | Lotação do docente

Bandeirantes, 00 do MÊS DE ano.

Dedico este trabalho a... *(opcional)*

Agradecimentos

Para o desenvolvimento desta pesquisa, eu agradeço a... *(opcional)*

Epígrafe *(opcional)*

Exemplo de epígrafe:

"A verdadeira viagem de descobrimento
não consiste em procurar novas
paisagens, mas em ter novos olhos"

– **Marcel Proust**

SOBRENOME, Nome Completo com. **Título**: subtítulo (quando houver). Ano. 8 f. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) – Centro de Ciências Tecnológicas, Universidade Estadual do Norte do Paraná, Bandeirantes, Ano.

Resumo

Sugere-se que no resumo contenha uma breve introdução/contextualização da pesquisa, apresentando suscintamente seus objetivos, os resultados obtidos e algumas considerações ou conclusões acerca da pesquisa. Quantidade de caracteres sugeridos: entre 150 e 500.

Norma de referência: ABNT NBR 6028 – Resumo, resenha e recensão (2021).

Palavras-chave: Palavra 1. Palavra 2. Palavra 3. Palavra 4. Palavra 5.

SURNAME, Full Name. **Title**: subtitle (if applicable). Year. 8 p. Undergraduate Thesis (Bachelor's in Computer Science) – Center of Technological Sciences, Northern Paraná State University, Bandeirantes, Year

Absctract

It is suggested that the summary contains a brief introduction/contextualization of the research, briefly presenting its objectives, the results obtained and some considerations or conclusions about the research. Number of suggested characters: between 150 and 500.

Reference standard: ABNT NBR 6028 – Summary, review and review (2021).

Keywords: Word 1. Word 2. Word 3. Word 4. Word 5.

Lista de ilustrações *(opcional)*

Exemplos:

Figura 1 – Título da figura..... 1
Figura 2 – Título da figura..... 2

Lista de tabelas *(opcional)*

Exemplos:

Tabela 1 – Título da figura..... 1
Tabela 2 – Título da figura..... 2

Lista de abreviaturas e siglas *(opcional)*

Exemplos:

ABRV	Associação Brasileira de Radiologia Veterinária
CAPES	Coordenadoria de Aperfeiçoamento de Pessoal de Nível Superior
CNPq	Conselho Nacional de Desenvolvimento Científico e Tecnológico
CRBio-7	Conselho Regional de Biologia da 7ª Região (Paraná)
CREA-PR	Conselho Regional de Engenharia e Agronomia do Paraná
COREN-PR	Conselho Regional de Enfermagem do Paraná
IBGE	Instituto Brasileiro de Geografia e Estatística
SBC	Sociedade Brasileira de Computação

Lista de símbolos *(opcional)*

Exemplos:

$\forall$ Quantificação universal
$\exists$ Quantificação existencial
$\emptyset$ Conjunto nulo ou vazio
$\cup$ União teórica de conjuntos
$\surd$ Raiz quadrada
∞ Infinito
π Pi
$\sum$ Somatório

SUMÁRIO

O sumário é o elemento que sintetiza e direciona os conteúdos contidos em determinado trabalho. *Exemplo:*

1 INTRODUÇÃO..... 14
1.1 Aspecto introdutório A (quando houver)..... 14
1.2 Aspecto metodológico..... 14
1.3 Aspecto introdutório C (quando houver)..... 14

2 DESENVOLVIMENTO..... 15
2.1 Tópico do desenvolvimento A.....
2.1.1 Tópico avançado A (quando houver).....
2.1.2 Tópico avançado B (quando houver).....
2.1.3 Tópico avançado C (quando houver).....
2.2 Tópico do desenvolvimento B.....
2.2.1 Tópico avançado A (quando houver).....
2.2.2 Tópico avançado B (quando houver).....
2.2.3 Tópico avançado C (quando houver).....
2.3 Tópico do desenvolvimento C.....
2.3.1 Tópico avançado A (quando houver).....
2.3.2 Tópico avançado B (quando houver)..... 16
2.3.3 Tópico avançado C (quando houver).....

3 CONCLUSÃO.....

REFERÊNCIAS.....

1 INTRODUÇÃO

A conferência de instrumentos cirúrgicos integra os cuidados relacionados à segurança dos procedimentos operatórios. As orientações da Organização Mundial da Saúde incluem a contagem de instrumentos, compressas e agulhas entre as medidas destinadas a prevenir a retenção inadvertida de materiais no paciente (Organização Mundial da Saúde, 2009). No contexto brasileiro, o Programa Nacional de Segurança do Paciente também situa a segurança cirúrgica entre as ações voltadas à melhoria da qualidade do cuidado (Brasil, 2014). Esses documentos fornecem o contexto assistencial desta pesquisa, cuja investigação se concentra em uma tarefa computacional: identificar e contar instrumentos visíveis em fotografias.

A possibilidade de extrair essas informações de imagens motiva o estudo de ferramentas que possam oferecer apoio à conferência. Uma fotografia, entretanto, registra apenas o que está visível no enquadramento. Por isso, contar os objetos representados em uma imagem não equivale a verificar, por si só, a integridade de uma caixa cirúrgica nem a acompanhar todos os materiais utilizados durante um procedimento. Neste trabalho, a contagem automática é tratada como uma estimativa a ser confrontada com anotações de referência, sem pressupor substituição da conferência profissional ou dos protocolos assistenciais.

Entre as abordagens de visão computacional aplicáveis a essa tarefa está a detecção de objetos, que permite localizar instâncias e atribuir categorias a elas. A proposta original da família *You Only Look Once* (YOLO) reúne a predição de caixas delimitadoras e de classes em uma única rede neural, processando a imagem completa em uma avaliação (Redmon *et al.*, 2016). Para a contagem baseada em detecção, cada instância aceita pelo sistema contribui para o total da imagem e para o total da classe à qual foi atribuída. Assim, objetos não detectados, detecções duplicadas e classificações incorretas podem produzir erros de naturezas distintas.

A literatura apresenta aplicações dessa abordagem ao reconhecimento de instrumentos cirúrgicos. Ran *et al.* (2023) investigaram modificações no YOLOv7x para lidar com dificuldades como semelhança visual, disposição densa dos objetos e variações de iluminação. Jiang *et al.* (2023), por sua vez, avaliaram uma versão modificada do YOLOv5 em imagens de instrumentos, incluindo situações com sobreposição. Esses estudos sustentam a pertinência de investigar detectores dessa família para o problema, mas seus resultados se referem aos respectivos conjuntos de dados e protocolos. Eles não permitem antecipar o desempenho em outras coleções de instrumentos ou condições de aquisição.

Neste trabalho, o recorte de aplicação compreende instrumentos selecio-

nados a partir de uma caixa de apendicectomia utilizada como referência. O conjunto de dados reúne imagens provenientes de bases disponíveis na internet e fotografias de instrumentos fornecidas por uma enfermeira do Hospital Universitário da Universidade Estadual de Londrina (HU-UEL). A preparação dessas fontes envolve revisão das anotações, seleção dos objetos pertencentes ao escopo, padronização das classes e tratamento de imagens duplicadas ou relacionadas. A reunião das duas origens amplia o material disponível para o estudo, mas sua representatividade e sua adequação à avaliação precisam ser examinadas, em vez de presumidas.

1.1 Problema de pesquisa e justificativa

A questão que orienta a pesquisa é: em que medida um modelo da família YOLO permite detectar e contar automaticamente os instrumentos selecionados, em fotografias independentes do treinamento, considerando os erros de localização, classificação e contagem e as condições representadas no conjunto de avaliação?

A análise distingue duas formas de representação dos objetos. Na primeira, os instrumentos são agrupados em categorias gerais: pinças, tesouras, afastadores, porta-agulhas, cabos de bisturi, bicos de aspiração e cúpulas. Na segunda, são representados por classes específicas, com distinção entre variantes retas e curvas quando prevista na taxonomia. Diferenças de tamanho permanecem na mesma classe. A contagem com categorias gerais constitui a prioridade experimental, enquanto a classificação específica permite examinar dificuldades que podem ficar ocultas no agrupamento.

Essa distinção é relevante porque uma contagem total correta pode coexistir com erros de identificação. Por exemplo, atribuir a classe incorreta a um instrumento pode preservar o total de objetos detectados e, ao mesmo tempo, produzir uma contagem incorreta por classe. Além disso, uma omissão e uma detecção indevida podem se compensar numericamente. Por esse motivo, a avaliação proposta considera conjuntamente a qualidade das detecções, o erro de contagem e a análise dos casos de falha, evitando interpretar a concordância do total como evidência suficiente de reconhecimento correto.

A contribuição pretendida é uma avaliação experimental documentada, apoiada em dados revisados e em critérios explícitos de seleção e anotação. A organização das imagens e a rastreabilidade das transformações também integram essa contribuição, pois permitem relacionar os resultados às condições em que o modelo foi desenvolvido. A pesquisa não parte da premissa de que a combinação de fontes, o uso de um modelo maior ou o agrupamento de classes produzirá

necessariamente melhor desempenho; essas escolhas precisam ser examinadas à luz dos experimentos efetivamente realizados.

1.2 Objetivos

O objetivo geral é avaliar a viabilidade técnica da detecção e da contagem automática de instrumentos cirúrgicos selecionados a partir da caixa de apendicectomia de referência, por meio de um modelo da família YOLO, considerando o desempenho e as limitações observadas nas imagens de avaliação.

Para alcançar esse objetivo, estabelecem-se os seguintes objetivos específicos:

a) organizar e revisar as imagens provenientes da internet e do HU-UEL, padronizando as classes e as anotações em caixas delimitadoras;
b) preparar conjuntos de treinamento, validação e teste com controle de duplicatas e de imagens relacionadas, registrando a distribuição por classe e por origem;
c) treinar e avaliar a detecção com categorias gerais, mantendo uma representação específica das anotações para a investigação complementar da identificação dos instrumentos;
d) quantificar o desempenho de detecção e os erros de contagem total e por classe, incluindo a frequência de imagens com contagem correta;
e) analisar os casos de falha e os recursos computacionais empregados, delimitando as condições em que os resultados sustentam a viabilidade da abordagem.

1.3 Delimitação do estudo

O estudo utiliza fotografias estáticas e anotações por caixas delimitadoras, com foco na localização, na identificação e na contagem dos objetos presentes nas imagens. A versão inicialmente selecionada para os experimentos é o YOLO26. O uso de variantes com diferentes capacidades e a avaliação com classes específicas serão documentados de acordo com as execuções concluídas. A viabilidade será discutida a partir das evidências obtidas, sem adotar como resultado uma meta de desempenho previamente desejada.

A seleção das classes depende da correspondência com os instrumentos de referência e da disponibilidade de imagens. A pinça Collin coração não integra a configuração inicial por ausência de exemplos, e as pinças anatômicas contam inicialmente apenas com imagens provenientes da internet. A cúpula integra a contagem entre os objetos de interesse, e os porta-agulhas constituem catego-

ria própria. Essas delimitações impedem que os resultados sejam interpretados como validação de todos os componentes da caixa ou de todas as classes no contexto do HU-UEL.

As fotografias hospitalares disponíveis incluem instrumentos isolados e alguns agrupamentos de objetos. O desempenho nesses registros não será interpretado automaticamente como desempenho em bandejas completas, cenas com oclusão acentuada ou acompanhamento de procedimentos cirúrgicos. Essas condições exigem exemplos e avaliações correspondentes. Do mesmo modo, não se pretende demonstrar redução de eventos adversos, benefício clínico ou substituição de profissionais, mas estabelecer as possibilidades e limitações técnicas da abordagem no recorte investigado.

2 FUNDAMENTAÇÃO TEÓRICA

A contagem de instrumentos por imagem depende de duas etapas logicamente distintas: reconhecer as instâncias visíveis e agregar as detecções aceitas. A primeira envolve localização e classificação; a segunda transforma essas saídas em quantidades. Este capítulo apresenta os conceitos que sustentam essa abordagem, relaciona estudos sobre instrumentos cirúrgicos e discute os cuidados necessários para interpretar os resultados de uma avaliação experimental.

2.1 Representação visual e aprendizagem supervisionada

Na aprendizagem supervisionada, um modelo é ajustado a partir de exemplos associados a respostas de referência. O objetivo não se limita a reproduzir esses exemplos: espera-se que o modelo apresente desempenho adequado em dados novos. A diferença entre ajuste aos dados disponíveis e generalização é central para interpretar o treinamento de redes neurais (Goodfellow; Bengio; Courville, 2016).

Em imagens, as redes convolucionais exploram a organização espacial dos pixels por meio de filtros com parâmetros aprendidos. A aplicação de filtros em diferentes posições permite construir mapas de características, enquanto a composição de camadas possibilita representar padrões progressivamente mais complexos. O compartilhamento de parâmetros reduz a necessidade de aprender uma transformação independente para cada posição da imagem (Goodfellow; Bengio; Courville, 2016). Isso não elimina, entretanto, a influência das condições de aquisição sobre a resposta da rede.

Para instrumentos cirúrgicos, detalhes como a extremidade ativa, a presença de dentes e a curvatura podem ser decisivos para distinguir classes específicas. Uma fotografia em alta resolução pode conter esses detalhes, mas o redimensionamento para a entrada do detector pode torná-los pouco visíveis. Por outro lado, uma imagem que mostra apenas a ponta pode favorecer a identificação de uma característica e oferecer pouca informação sobre a localização do instrumento completo. Essas situações representam exigências diferentes para o sistema e precisam ser consideradas na seleção dos exemplos de treinamento e avaliação.

Classificação de imagens, detecção de objetos e segmentação de instâncias também produzem respostas diferentes. A classificação associa categorias à imagem; a detecção localiza objetos por caixas e atribui classes; a segmentação de instâncias delimita regiões de pixels de cada objeto. Na formulação original do YOLO, a rede estima caixas delimitadoras e probabilidades de classe a partir

da imagem completa (Redmon *et al.*, 2016). Para a contagem aqui investigada, a unidade de interesse é a instância de instrumento, e uma caixa deve representar um objeto, mesmo que ele tenha partes separadas visualmente por oclusão.

Uma caixa delimitadora alinhada aos eixos descreve uma região retangular, não o contorno exato do instrumento. Por isso, pode incluir fundo e partes de outros objetos, sobretudo quando o instrumento está inclinado ou sobreposto. Converter um polígono em sua caixa envolvente permite utilizar a anotação em detecção, mas descarta a informação fina de contorno. A conversão também não corrige automaticamente um polígono que abranja componentes fora do objeto desejado; essa adequação depende de revisão da anotação.

2.2 Detecção com a família YOLO

Redmon *et al.* (2016) propuseram tratar a detecção como uma predição conjunta de localização e classe em uma única rede. Essa formulação utiliza informação da imagem completa para estimar os objetos presentes. A designação YOLO, contudo, passou a reunir modelos com mudanças de arquitetura e treinamento; características da proposta original não devem ser atribuídas automaticamente às versões posteriores.

O YOLO26 é descrito por Jocher *et al.* (2026) como uma família com diferentes escalas de modelo e suporte a tarefas de visão computacional. Para detecção, os autores apresentam uma arquitetura com duas cabeças e a possibilidade de inferência sem uma etapa separada de supressão de não máximos, conhecida pela sigla NMS. Essa supressão é utilizada em detectores para reduzir caixas redundantes a partir de suas pontuações e sobreposição. A existência de um caminho de inferência sem NMS não dispensa a conferência da configuração efetivamente utilizada pelo software.

O estudo de Jocher *et al.* (2026) está disponível como *preprint*; sua descrição técnica é útil para identificar o modelo, mas não constitui validação independente para a aplicação hospitalar deste trabalho. Resultados obtidos pelos autores em bases de referência e dispositivos específicos não antecipam a precisão nem o tempo de execução nas imagens de instrumentos e no equipamento aqui empregado.

O uso de pesos pré-treinados permite iniciar o ajuste de um detector a partir de parâmetros já aprendidos, em vez de partir apenas de uma inicialização aleatória. Ainda assim, o novo treinamento precisa adaptar a saída às classes e aos exemplos disponíveis. O reaproveitamento de representações entre tarefas integra as estratégias de transferência de aprendizagem discutidas por Goodfellow, Bengio e Courville (2016). No presente problema, uma categoria reconhecida

em uma base genérica não equivale à distinção entre instrumentos visualmente próximos.

A escolha entre variantes de menor e maior capacidade envolve recursos computacionais, tempo disponível e desempenho observado. Um modelo maior pode exigir mais memória e processamento sem resolver problemas de anotação, baixa diversidade ou ausência de exemplos representativos. Consequentemente, a comparação de variantes precisa manter condições de avaliação compatíveis e apresentar os resultados medidos, sem tomar o tamanho do modelo como evidência antecipada de superioridade.

2.3 Estudos sobre reconhecimento de instrumentos cirúrgicos

Ran *et al.* (2023) investigaram uma adaptação do YOLOv7x para detectar instrumentos cirúrgicos. O trabalho aborda dificuldades relacionadas à semelhança entre objetos, à disposição dos instrumentos e às condições visuais das imagens. Sua contribuição sustenta o uso da detecção como abordagem pertinente ao problema, mas os resultados relatados estão vinculados às classes, às imagens e ao protocolo empregados naquele estudo.

Jiang *et al.* (2023) estudaram uma versão modificada do YOLOv5 para reconhecimento de instrumentos. A base descrita pelos autores inclui imagens com instrumentos sem empilhamento e com empilhamento, utilizando tecido azul como fundo. A consideração de sobreposição aproxima o estudo de uma dificuldade relevante para a contagem, pois a presença de vários objetos exige que o detector separe instâncias e mantenha sua identificação mesmo quando parte delas está encoberta.

Os dois trabalhos fornecem referências de aplicação, mas não estabelecem uma comparação direta com este TCC. Diferenças na composição das bases, no número de classes, nas condições de captura e nos critérios de avaliação impedem interpretar métricas publicadas como metas automaticamente transferíveis. Tampouco a adoção de uma versão mais recente da família YOLO garante superar os resultados de versões anteriores avaliadas em outros dados.

A contribuição deste trabalho concentra-se na avaliação da contagem para o conjunto de instrumentos selecionado e nas condições documentadas de aquisição e organização das imagens. Isso exige observar não apenas se há detecções, mas quais instrumentos foram omitidos, confundidos ou contados mais de uma vez. As orientações de cirurgia segura da Organização Mundial da Saúde contextualizam a importância da conferência de materiais (Organização Mundial da Saúde, 2009); contudo, uma avaliação computacional em fotografias não demonstra, por si só, redução de eventos adversos ou substituição de procedimen-

tos assistenciais.

2.4 Qualidade dos dados e independência da avaliação

A separação entre treinamento, validação e teste atribui funções diferentes aos dados. O treinamento ajusta os parâmetros; a validação auxilia a escolha de configurações; o teste estima o desempenho após essas escolhas. Utilizar repetidamente o teste para orientar modificações compromete sua função de avaliação independente. Kapoor e Narayanan (2023) discutem como o vazamento de informação pode levar a conclusões excessivamente otimistas em pesquisas baseadas em aprendizagem de máquina.

No caso de fotografias de instrumentos, a independência não pode ser verificada apenas pelo nome do arquivo. Cópias recomprimidas, recortes e transformações de uma mesma fotografia podem preservar grande parte do conteúdo visual. Imagens capturadas em sequência também podem compartilhar objeto, posição, iluminação e fundo. Se exemplos fortemente relacionados forem distribuídos entre treinamento e teste, a avaliação pode refletir a familiaridade com aquela aquisição, em vez da resposta a uma condição nova. O controle desse risco demanda rastreabilidade e agrupamento dos exemplos relacionados antes da divisão.

Identidade digital e similaridade visual são evidências diferentes. Um resumo criptográfico permite comparar os bytes dos arquivos, mas uma alteração de compressão pode modificar esses bytes sem produzir uma mudança visual relevante. Métodos perceptuais auxiliam a busca por candidatos semelhantes, porém não substituem a análise dos casos ambíguos: instrumentos distintos podem ter aparência próxima. O procedimento adotado precisa registrar os critérios e as decisões, sem afirmar que um único limiar garante ausência de vazamento.

O aumento de dados produz variações dos exemplos de treinamento, como mudanças de orientação e aparência. Essas transformações são formas de introduzir variação e regularizar o aprendizado (Goodfellow; Bengio; Courville, 2016). Elas não criam novas sessões independentes de coleta. Quando aplicadas durante o carregamento dos lotes, também não correspondem necessariamente a uma nova quantidade fixa de arquivos no disco. Por essa razão, é mais informativo registrar as técnicas, suas probabilidades e as épocas de aplicação do que apresentar uma multiplicação arbitrária do número de imagens.

Outro aspecto é a distribuição conjunta de classes e origens. Uma classe numerosa pode estar representada quase exclusivamente por imagens da internet, enquanto outra pode ter maior variedade de fotografias hospitalares. Assim, a quantidade de exemplos, isoladamente, não expressa a cobertura das condi-

ções de uso. Para este estudo, resultados separados por origem e por classe ajudam a localizar limitações que uma média global pode ocultar. Classes sem exemplos hospitalares de teste não permitem estimar diretamente seu desempenho nesse domínio.

2.5 Avaliação da detecção

A avaliação exige comparar predições com anotações de referência segundo critérios explícitos. A interseção sobre união, ou IoU, mede a sobreposição entre a caixa predita B_p e a caixa de referência B_r:

$$\text{IoU}(B_p, B_r) = \frac{|B_p \cap B_r|}{|B_p \cup B_r|}. \tag{1}$$

Na Equação 1, as barras representam áreas. A correspondência de uma detecção depende da classe, do limiar de IoU e da regra de associação entre predições e referências. Na avaliação usual de instâncias individuais, uma referência não deve contabilizar várias predições como acertos (Padilla *et al.*, 2021).

Sejam VP, FP e FN as quantidades de verdadeiros positivos, falsos positivos e falsos negativos. Precisão e revocação são expressas, para denominadores não nulos, por

$$P = \frac{VP}{VP + FP}, \qquad R = \frac{VP}{VP + FN}. \tag{2}$$

A precisão relaciona os acertos às detecções aceitas; a revocação relaciona os acertos aos objetos de referência. A precisão média, AP, resume a curva precisão--revocação segundo uma regra de integração ou interpolação. A mAP agrega AP entre classes. As convenções de cálculo precisam ser informadas, pois diferenças de implementação afetam a comparação (Padilla *et al.*, 2021).

Na notação usual, mAP@0,50 utiliza IoU de 0,50; mAP@0,50:0,95 agrega os limiares de 0,50 a 0,95 em passos de 0,05. Esses valores não representam a porcentagem de fotografias cuja contagem está correta. Além disso, o limiar de IoU empregado para julgar a localização não é o limiar de confiança utilizado para aceitar uma predição. A metodologia deve registrar ambos e distinguir a avaliação da curva de detecção da configuração usada para produzir as contagens.

Uma caixa imprecisa pode ainda contribuir com uma unidade para a contagem, enquanto uma classificação errada pode preservar o total e alterar a composição por instrumento. Por isso, as métricas de detecção e de contagem respondem a perguntas complementares. A análise dos erros deve relacionar o resultado numérico às caixas e às classes preditas.

2.6 Contagem por detecção e critérios de interpretação

Considere N imagens e C classes. Para a imagem i, seja D_i o conjunto de detecções aceitas após a aplicação dos critérios de confiança e pós-processamento definidos. A contagem estimada da classe c pode ser escrita como

$$\widehat{n}_{ic} = \sum_{d \in D_i} \mathbf{1}[\text{classe}(d) = c], \qquad \widehat{n}_i = \sum_{c=1}^{C} \widehat{n}_{ic}, \tag{3}$$

em que $\mathbf{1}[\cdot]$ vale um quando a condição é verdadeira e zero caso contrário. Os índices matemáticos das classes vão de um a C, independentemente da numeração adotada nos arquivos de anotação. Essa formulação explicita que a contagem depende das detecções efetivamente aceitas, não de todas as hipóteses internas da rede.

Se n_i é a contagem total de referência, o erro absoluto médio total é

$$\text{MAE}_{\text{total}} = \frac{1}{N} \sum_{i=1}^{N} |\widehat{n}_i - n_i|. \tag{4}$$

O valor informa quantos objetos, em média por imagem, separam a estimativa do total anotado. Para examinar a identificação, calcula-se também o erro por classe, substituindo os totais por $\widehat{n}_{ic}$ e n_{ic}. Quando a maioria das imagens não contém determinada classe, a média calculada sobre todas as imagens pode ser pequena mesmo com falhas nos exemplos positivos; convém, portanto, explicitar o suporte e separar a análise de presença e ausência.

A proporção de imagens com total exato e a proporção com todas as contagens por classe corretas podem ser definidas, respectivamente, por

$$E_{\text{total}} = \frac{1}{N} \sum_{i=1}^{N} \mathbf{1}[\widehat{n}_i = n_i], \tag{5}$$

$$E_{\text{classes}} = \frac{1}{N} \sum_{i=1}^{N} \mathbf{1}[\widehat{n}_{ic} = n_{ic} \text{ para todo } c]. \tag{6}$$

Essas expressões são definições operacionais para organizar a avaliação deste problema, e não resultados experimentais. Uma omissão e uma detecção indevida podem se compensar no total; até a igualdade das contagens por classe pode coexistir com erros de localização. Nenhum desses indicadores substitui a inspeção das detecções.

O Quadro 1 sintetiza as diferenças entre as perguntas de avaliação. O agrupamento em categorias gerais exige atenção adicional: confundir duas clas-

ses específicas pertencentes ao mesmo grupo deixa de ser um erro de classe nessa representação. Logo, um resultado superior com categorias gerais não demonstra, por si só, melhor reconhecimento específico.

Quadro 1 – Interpretação complementar dos resultados

Aspecto	**Pergunta respondida**	**Limite de interpretação**
Detecção	Os instrumentos foram localizados e classificados?	Não informa diretamente a frequência de contagens exatas.
Contagem total	Quantos objetos há na imagem?	Erros podem se compensar; classes podem estar trocadas.
Contagem por classe	A composição por instrumento está correta?	Contagens iguais não garantem caixas corretas.
Imagens sem objetos	O sistema produz detecções indevidas?	Bandejas vazias não representam todos os fundos possíveis.
Tempo de execução	Qual o custo no equipamento utilizado?	Depende da resolução e das etapas incluídas na medição.

Fonte: elaboração própria.

Finalmente, a viabilidade técnica depende do cenário avaliado. Fotografias de objetos isolados, imagens com poucos instrumentos e fotografias de bandejas completas impõem dificuldades distintas. Uma conclusão favorável em um desses cenários deve permanecer limitada às condições observadas. Neste trabalho, a articulação entre detecção, contagem, análise visual dos erros e custo computacional fornece a base para essa delimitação, sem converter desempenho experimental em comprovação de segurança clínica.

3 METODOLOGIA

Este trabalho adota uma abordagem quantitativa, de caráter aplicado e experimental, para avaliar a detecção e a contagem de instrumentos cirúrgicos em fotografias. A unidade de entrada do sistema é uma imagem, enquanto a unidade de anotação é cada instrumento individualmente delimitado. O procedimento compreende a seleção das fontes, a revisão das imagens e anotações, a consolidação das classes, a separação dos dados e o treinamento de um detector. A avaliação considera tanto a localização dos objetos quanto as quantidades obtidas a partir das detecções.

O escopo é delimitado por instrumentos associados à caixa de apendicectomia adotada como referência. A investigação não abrange o reconhecimento irrestrito de materiais cirúrgicos nem a verificação de esterilidade, integridade física ou utilização de cada instrumento. A viabilidade examinada é computacional e condicionada às imagens disponíveis; não corresponde à validação de um dispositivo para uso assistencial.

3.1 Constituição e procedência da base de imagens

A base foi constituída por duas origens: conjuntos obtidos na internet e fotografias disponibilizadas por uma enfermeira do Hospital Universitário da Universidade Estadual de Londrina (HU-UEL). As fontes externas foram identificadas internamente como DS01 a DS07 para preservar sua procedência durante a preparação. Essa identificação é operacional e não substitui a referência ao conjunto original, à sua versão e às condições de uso.

Os conjuntos DS01, DS03, DS04 e DS05 foram obtidos no Roboflow, e o DS06, no Kaggle. O DS07 foi incorporado a partir de imagens cujas anotações haviam sido convertidas de JSONL para o formato YOLO. O DS02 foi integralmente descartado após a identificação de conteúdo repetido em relação ao DS01, incluindo versões com diferenças de borda ou ampliação. Assim, seis conjuntos externos contribuíram para a consolidação. A identificação bibliográfica completa dessas fontes permanece em conferência documental.

As fotografias do HU-UEL foram organizadas inicialmente por instrumento e, em casos específicos, por composição de objetos. Entre as composições anotadas estão imagens com pinça dente de rato, pinça Backhaus e cúpula, além de imagens contendo uma tesoura Metzenbaum reta e outra curva. Também foram incorporadas 100 fotografias de bandejas vazias como exemplos negativos. Imagens sem instrumentos possuem arquivo de anotação vazio; por isso, a ausência de objetos nesses casos é intencional e não deve ser interpretada como falha de

rotulagem.

Os registros fornecidos para o estudo representam instrumentos e superfícies de apoio. Não se atribui a essas fotografias a condição de registros de procedimentos cirúrgicos em andamento. Datas, dispositivos e organização das sessões de aquisição devem acompanhar a documentação da coleta para permitir interpretar sua diversidade. A disponibilização por uma profissional do hospital não é apresentada neste trabalho como parecer de comitê de ética ou como autorização institucional formal.

A Tabela 2 apresenta a composição registrada no manifesto da revisão v3. As quantidades correspondem ao material após a seleção, e não ao volume originalmente baixado. A distinção entre imagens e objetos é necessária porque uma fotografia pode conter várias instâncias, inclusive de uma mesma classe.

Tabela 2 – Composição da base consolidada por origem

Origem	Imagens	Objetos anotados
DS01	289	414
DS03	115	129
DS04	249	382
DS05	85	85
DS06	2.964	4.149
DS07	1.008	1.008
Subtotal da internet	4.710	6.167
HU-UEL	5.617	6.547
Total	10.327	12.714

Fonte: elaboração própria, com base nos manifestos da revisão v3 (2026).
Nota: as 100 imagens negativas estão incluídas no total do HU-UEL e não acrescentam objetos.

3.2 Seleção, anotação e padronização dos instrumentos

A seleção foi orientada pela correspondência com os instrumentos definidos para o estudo, pela possibilidade de identificação visual e pela adequação das anotações. Foram retiradas imagens de baixa qualidade que impediam a inspeção, exemplos incompatíveis com a caixa de referência e versões repetidas identificadas durante a revisão. O processo considerou conteúdo e aparência, e não apenas nomes de arquivos ou rótulos originais. Dúvidas sobre determinados instrumentos foram submetidas à apreciação da enfermeira colaboradora; não foi realizado um estudo formal de concordância entre múltiplos anotadores.

Instrumentos visualmente semelhantes, mas fora do escopo, não foram incluídos apenas para aumentar o volume da base. Quando sua presença poderia gerar supervisão contraditória, optou-se pela retirada da imagem, inclusive

se ela também apresentasse um objeto desejado. Um exemplo foi o afastador Army-Navy, cuja aparência em determinadas posições se aproxima daquela do Farabeuf. Essa escolha delimita o domínio do experimento: o detector não é avaliado como classificador universal de instrumentos semelhantes aos selecionados.

A revisão dos conjuntos externos foi realizada com apoio do CVAT e de inspeções no Roboflow. As imagens do HU-UEL foram anotadas no X-AnyLabeling com caixas delimitadoras horizontais, uma por objeto. O arquivo exportado associa a cada caixa um identificador de classe e quatro coordenadas normalizadas, correspondentes ao centro, à largura e à altura. As anotações foram organizadas de forma que cada imagem e seu arquivo de rótulos compartilhassem o mesmo nome-base.

Nos conjuntos com polígonos, a conversão para detecção utilizou os menores e maiores valores de cada coordenada para obter a caixa envolvente de cada instância. Esse procedimento conserva a extensão espacial do contorno anotado, mas não verifica sua pertinência semântica. Por isso, caixas que abrangiam componentes indesejados, como tubos conectados ao bico de aspiração ou partes além do cabo de bisturi, foram submetidas à revisão manual. No DS07, as anotações convertidas de JSONL foram inspecionadas visualmente, e foram mantidas as classes correspondentes a porta-agulhas e cabos de bisturi.

Foram preservadas duas taxonomias. A específica distingue 17 classes, incluindo versões retas e curvas de Kelly, Mayo e Metzenbaum. A geral reúne os mesmos objetos em sete categorias, utilizadas no primeiro treinamento. Diferenças de tamanho não originam classes distintas. O porta-agulhas permanece separado das tesouras, apesar da semelhança visual de alguns modelos. A pinça Collin coração não integra a configuração inicial por falta de imagens, e a Kocher curva não integra o conjunto de instrumentos selecionado.

A Tabela 3 explicita a correspondência entre as taxonomias e a quantidade de objetos em cada categoria geral. Os nomes em português são utilizados na apresentação do trabalho; os identificadores em inglês são empregados nos arquivos de treinamento. As duas organizações mantêm as mesmas caixas e divisões, alterando apenas os identificadores de classe. Portanto, não constituem duas bases independentes.

A representação é desigual entre classes e origens. Por exemplo, as pinças anatômicas e os cabos de bisturi da base consolidada provêm exclusivamente da internet. Consequentemente, um resultado agregado satisfatório não demonstra desempenho hospitalar para todas as classes. Essa diferença deve ser considerada na análise dos erros e na apresentação dos resultados por origem.

Tabela 3 – Correspondência entre classes específicas e categorias gerais

Categoria geral	Classes específicas representadas	Objetos
Pinças	Allis; anatômica; Backhaus; Kelly curva; Kelly reta; Foerster; dente de rato; Kocher reta	4.907
Tesouras	Mayo curva; Mayo reta; Metzenbaum curva; Metzenbaum reta	3.976
Afastadores	Farabeuf	848
Porta-agulhas	Porta-agulhas	760
Cabos de bisturi	Cabo de bisturi	1.673
Bicos de aspiração	Bico de aspiração, incluindo exemplares Yankauer aceitos na revisão	244
Cúpulas	Cúpula	306
Total	17 classes específicas e 7 categorias gerais	12.714

Fonte: elaboração própria, com base no mapeamento de classes e no manifesto de objetos da revisão v3 (2026).

3.3 Consolidação, verificação e separação dos dados

A consolidação foi executada por scripts Python sobre cópias dos conjuntos selecionados. Os arquivos brutos foram mantidos separados da base de trabalho. Foram produzidos manifestos de imagens e objetos, mapas de classes e registros de exclusões, de forma a vincular cada arquivo consolidado à origem e à divisão atribuída. A organização foi preparada no Windows e transferida para o Mac utilizado no treinamento.

A verificação combinou comparação de nomes-base, leitura dos rótulos, conferência das classes e validação geométrica das caixas. Foram calculados resumos criptográficos SHA-256 para conferir integridade de arquivos, além de resumos dos pixels decodificados e assinaturas perceptuais dHash para investigar repetições. Esses mecanismos têm finalidades distintas: igualdade criptográfica verifica o conteúdo comparado, enquanto proximidade perceptual apenas indica candidatos que exigem inspeção. Fundos semelhantes podem produzir assinaturas próximas mesmo quando os objetos são diferentes.

Na revisão complementar, pares entre divisões com distância de Hamming de até dois bits em assinaturas dHash de 64 bits foram selecionados para inspeção visual. Essa busca resultou em 373 pares candidatos envolvendo 197 imagens; a sequência de 42 imagens do DS07 foi acrescentada à coleta visual, totalizando 239 imagens examinadas nessa etapa. Esses números descrevem candidatos e material revisado, não quantidades de duplicatas. Vários pares do DS06 foram reconhecidos como cenas distintas sobre fundos semelhantes.

A revisão também identificou uma imagem do DS05 com três caixas para um único objeto. Duas caixas coincidentes abrangiam praticamente toda a fo-

tografia, enquanto a terceira delimitava o instrumento; as duas primeiras foram removidas. Em outro caso, foi excluída a versão de menor resolução de uma fotografia repetida do DS04, juntamente com seu rótulo. Imagens relacionadas já identificadas foram mantidas na mesma divisão, e 42 fotografias de uma sequência de cabo de bisturi do DS07 foram reunidas em um único grupo de treino.

O agrupamento procura reduzir a dependência entre dados usados para aprender e dados usados para avaliar. Como discutem Kapoor e Narayanan (2023), falhas na separação podem produzir conclusões excessivamente otimistas. Entretanto, a ausência de grupos cadastrados em mais de uma divisão não comprova independência de todas as sessões de aquisição. A base contém imagens de instrumentos reposicionados em cenários semelhantes, e os registros disponíveis não permitem reconstruir integralmente todas as sessões das fontes externas. Essa restrição permanece como limitação do experimento.

A divisão preserva conjuntos de treino, validação e teste, com as quantidades da Tabela 4. A distribuição foi ajustada pelas revisões de grupos e duplicatas, em vez de se refazer uma separação aleatória apenas para obter percentuais exatos. A mesma atribuição foi mantida nas duas taxonomias. Entre as imagens negativas, 80 pertencem ao treino, dez à validação e dez ao teste.

Tabela 4 – Distribuição das imagens e dos objetos por divisão

Divisão	Imagens	Objetos anotados
Treino	8.304	10.044
Validação	1.015	1.293
Teste	1.008	1.377
Total	10.327	12.714

Fonte: elaboração própria, com base nos manifestos da revisão v3 (2026).

3.4 Ambiente computacional e configuração do treinamento

O ambiente de execução utiliza um Mac mini com chip Apple M4 e 16 GB de memória unificada, com aceleração pela interface Metal Performance Shaders (MPS) do PyTorch. O ambiente informado nos testes compreende Python 3.13, PyTorch 2.15.0 e Ultralytics 8.4.192, em arquitetura arm64. A configuração foi mantida após os testes de instalação para evitar mudanças de dependências durante o experimento.

Antes da execução principal, foi realizado um piloto de três épocas com uma fração de 10% do conjunto de treino, destinado a verificar carregamento, uso do dispositivo e funcionamento do procedimento. Esse piloto não foi adotado como resultado definitivo de viabilidade, nem seus pesos foram utilizados como

ponto de partida do treinamento principal. Para este, selecionou-se o YOLO26n com pesos pré-treinados e utilização integral da divisão de treino.

A variante de menor porte foi escolhida em razão do recurso computacional disponível e do tempo de execução observado no piloto. Essa escolha não pressupõe superioridade em relação a modelos maiores. Da mesma forma, o uso de pré-treinamento constitui uma estratégia de inicialização e adaptação, sem garantir precisão para instrumentos não representados adequadamente nos dados.

A configuração principal está sintetizada na Tabela 5. O limite de 50 épocas foi definido como orçamento inicial de treinamento, e não como valor ótimo estabelecido por busca sistemática. A parada antecipada foi configurada com tolerância de dez épocas sem melhora no critério de validação da implementação. A quantidade efetivamente executada, a época selecionada e a duração serão informadas a partir dos registros, após o encerramento.

Tabela 5 – Parâmetros definidos para o treinamento principal

Parâmetro	Configuração
Modelo e tarefa	YOLO26n; detecção de caixas horizontais
Classes e fração do treino	7 categorias; 100% da divisão
Épocas e tolerância de parada	Máximo de 50; tolerância de 10
Dimensão de entrada configurada	640 pixels
Lote físico / lote nominal	4 / 64
Otimizador	AdamW
Taxa inicial / fator final	0,001 / 0,01
Decaimento de pesos solicitado	0,0005
Parâmetro de momento	0,9
Aquecimento	3 épocas
Semente	42
Dispositivo e precisão mista	MPS; precisão mista desativada
Processos auxiliares / cache de imagens	0 / desativado
Salvamento periódico	A cada 5 épocas

Fonte: elaboração própria, com base no script de treinamento da revisão v3 (2026).
Nota: o lote nominal é uma referência interna para a otimização; não equivale ao número de imagens simultaneamente processadas no dispositivo.

O AdamW emprega decaimento de pesos desacoplado da atualização adaptativa, conforme a formulação de Loshchilov e Hutter (2019). Sua adoção neste experimento representa uma escolha explícita de otimização, sem reproduzir integralmente a receita de pré-treinamento do YOLO26. A taxa de aprendizagem foi configurada com aquecimento e redução linear, sem busca automática de hiperparâmetros. As definições operacionais dos argumentos são apresentadas na documentação do software (Ultralytics, 2026b).

A dimensão de entrada é aplicada durante o carregamento e o processa-

mento das imagens. Os arquivos preservados na base não foram recomprimidos nem redimensionados por essa etapa. Entretanto, a redução para a entrada da rede pode eliminar detalhes de instrumentos finos, aspecto que será examinado na análise dos erros. O processamento utiliza lote físico de quatro imagens, sem cache de imagens em memória e sem processos auxiliares de carregamento, priorizando a execução no equipamento disponível.

A semente foi fixada e foi solicitada execução determinística. Isso favorece a rastreabilidade, mas não implica reprodução bit a bit, pois determinadas operações do ambiente MPS podem não dispor de implementação determinística. Os argumentos efetivos, as versões dos pacotes e os caminhos dos arquivos são registrados junto à execução. O treinamento preserva o último estado e o estado selecionado pelo critério de validação da biblioteca; o conjunto de teste não participa dessa seleção.

3.5 Aumento de dados durante o treinamento

O aumento de dados foi configurado para aplicação durante o treinamento, sem produzir uma nova coleção permanente de fotografias. A estratégia procura introduzir variações de aparência e disposição dos objetos e constitui uma forma de regularização (Goodfellow; Bengio; Courville, 2016). A política solicitada compreende espelhamentos horizontal e vertical com probabilidade de 0,5 cada, rotações de até aproximadamente $\pm 15°$, translação relativa de 0,1 e variação de escala de 0,25. Os parâmetros de matiz, saturação e valor foram definidos, respectivamente, como 0,015, 0,3 e 0,2.

A transformação mosaic foi configurada com probabilidade de 0,5 para compor entradas a partir de diferentes imagens. Sua aplicação busca ampliar a variedade de composições, mas não reproduz necessariamente oclusões e interações físicas entre instrumentos em uma bandeja real. MixUp, Copy-Paste, cisalhamento e perspectiva adicional foram desativados. A documentação da Ultralytics descreve essas operações e seus parâmetros (Ultralytics, 2026a).

Foi prevista a desativação do mosaic nas dez últimas épocas da agenda programada. Caso a parada antecipada ocorra antes dessa etapa, não se pode afirmar que o modelo tenha passado por esse período final sem mosaic. As transformações efetivamente carregadas, inclusive componentes opcionais dependentes do ambiente, são registradas para conferir a correspondência com a configuração solicitada. Exemplos de lotes transformados permitem inspecionar cortes e caixas produzidos durante o treinamento.

As 8.304 imagens de treino permanecem como quantidade física de referência. Repetições ao longo das épocas e variações geradas durante o processa-

mento não são contabilizadas como fotografias independentes. Validação e teste não recebem a política aleatória de aumento de dados do treino, embora também necessitem do pré-processamento de entrada. Essa distinção evita confundir expansão de apresentações do mesmo material com aumento da diversidade original da amostra.

3.6 Protocolo de avaliação da detecção e da contagem

A avaliação será realizada após o encerramento do treinamento. A seleção do estado do modelo e o ajuste do limiar de confiança utilizarão a validação, preservando o teste para a aplicação do procedimento escolhido. O limiar determina quais predições serão aceitas para a contagem; sua definição deve considerar omissões e falsas detecções, sem utilizar o teste para procurar a configuração mais favorável.

Para detecção, serão examinados precisão, revocação, mAP com interseção sobre união de 0,50 e mAP no intervalo de 0,50 a 0,95, com os resultados discriminados por categoria. A interpretação seguirá as definições apresentadas na fundamentação e as distinções entre métricas discutidas por Padilla *et al.* (2021). As opções efetivas de inferência e associação de predições serão registradas, pois não devem ser inferidas exclusivamente a partir da designação YOLO26.

Para contagem, as detecções aceitas serão agregadas por imagem e por categoria. Serão calculados o erro absoluto médio e a proporção de imagens com contagem total correta, acompanhados dos resultados por classe. Também será examinada a coincidência do vetor de contagens das categorias, que exige acerto simultâneo em todas elas. Essa análise é mais restritiva que o acerto do total: uma falsa detecção e uma omissão podem compensar-se numericamente sem que os objetos tenham sido reconhecidos corretamente.

A análise qualitativa distinguirá omissões, contagens excedentes, confusões entre categorias e problemas de localização. Serão considerados o número de objetos na cena, sua sobreposição e a origem das imagens, conforme a informação disponível. Resultados do HU-UEL e da internet serão apresentados separadamente quando houver suporte amostral, evitando atribuir desempenho hospitalar a uma categoria avaliada apenas em imagens externas.

O custo computacional será descrito a partir do equipamento e das condições reais de execução. A duração do treinamento e, quando medido, o tempo de inferência deverão indicar o que foi incluído na medição, como carregamento, pré-processamento e pós-processamento. Tempos obtidos em outros dispositivos ou bases não serão empregados como resultados deste experimento.

A interpretação da viabilidade combinará desempenho de detecção, erros

de contagem, condições de falha e custo computacional. Não foi estabelecido um limiar clínico de aceitação nem será atribuída aprovação assistencial ao modelo. A conclusão deverá permanecer limitada aos cenários avaliados e à necessidade de conferência humana. Fotografias futuras de uma nova sessão poderão ampliar a avaliação externa, desde que não sejam utilizadas para ajustar o mesmo modelo que será avaliado nelas.

3 CONCLUSÃO

Com a presente pesquisa, conclui-se que...

REFERÊNCIAS

BRASIL. MINISTÉRIO DA SAÚDE. **Documento de referência para o Programa Nacional de Segurança do Paciente**. Brasília, DF: Ministério da Saúde, 2014. 40 p. ISBN 978-85-334-2130-1. Disponível em: https://bvsms.saude.gov.br/bvs/publicacoes/documento_referencia_programa_nacional_seguranca.pdf. Acesso em: 30 out. 2026.

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. **Deep Learning**. Cambridge, MA: MIT Press, 2016. Disponível em: https://www.deeplearningbook.org/. Acesso em: 31 out. 2026.

JIANG, Kaile; PAN, Shuwan; YANG, Luxuan; YU, Jie; LIN, Yuanda; WANG, Huaiqian. Surgical Instrument Recognition Based on Improved YOLOv5. **Applied Sciences**, Basel, v. 13, n. 21, 11709, 2023. DOI: 10.3390/app132111709. Disponível em: https://www.mdpi.com/2076-3417/13/21/11709. Acesso em: 30 out. 2026.

JOCHER, Glenn; QIU, Jing; LIU, Mengyu; LYU, Shuai; AKYON, Fatih Cagatay; KALFAOGLU, Muhammet Esat. **Ultralytics YOLO26: Unified Real-Time End-to-End Vision Models**. Preprint. Versão 1. arXiv. 2 jun. 2026. DOI: 10.48550/arXiv.2606.03748. Disponível em: https://arxiv.org/abs/2606.03748v1. Acesso em: 31 out. 2026.

KAPOOR, Sayash; NARAYANAN, Arvind. Leakage and the reproducibility crisis in machine-learning-based science. **Patterns**, v. 4, n. 9, 100804, 2023. DOI: 10.1016/j.patter.2023.100804. Disponível em: https://doi.org/10.1016/j.patter.2023.100804. Acesso em: 31 out. 2026.

LOSHCHILOV, Ilya; HUTTER, Frank. Decoupled Weight Decay Regularization. *In:* INTERNATIONAL Conference on Learning Representations. [*S. l.: s. n.*], 2019. Versão dos autores do artigo publicado na ICLR 2019. Disponível em: https://arxiv.org/abs/1711.05101v3. Acesso em: 31 out. 2026.

ORGANIZAÇÃO MUNDIAL DA SAÚDE. **Segundo desafio global para a segurança do paciente: cirurgias seguras salvam vidas (orientações para cirurgia segura da OMS)**. Tradução: Marcela Sánchez Nilo e Irma Angélica Durán. Rio de Janeiro: Organização Pan-Americana da Saúde, Ministério da Saúde e Agência Nacional de Vigilância Sanitária, 2009. 211 p. ISBN 978-85-87943-97-2. Disponível em: https://bvsms.saude.gov.br/bvs/publicacoes/seguranca_paciente_cirurgias_seguras_salvam_vidas.pdf. Acesso em: 30 out. 2026.

PADILLA, Rafael; PASSOS, Wesley L.; DIAS, Thadeu L. B.; NETTO, Sergio L.; SILVA, Eduardo A. B. da. A Comparative Analysis of Object Detection Metrics with a Companion Open-Source Toolkit. **Electronics**, Basel, v. 10, n. 3, 279, 2021. DOI: 10.3390/electronics10030279. Disponível em: https://www.mdpi.com/2079-9292/10/3/279. Acesso em: 31 out. 2026.

RAN, Boping; HUANG, Bo; LIANG, Shunpan; HOU, Yulei. Surgical Instrument Detection Algorithm Based on Improved YOLOv7x. **Sensors**, Basel, v. 23, n. 11, 5037, 2023. DOI: 10.3390/s23115037. Disponível em: https://www.mdpi.com/1424-8220/23/11/5037. Acesso em: 30 out. 2026.

REDMON, Joseph; DIVVALA, Santosh; GIRSHICK, Ross; FARHADI, Ali. You Only Look Once: Unified, Real-Time Object Detection. *In:* IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2016, Las Vegas. **Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition**. Las Vegas: IEEE, 2016. p. 779–788. Disponível em: https://openaccess.thecvf.com/content_cvpr_2016/html/Redmon_You_Only_Look_CVPR_2016_paper.html. Acesso em: 30 out. 2026.

ULTRALYTICS. **Data Augmentation using Ultralytics YOLO**. Documentação técnica atualizável, sem data de publicação identificada. Disponível em: https://docs.ultralytics.com/guides/yolo-data-augmentation/. Acesso em: 31 out. 2026.

ULTRALYTICS. **Model Training with Ultralytics YOLO**. Documentação técnica atualizável, sem data de publicação identificada. Disponível em: https://docs.ultralytics.com/modes/train/. Acesso em: 31 out. 2026.

GLOSSÁRIO *(opcional)*

Glossário é uma ferramenta linguística/terminológica para apresentação do significado de palavras ou preferencialmente termos. A palavra tem sua existência no contexto geral, enquanto o termo conta com um significado particular, dependendo da área em que se encontra vinculado. Na apresentação dos termos e significado, sugere-se que sejam apresentadas fontes, contudo, em caso de significados atribuídos pelo próprio autor ou significados contextuais, a apresentação da fonte não é totalmente aplicável.

Exemplos:

Bibliografia: no contexto de trabalhos acadêmicos, a bibliografia muitas vezes está relacionada com o conjunto de insumos que determinada pessoa se apropriou, para a elaboração de uma pesquisa. A bibliografia pode ser lida também como um conjunto ordenado de materiais sobre determinado assunto. Em uma pesquisa, a bibliografia não precisa necessariamente ter sido citada para demonstrar relevância no trabalho, ela muitas vezes é vista também como sugestões para se aprofundar em determinado tópico, diferentemente das referências.

Dissertação: no Brasil, a dissertação é comumente relativa à materialização para a defesa de uma pesquisa à nível de mestrado.

Referência: a principal diferença da referência para a bibliografia, é a citação. As referências, como seu próprio termo diz, são documentos citados para a composição ou apresentação de determinada fonte. Em um trabalho acadêmico, às referências se configuram com uma relação de materiais citados ao longo de uma pesquisa, são a sua base teórica ou metodológica.

APÊNDICE – *(opcional)*

O apêndice é composto por um conteúdo original, inédito e de autoria própria, necessário ou utilizado para enriquecer a compreensão da leitura da pesquisa.

ANEXO *(opcional)*

O anexo é composto por um conteúdo de terceiros ou de autoria própria, necessário ou utilizado para enriquecer a compreensão da leitura da pesquisa.

ÍNDICE *(opcional)*

O índice configura-se, de modo geral, como um instrumento que reúne e muitas vezes direciona o leitor para trechos do documento. Normalmente, segmentando partes ou assuntos possivelmente de interesse do público. Uma diferença do índice e do sumário é de que o sumário apresenta a divisão formal do documento, enquanto o índice exige um processo mais complexo de indexação para sua elaboração.