

UNIVERSIDADE ESTADUAL DO NORTE DO PARANÁ
***CAMPUS* LUIZ MENEGHEL**
CENTRO DE CIÊNCIAS TECNOLÓGICAS
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

Nome Completo Estudante

Título: subtítulo (quando houver)

BANDEIRANTES
ANO

Nome Completo do Estudante

Título: subtítulo (quando houver)

Área de Concentração:
Linha de Pesquisa:
Orientador(a):

BANDEIRANTES
ANO

Ficha catalográfica

Nome Completo Estudante

Título: subtítulo (quando houver)

Trabalho de Conclusão de Curso apresentado ao Curso de Bacharelado em Ciência da Computação da Universidade Estadual do Norte do Paraná, *Campus* Luiz Meneghel, Centro de Ciências Tecnológicas, como requisito parcial para obtenção do título de Bacharel em Ciência da Computação.

Área de Concentração:

Linha de Pesquisa:

Orientador(a):

Banca Examinadora

Nome do/a Professor/a (Orientador/a)
Universidade Estadual do Norte do Paraná (UENP)
UENP | *Campus* Luiz Meneghel

Nome do/a Professor/a (membro interno)
Universidade Estadual do Norte do Paraná (UENP)
UENP | *Campus* Luiz Meneghel

Nome do/a Professor/a (membro externo)
Nome da Universidade (NDU)
Sigla da Universidade | Lotação do docente

Bandeirantes, 00 do MÊS DE ano.

Dedico este trabalho a... *(opcional)*

Agradecimentos

Para o desenvolvimento desta pesquisa, eu agradeço a... *(opcional)*

Epígrafe *(opcional)*

Exemplo de epígrafe:

"A verdadeira viagem de descobrimento
não consiste em procurar novas
paisagens, mas em ter novos olhos"

– **Marcel Proust**

SOBRENOME, Nome Completo com. **Título**: subtítulo (quando houver). Ano. 8 f. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) – Centro de Ciências Tecnológicas, Universidade Estadual do Norte do Paraná, Bandeirantes, Ano.

Resumo

Sugere-se que no resumo contenha uma breve introdução/contextualização da pesquisa, apresentando suscintamente seus objetivos, os resultados obtidos e algumas considerações ou conclusões acerca da pesquisa. Quantidade de caracteres sugeridos: entre 150 e 500.

Norma de referência: ABNT NBR 6028 – Resumo, resenha e recensão (2021).

Palavras-chave: Palavra 1. Palavra 2. Palavra 3. Palavra 4. Palavra 5.

SURNAME, Full Name. **Title**: subtitle (if applicable). Year. 8 p. Undergraduate Thesis (Bachelor's in Computer Science) – Center of Technological Sciences, Northern Paraná State University, Bandeirantes, Year

Absctract

It is suggested that the summary contains a brief introduction/contextualization of the research, briefly presenting its objectives, the results obtained and some considerations or conclusions about the research. Number of suggested characters: between 150 and 500.

Reference standard: ABNT NBR 6028 – Summary, review and review (2021).

Keywords: Word 1. Word 2. Word 3. Word 4. Word 5.

Lista de ilustrações *(opcional)*

Exemplos:

Figura 1 – Título da figura..... 1
Figura 2 – Título da figura..... 2

Lista de tabelas *(opcional)*

Exemplos:

Tabela 1 – Título da figura..... 1
Tabela 2 – Título da figura..... 2

Lista de abreviaturas e siglas *(opcional)*

Exemplos:

ABRV	Associação Brasileira de Radiologia Veterinária
CAPES	Coordenadoria de Aperfeiçoamento de Pessoal de Nível Superior
CNPq	Conselho Nacional de Desenvolvimento Científico e Tecnológico
CRBio-7	Conselho Regional de Biologia da 7ª Região (Paraná)
CREA-PR	Conselho Regional de Engenharia e Agronomia do Paraná
COREN-PR	Conselho Regional de Enfermagem do Paraná
IBGE	Instituto Brasileiro de Geografia e Estatística
SBC	Sociedade Brasileira de Computação

Lista de símbolos *(opcional)*

Exemplos:

$\forall$ Quantificação universal
$\exists$ Quantificação existencial
$\emptyset$ Conjunto nulo ou vazio
$\cup$ União teórica de conjuntos
$\surd$ Raiz quadrada
∞ Infinito
π Pi
$\sum$ Somatório

SUMÁRIO

O sumário é o elemento que sintetiza e direciona os conteúdos contidos em determinado trabalho. *Exemplo:*

1 INTRODUÇÃO..... 14
1.1 Aspecto introdutório A (quando houver)..... 14
1.2 Aspecto metodológico..... 14
1.3 Aspecto introdutório C (quando houver)..... 14

2 DESENVOLVIMENTO..... 15
2.1 Tópico do desenvolvimento A.....
2.1.1 Tópico avançado A (quando houver).....
2.1.2 Tópico avançado B (quando houver).....
2.1.3 Tópico avançado C (quando houver).....
2.2 Tópico do desenvolvimento B.....
2.2.1 Tópico avançado A (quando houver).....
2.2.2 Tópico avançado B (quando houver).....
2.2.3 Tópico avançado C (quando houver).....
2.3 Tópico do desenvolvimento C.....
2.3.1 Tópico avançado A (quando houver).....
2.3.2 Tópico avançado B (quando houver)..... 16
2.3.3 Tópico avançado C (quando houver).....

3 CONCLUSÃO.....

REFERÊNCIAS.....

1 INTRODUÇÃO

A conferência de instrumentos cirúrgicos integra os cuidados relacionados à segurança dos procedimentos operatórios. As orientações da Organização Mundial da Saúde incluem a contagem de instrumentos, compressas e agulhas entre as medidas destinadas a prevenir a retenção inadvertida de materiais no paciente (Organização Mundial da Saúde, 2009). No contexto brasileiro, o Programa Nacional de Segurança do Paciente também situa a segurança cirúrgica entre as ações voltadas à melhoria da qualidade do cuidado (Brasil, 2014). Esses documentos fornecem o contexto assistencial desta pesquisa, cuja investigação se concentra em uma tarefa computacional: identificar e contar instrumentos visíveis em fotografias.

A possibilidade de extrair essas informações de imagens motiva o estudo de ferramentas que possam oferecer apoio à conferência. Uma fotografia, entretanto, registra apenas o que está visível no enquadramento. Por isso, contar os objetos representados em uma imagem não equivale a verificar, por si só, a integridade de uma caixa cirúrgica nem a acompanhar todos os materiais utilizados durante um procedimento. Neste trabalho, a contagem automática é tratada como uma estimativa a ser confrontada com anotações de referência, sem pressupor substituição da conferência profissional ou dos protocolos assistenciais.

Entre as abordagens de visão computacional aplicáveis a essa tarefa está a detecção de objetos, que permite localizar instâncias e atribuir categorias a elas. A proposta original da família *You Only Look Once* (YOLO) reúne a predição de caixas delimitadoras e de classes em uma única rede neural, processando a imagem completa em uma avaliação (Redmon *et al.*, 2016). Para a contagem baseada em detecção, cada instância aceita pelo sistema contribui para o total da imagem e para o total da classe à qual foi atribuída. Assim, objetos não detectados, detecções duplicadas e classificações incorretas podem produzir erros de naturezas distintas.

A literatura apresenta aplicações dessa abordagem ao reconhecimento de instrumentos cirúrgicos. Ran *et al.* (2023) investigaram modificações no YOLOv7x para lidar com dificuldades como semelhança visual, disposição densa dos objetos e variações de iluminação. Jiang *et al.* (2023), por sua vez, avaliaram uma versão modificada do YOLOv5 em imagens de instrumentos, incluindo situações com sobreposição. Esses estudos sustentam a pertinência de investigar detectores dessa família para o problema, mas seus resultados se referem aos respectivos conjuntos de dados e protocolos. Eles não permitem antecipar o desempenho em outras coleções de instrumentos ou condições de aquisição.

Neste trabalho, o recorte de aplicação compreende instrumentos selecio-

nados a partir de uma caixa de apendicectomia utilizada como referência. O conjunto de dados reúne imagens provenientes de bases disponíveis na internet e fotografias de instrumentos fornecidas por uma enfermeira do Hospital Universitário da Universidade Estadual de Londrina (HU-UEL). A preparação dessas fontes envolve revisão das anotações, seleção dos objetos pertencentes ao escopo, padronização das classes e tratamento de imagens duplicadas ou relacionadas. A reunião das duas origens amplia o material disponível para o estudo, mas sua representatividade e sua adequação à avaliação precisam ser examinadas, em vez de presumidas.

1.1 Problema de pesquisa e justificativa

A questão que orienta a pesquisa é: em que medida um modelo da família YOLO permite detectar e contar automaticamente os instrumentos selecionados, em fotografias independentes do treinamento, considerando os erros de localização, classificação e contagem e as condições representadas no conjunto de avaliação?

A análise distingue duas formas de representação dos objetos. Na primeira, os instrumentos são agrupados em categorias gerais: pinças, tesouras, afastadores, porta-agulhas, cabos de bisturi, bicos de aspiração e cúpulas. Na segunda, são representados por classes específicas, com distinção entre variantes retas e curvas quando prevista na taxonomia. Diferenças de tamanho permanecem na mesma classe. A contagem com categorias gerais constitui a prioridade experimental, enquanto a classificação específica permite examinar dificuldades que podem ficar ocultas no agrupamento.

Essa distinção é relevante porque uma contagem total correta pode coexistir com erros de identificação. Por exemplo, atribuir a classe incorreta a um instrumento pode preservar o total de objetos detectados e, ao mesmo tempo, produzir uma contagem incorreta por classe. Além disso, uma omissão e uma detecção indevida podem se compensar numericamente. Por esse motivo, a avaliação proposta considera conjuntamente a qualidade das detecções, o erro de contagem e a análise dos casos de falha, evitando interpretar a concordância do total como evidência suficiente de reconhecimento correto.

A contribuição pretendida é uma avaliação experimental documentada, apoiada em dados revisados e em critérios explícitos de seleção e anotação. A organização das imagens e a rastreabilidade das transformações também integram essa contribuição, pois permitem relacionar os resultados às condições em que o modelo foi desenvolvido. A pesquisa não parte da premissa de que a combinação de fontes, o uso de um modelo maior ou o agrupamento de classes produzirá

necessariamente melhor desempenho; essas escolhas precisam ser examinadas à luz dos experimentos efetivamente realizados.

1.2 Objetivos

O objetivo geral é avaliar a viabilidade técnica da detecção e da contagem automática de instrumentos cirúrgicos selecionados a partir da caixa de apendicectomia de referência, por meio de um modelo da família YOLO, considerando o desempenho e as limitações observadas nas imagens de avaliação.

Para alcançar esse objetivo, estabelecem-se os seguintes objetivos específicos:

a) organizar e revisar as imagens provenientes da internet e do HU-UEL, padronizando as classes e as anotações em caixas delimitadoras;
b) preparar conjuntos de treinamento, validação e teste com controle de duplicatas e de imagens relacionadas, registrando a distribuição por classe e por origem;
c) treinar e avaliar a detecção com categorias gerais, mantendo uma representação específica das anotações para a investigação complementar da identificação dos instrumentos;
d) quantificar o desempenho de detecção e os erros de contagem total e por classe, incluindo a frequência de imagens com contagem correta;
e) analisar os casos de falha e os recursos computacionais empregados, delimitando as condições em que os resultados sustentam a viabilidade da abordagem.

1.3 Delimitação do estudo

O estudo utiliza fotografias estáticas e anotações por caixas delimitadoras, com foco na localização, na identificação e na contagem dos objetos presentes nas imagens. A versão inicialmente selecionada para os experimentos é o YOLO26. O uso de variantes com diferentes capacidades e a avaliação com classes específicas serão documentados de acordo com as execuções concluídas. A viabilidade será discutida a partir das evidências obtidas, sem adotar como resultado uma meta de desempenho previamente desejada.

A seleção das classes depende da correspondência com os instrumentos de referência e da disponibilidade de imagens. A pinça Collin coração não integra a configuração inicial por ausência de exemplos, e as pinças anatômicas contam inicialmente apenas com imagens provenientes da internet. A cúpula integra a contagem entre os objetos de interesse, e os porta-agulhas constituem catego-

ria própria. Essas delimitações impedem que os resultados sejam interpretados como validação de todos os componentes da caixa ou de todas as classes no contexto do HU-UEL.

As fotografias hospitalares disponíveis incluem instrumentos isolados e alguns agrupamentos de objetos. O desempenho nesses registros não será interpretado automaticamente como desempenho em bandejas completas, cenas com oclusão acentuada ou acompanhamento de procedimentos cirúrgicos. Essas condições exigem exemplos e avaliações correspondentes. Do mesmo modo, não se pretende demonstrar redução de eventos adversos, benefício clínico ou substituição de profissionais, mas estabelecer as possibilidades e limitações técnicas da abordagem no recorte investigado.

2 FUNDAMENTAÇÃO TEÓRICA

A contagem de instrumentos por imagem depende de duas etapas logicamente distintas: reconhecer as instâncias visíveis e agregar as detecções aceitas. A primeira envolve localização e classificação; a segunda transforma essas saídas em quantidades. Este capítulo apresenta os conceitos que sustentam essa abordagem, relaciona estudos sobre instrumentos cirúrgicos e discute os cuidados necessários para interpretar os resultados de uma avaliação experimental.

2.1 Representação visual e aprendizagem supervisionada

Na aprendizagem supervisionada, um modelo é ajustado a partir de exemplos associados a respostas de referência. O objetivo não se limita a reproduzir esses exemplos: espera-se que o modelo apresente desempenho adequado em dados novos. A diferença entre ajuste aos dados disponíveis e generalização é central para interpretar o treinamento de redes neurais (Goodfellow; Bengio; Courville, 2016).

Em imagens, as redes convolucionais exploram a organização espacial dos pixels por meio de filtros com parâmetros aprendidos. A aplicação de filtros em diferentes posições permite construir mapas de características, enquanto a composição de camadas possibilita representar padrões progressivamente mais complexos. O compartilhamento de parâmetros reduz a necessidade de aprender uma transformação independente para cada posição da imagem (Goodfellow; Bengio; Courville, 2016). Isso não elimina, entretanto, a influência das condições de aquisição sobre a resposta da rede.

Para instrumentos cirúrgicos, detalhes como a extremidade ativa, a presença de dentes e a curvatura podem ser decisivos para distinguir classes específicas. Uma fotografia em alta resolução pode conter esses detalhes, mas o redimensionamento para a entrada do detector pode torná-los pouco visíveis. Por outro lado, uma imagem que mostra apenas a ponta pode favorecer a identificação de uma característica e oferecer pouca informação sobre a localização do instrumento completo. Essas situações representam exigências diferentes para o sistema e precisam ser consideradas na seleção dos exemplos de treinamento e avaliação.

Classificação de imagens, detecção de objetos e segmentação de instâncias também produzem respostas diferentes. A classificação associa categorias à imagem; a detecção localiza objetos por caixas e atribui classes; a segmentação de instâncias delimita regiões de pixels de cada objeto. Na formulação original do YOLO, a rede estima caixas delimitadoras e probabilidades de classe a partir

da imagem completa (Redmon *et al.*, 2016). Para a contagem aqui investigada, a unidade de interesse é a instância de instrumento, e uma caixa deve representar um objeto, mesmo que ele tenha partes separadas visualmente por oclusão.

Uma caixa delimitadora alinhada aos eixos descreve uma região retangular, não o contorno exato do instrumento. Por isso, pode incluir fundo e partes de outros objetos, sobretudo quando o instrumento está inclinado ou sobreposto. Converter um polígono em sua caixa envolvente permite utilizar a anotação em detecção, mas descarta a informação fina de contorno. A conversão também não corrige automaticamente um polígono que abranja componentes fora do objeto desejado; essa adequação depende de revisão da anotação.

2.2 Detecção com a família YOLO

Redmon *et al.* (2016) propuseram tratar a detecção como uma predição conjunta de localização e classe em uma única rede. Essa formulação utiliza informação da imagem completa para estimar os objetos presentes. A designação YOLO, contudo, passou a reunir modelos com mudanças de arquitetura e treinamento; características da proposta original não devem ser atribuídas automaticamente às versões posteriores.

O YOLO26 é descrito por Jocher *et al.* (2026) como uma família com diferentes escalas de modelo e suporte a tarefas de visão computacional. Para detecção, os autores apresentam uma arquitetura com duas cabeças e a possibilidade de inferência sem uma etapa separada de supressão de não máximos, conhecida pela sigla NMS. Essa supressão é utilizada em detectores para reduzir caixas redundantes a partir de suas pontuações e sobreposição. A existência de um caminho de inferência sem NMS não dispensa a conferência da configuração efetivamente utilizada pelo software.

O estudo de Jocher *et al.* (2026) está disponível como *preprint*; sua descrição técnica é útil para identificar o modelo, mas não constitui validação independente para a aplicação hospitalar deste trabalho. Resultados obtidos pelos autores em bases de referência e dispositivos específicos não antecipam a precisão nem o tempo de execução nas imagens de instrumentos e no equipamento aqui empregado.

O uso de pesos pré-treinados permite iniciar o ajuste de um detector a partir de parâmetros já aprendidos, em vez de partir apenas de uma inicialização aleatória. Ainda assim, o novo treinamento precisa adaptar a saída às classes e aos exemplos disponíveis. O reaproveitamento de representações entre tarefas integra as estratégias de transferência de aprendizagem discutidas por Goodfellow, Bengio e Courville (2016). No presente problema, uma categoria reconhecida

em uma base genérica não equivale à distinção entre instrumentos visualmente próximos.

A escolha entre variantes de menor e maior capacidade envolve recursos computacionais, tempo disponível e desempenho observado. Um modelo maior pode exigir mais memória e processamento sem resolver problemas de anotação, baixa diversidade ou ausência de exemplos representativos. Consequentemente, a comparação de variantes precisa manter condições de avaliação compatíveis e apresentar os resultados medidos, sem tomar o tamanho do modelo como evidência antecipada de superioridade.

2.3 Estudos sobre reconhecimento de instrumentos cirúrgicos

Ran *et al.* (2023) investigaram uma adaptação do YOLOv7x para detectar instrumentos cirúrgicos. O trabalho aborda dificuldades relacionadas à semelhança entre objetos, à disposição dos instrumentos e às condições visuais das imagens. Sua contribuição sustenta o uso da detecção como abordagem pertinente ao problema, mas os resultados relatados estão vinculados às classes, às imagens e ao protocolo empregados naquele estudo.

Jiang *et al.* (2023) estudaram uma versão modificada do YOLOv5 para reconhecimento de instrumentos. A base descrita pelos autores inclui imagens com instrumentos sem empilhamento e com empilhamento, utilizando tecido azul como fundo. A consideração de sobreposição aproxima o estudo de uma dificuldade relevante para a contagem, pois a presença de vários objetos exige que o detector separe instâncias e mantenha sua identificação mesmo quando parte delas está encoberta.

Os dois trabalhos fornecem referências de aplicação, mas não estabelecem uma comparação direta com este TCC. Diferenças na composição das bases, no número de classes, nas condições de captura e nos critérios de avaliação impedem interpretar métricas publicadas como metas automaticamente transferíveis. Tampouco a adoção de uma versão mais recente da família YOLO garante superar os resultados de versões anteriores avaliadas em outros dados.

A contribuição deste trabalho concentra-se na avaliação da contagem para o conjunto de instrumentos selecionado e nas condições documentadas de aquisição e organização das imagens. Isso exige observar não apenas se há detecções, mas quais instrumentos foram omitidos, confundidos ou contados mais de uma vez. As orientações de cirurgia segura da Organização Mundial da Saúde contextualizam a importância da conferência de materiais (Organização Mundial da Saúde, 2009); contudo, uma avaliação computacional em fotografias não demonstra, por si só, redução de eventos adversos ou substituição de procedimen-

tos assistenciais.

2.4 Qualidade dos dados e independência da avaliação

A separação entre treinamento, validação e teste atribui funções diferentes aos dados. O treinamento ajusta os parâmetros; a validação auxilia a escolha de configurações; o teste estima o desempenho após essas escolhas. Utilizar repetidamente o teste para orientar modificações compromete sua função de avaliação independente. Kapoor e Narayanan (2023) discutem como o vazamento de informação pode levar a conclusões excessivamente otimistas em pesquisas baseadas em aprendizagem de máquina.

No caso de fotografias de instrumentos, a independência não pode ser verificada apenas pelo nome do arquivo. Cópias recomprimidas, recortes e transformações de uma mesma fotografia podem preservar grande parte do conteúdo visual. Imagens capturadas em sequência também podem compartilhar objeto, posição, iluminação e fundo. Se exemplos fortemente relacionados forem distribuídos entre treinamento e teste, a avaliação pode refletir a familiaridade com aquela aquisição, em vez da resposta a uma condição nova. O controle desse risco demanda rastreabilidade e agrupamento dos exemplos relacionados antes da divisão.

Identidade digital e similaridade visual são evidências diferentes. Um resumo criptográfico permite comparar os bytes dos arquivos, mas uma alteração de compressão pode modificar esses bytes sem produzir uma mudança visual relevante. Métodos perceptuais auxiliam a busca por candidatos semelhantes, porém não substituem a análise dos casos ambíguos: instrumentos distintos podem ter aparência próxima. O procedimento adotado precisa registrar os critérios e as decisões, sem afirmar que um único limiar garante ausência de vazamento.

O aumento de dados produz variações dos exemplos de treinamento, como mudanças de orientação e aparência. Essas transformações são formas de introduzir variação e regularizar o aprendizado (Goodfellow; Bengio; Courville, 2016). Elas não criam novas sessões independentes de coleta. Quando aplicadas durante o carregamento dos lotes, também não correspondem necessariamente a uma nova quantidade fixa de arquivos no disco. Por essa razão, é mais informativo registrar as técnicas, suas probabilidades e as épocas de aplicação do que apresentar uma multiplicação arbitrária do número de imagens.

Outro aspecto é a distribuição conjunta de classes e origens. Uma classe numerosa pode estar representada quase exclusivamente por imagens da internet, enquanto outra pode ter maior variedade de fotografias hospitalares. Assim, a quantidade de exemplos, isoladamente, não expressa a cobertura das condi-

ções de uso. Para este estudo, resultados separados por origem e por classe ajudam a localizar limitações que uma média global pode ocultar. Classes sem exemplos hospitalares de teste não permitem estimar diretamente seu desempenho nesse domínio.

2.5 Avaliação da detecção

A avaliação exige comparar predições com anotações de referência segundo critérios explícitos. A interseção sobre união, ou IoU, mede a sobreposição entre a caixa predita B_p e a caixa de referência B_r:

$$\text{IoU}(B_p, B_r) = \frac{|B_p \cap B_r|}{|B_p \cup B_r|}. \tag{1}$$

Na Equação 1, as barras representam áreas. A correspondência de uma detecção depende da classe, do limiar de IoU e da regra de associação entre predições e referências. Na avaliação usual de instâncias individuais, uma referência não deve contabilizar várias predições como acertos (Padilla *et al.*, 2021).

Sejam VP, FP e FN as quantidades de verdadeiros positivos, falsos positivos e falsos negativos. Precisão e revocação são expressas, para denominadores não nulos, por

$$P = \frac{VP}{VP + FP}, \qquad R = \frac{VP}{VP + FN}. \tag{2}$$

A precisão relaciona os acertos às detecções aceitas; a revocação relaciona os acertos aos objetos de referência. A precisão média, AP, resume a curva precisão--revocação segundo uma regra de integração ou interpolação. A mAP agrega AP entre classes. As convenções de cálculo precisam ser informadas, pois diferenças de implementação afetam a comparação (Padilla *et al.*, 2021).

Na notação usual, mAP@0,50 utiliza IoU de 0,50; mAP@0,50:0,95 agrega os limiares de 0,50 a 0,95 em passos de 0,05. Esses valores não representam a porcentagem de fotografias cuja contagem está correta. Além disso, o limiar de IoU empregado para julgar a localização não é o limiar de confiança utilizado para aceitar uma predição. A metodologia deve registrar ambos e distinguir a avaliação da curva de detecção da configuração usada para produzir as contagens.

Uma caixa imprecisa pode ainda contribuir com uma unidade para a contagem, enquanto uma classificação errada pode preservar o total e alterar a composição por instrumento. Por isso, as métricas de detecção e de contagem respondem a perguntas complementares. A análise dos erros deve relacionar o resultado numérico às caixas e às classes preditas.

2.6 Contagem por detecção e critérios de interpretação

Considere N imagens e C classes. Para a imagem i, seja D_i o conjunto de detecções aceitas após a aplicação dos critérios de confiança e pós-processamento definidos. A contagem estimada da classe c pode ser escrita como

$$\widehat{n}_{ic} = \sum_{d \in D_i} \mathbf{1}[\text{classe}(d) = c], \qquad \widehat{n}_i = \sum_{c=1}^{C} \widehat{n}_{ic}, \tag{3}$$

em que $\mathbf{1}[\cdot]$ vale um quando a condição é verdadeira e zero caso contrário. Os índices matemáticos das classes vão de um a C, independentemente da numeração adotada nos arquivos de anotação. Essa formulação explicita que a contagem depende das detecções efetivamente aceitas, não de todas as hipóteses internas da rede.

Se n_i é a contagem total de referência, o erro absoluto médio total é

$$\text{MAE}_{\text{total}} = \frac{1}{N} \sum_{i=1}^{N} |\widehat{n}_i - n_i|. \tag{4}$$

O valor informa quantos objetos, em média por imagem, separam a estimativa do total anotado. Para examinar a identificação, calcula-se também o erro por classe, substituindo os totais por $\widehat{n}_{ic}$ e n_{ic}. Quando a maioria das imagens não contém determinada classe, a média calculada sobre todas as imagens pode ser pequena mesmo com falhas nos exemplos positivos; convém, portanto, explicitar o suporte e separar a análise de presença e ausência.

A proporção de imagens com total exato e a proporção com todas as contagens por classe corretas podem ser definidas, respectivamente, por

$$E_{\text{total}} = \frac{1}{N} \sum_{i=1}^{N} \mathbf{1}[\widehat{n}_i = n_i], \tag{5}$$

$$E_{\text{classes}} = \frac{1}{N} \sum_{i=1}^{N} \mathbf{1}[\widehat{n}_{ic} = n_{ic} \text{ para todo } c]. \tag{6}$$

Essas expressões são definições operacionais para organizar a avaliação deste problema, e não resultados experimentais. Uma omissão e uma detecção indevida podem se compensar no total; até a igualdade das contagens por classe pode coexistir com erros de localização. Nenhum desses indicadores substitui a inspeção das detecções.

O Quadro 1 sintetiza as diferenças entre as perguntas de avaliação. O agrupamento em categorias gerais exige atenção adicional: confundir duas clas-

ses específicas pertencentes ao mesmo grupo deixa de ser um erro de classe nessa representação. Logo, um resultado superior com categorias gerais não demonstra, por si só, melhor reconhecimento específico.

Quadro 1 – Interpretação complementar dos resultados

Aspecto	**Pergunta respondida**	**Limite de interpretação**
Detecção	Os instrumentos foram localizados e classificados?	Não informa diretamente a frequência de contagens exatas.
Contagem total	Quantos objetos há na imagem?	Erros podem se compensar; classes podem estar trocadas.
Contagem por classe	A composição por instrumento está correta?	Contagens iguais não garantem caixas corretas.
Imagens sem objetos	O sistema produz detecções indevidas?	Bandejas vazias não representam todos os fundos possíveis.
Tempo de execução	Qual o custo no equipamento utilizado?	Depende da resolução e das etapas incluídas na medição.

Fonte: elaboração própria.

Finalmente, a viabilidade técnica depende do cenário avaliado. Fotografias de objetos isolados, imagens com poucos instrumentos e fotografias de bandejas completas impõem dificuldades distintas. Uma conclusão favorável em um desses cenários deve permanecer limitada às condições observadas. Neste trabalho, a articulação entre detecção, contagem, análise visual dos erros e custo computacional fornece a base para essa delimitação, sem converter desempenho experimental em comprovação de segurança clínica.

3 CONCLUSÃO

Com a presente pesquisa, conclui-se que...

REFERÊNCIAS

BRASIL. MINISTÉRIO DA SAÚDE. **Documento de referência para o Programa Nacional de Segurança do Paciente**. Brasília, DF: Ministério da Saúde, 2014. 40 p. ISBN 978-85-334-2130-1. Disponível em: https://bvsms.saude.gov.br/bvs/publicacoes/documento_referencia_programa_nacional_seguranca.pdf. Acesso em: 30 out. 2026.

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. **Deep Learning**. Cambridge, MA: MIT Press, 2016. Disponível em: https://www.deeplearningbook.org/. Acesso em: 31 out. 2026.

JIANG, Kaile; PAN, Shuwan; YANG, Luxuan; YU, Jie; LIN, Yuanda; WANG, Huaiqian. Surgical Instrument Recognition Based on Improved YOLOv5. **Applied Sciences**, Basel, v. 13, n. 21, 11709, 2023. DOI: 10.3390/app132111709. Disponível em: https://www.mdpi.com/2076-3417/13/21/11709. Acesso em: 30 out. 2026.

JOCHER, Glenn; QIU, Jing; LIU, Mengyu; LYU, Shuai; AKYON, Fatih Cagatay; KALFAOGLU, Muhammet Esat. **Ultralytics YOLO26: Unified Real-Time End-to-End Vision Models**. Preprint. Versão 1. arXiv. 2 jun. 2026. DOI: 10.48550/arXiv.2606.03748. Disponível em: https://arxiv.org/abs/2606.03748v1. Acesso em: 31 out. 2026.

KAPOOR, Sayash; NARAYANAN, Arvind. Leakage and the reproducibility crisis in machine-learning-based science. **Patterns**, v. 4, n. 9, 100804, 2023. DOI: 10.1016/j.patter.2023.100804. Disponível em: https://doi.org/10.1016/j.patter.2023.100804. Acesso em: 31 out. 2026.

ORGANIZAÇÃO MUNDIAL DA SAÚDE. **Segundo desafio global para a segurança do paciente: cirurgias seguras salvam vidas (orientações para cirurgia segura da OMS)**. Tradução: Marcela Sánchez Nilo e Irma Angélica Durán. Rio de Janeiro: Organização Pan-Americana da Saúde, Ministério da Saúde e Agência Nacional de Vigilância Sanitária, 2009. 211 p. ISBN 978-85-87943-97-2. Disponível em: https://bvsms.saude.gov.br/bvs/publicacoes/seguranca_paciente_cirurgias_seguras_salvam_vidas.pdf. Acesso em: 30 out. 2026.

PADILLA, Rafael; PASSOS, Wesley L.; DIAS, Thadeu L. B.; NETTO, Sergio L.; SILVA, Eduardo A. B. da. A Comparative Analysis of Object Detection Metrics with a Companion Open-Source Toolkit. **Electronics**, Basel, v. 10, n. 3, 279, 2021. DOI: 10.3390/electronics10030279. Disponível em: https://www.mdpi.com/2079-9292/10/3/279. Acesso em: 31 out. 2026.

RAN, Boping; HUANG, Bo; LIANG, Shunpan; HOU, Yulei. Surgical Instrument Detection Algorithm Based on Improved YOLOv7x. **Sensors**, Basel, v. 23, n. 11, 5037, 2023. DOI: 10.3390/s23115037. Disponível em: https://www.mdpi.com/1424-8220/23/11/5037. Acesso em: 30 out. 2026.

REDMON, Joseph; DIVVALA, Santosh; GIRSHICK, Ross; FARHADI, Ali. You Only Look Once: Unified, Real-Time Object Detection*. In:* IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2016, Las Vegas. **Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition**. Las Vegas: IEEE, 2016. p. 779–788. Disponível em: https://openaccess.thecvf.com/content_cvpr_2016/html/Redmon_You_Only_Look_CVPR_2016_paper.html. Acesso em: 30 out. 2026.

GLOSSÁRIO *(opcional)*

Glossário é uma ferramenta linguística/terminológica para apresentação do significado de palavras ou preferencialmente termos. A palavra tem sua existência no contexto geral, enquanto o termo conta com um significado particular, dependendo da área em que se encontra vinculado. Na apresentação dos termos e significado, sugere-se que sejam apresentadas fontes, contudo, em caso de significados atribuídos pelo próprio autor ou significados contextuais, a apresentação da fonte não é totalmente aplicável.

Exemplos:

Bibliografia: no contexto de trabalhos acadêmicos, a bibliografia muitas vezes está relacionada com o conjunto de insumos que determinada pessoa se apropriou, para a elaboração de uma pesquisa. A bibliografia pode ser lida também como um conjunto ordenado de materiais sobre determinado assunto. Em uma pesquisa, a bibliografia não precisa necessariamente ter sido citada para demonstrar relevância no trabalho, ela muitas vezes é vista também como sugestões para se aprofundar em determinado tópico, diferentemente das referências.

Dissertação: no Brasil, a dissertação é comumente relativa à materialização para a defesa de uma pesquisa à nível de mestrado.

Referência: a principal diferença da referência para a bibliografia, é a citação. As referências, como seu próprio termo diz, são documentos citados para a composição ou apresentação de determinada fonte. Em um trabalho acadêmico, às referências se configuram com uma relação de materiais citados ao longo de uma pesquisa, são a sua base teórica ou metodológica.

APÊNDICE – *(opcional)*

O apêndice é composto por um conteúdo original, inédito e de autoria própria, necessário ou utilizado para enriquecer a compreensão da leitura da pesquisa.

ANEXO *(opcional)*

O anexo é composto por um conteúdo de terceiros ou de autoria própria, necessário ou utilizado para enriquecer a compreensão da leitura da pesquisa.

ÍNDICE *(opcional)*

O índice configura-se, de modo geral, como um instrumento que reúne e muitas vezes direciona o leitor para trechos do documento. Normalmente, segmentando partes ou assuntos possivelmente de interesse do público. Uma diferença do índice e do sumário é de que o sumário apresenta a divisão formal do documento, enquanto o índice exige um processo mais complexo de indexação para sua elaboração.